Ταξινόμηση Τρισδιάστατων Μαγνητικών Τομογραφιών Εγκεφάλου με Προηγμένες Αρχιτεκτονικές Βαθιών Νευρωνικών Δικτύων

Θεοδώρα Ξούλου

Διπλωματική Εργασία

Επιβλέπων: Μπλέκας Κωνσταντίνος

Ιωάννινα, Φεβρουάριος, 2026



ΤΜΗΜΑ ΜΗΧ. Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ
ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ

DEPARTMENT OF COMPUTER SCIENCE & ENGINEERING
UNIVERSITY OF IOANNINA

Περίληψη

Η παρούσα διπλωματική εργασία εξετάζει την αυτόματη ανίχνευση και εκτίμηση βαθμού άνοιας μέσω τρισδιάστατων δεδομένων μαγνητικής τομογραφίας εγκεφάλου, αξιοποιώντας σύγχρονες τεχνικές βαθιάς μάθησης και συνένωσης πληροφορίας. Αναπτύχθηκε ένα ολοκληρωμένο υπολογιστικό πλαίσιο που περιλαμβάνει στάδια προεπεξεργασίας, ομογενοποίησης όγκων, εξαγωγής αναπαραστάσεων από προεκπαιδευμένα 3D νευρωνικά δίκτυα και συγκριτικής αξιολόγησης πολλαπλών στρατηγικών ταξινόμησης.

Μελετήθηκαν τρία διαφορετικά 3D backbones (Med3D, ModelGenesis, MedicalNet) σε δυαδικά και πολυταξικά διαγνωστικά σενάρια, ενώ διερευνήθηκαν τεχνικές early, mid, late και weighted fusion, καθώς και ιεραρχική αρχιτεκτονική δύο σταδίων που προσεγγίζει τη λογική της κλινικής διάγνωσης. Ιδιαίτερη έμφαση δόθηκε στη συστηματική αξιολόγηση με μετρικές κατάλληλες για ανισόρροπα ιατρικά δεδομένα, με κύριο δείκτη τη Macro-F1.

Τα αποτελέσματα ανέδειξαν ότι δεν υφίσταται καθολικά βέλτιστη αρχιτεκτονική για όλα τα διαγνωστικά σενάρια. Η δυαδική ανίχνευση παθολογίας και η εκτίμηση βαρύτητας ωφελούνται από διαφορετικές αναπαραστάσεις, ενώ η σταθμισμένη late fusion παρείχε τη σταθερότερη συμπεριφορά στο πολυταξικό πρόβλημα. Επιπλέον, η ιεραρχική προσέγγιση συνέβαλε στη μείωση της πολυπλοκότητας της απόφασης και στη βελτίωση της διαχωριστικής ικανότητας μεταξύ σταδίων άνοιας.

Η εργασία καταδεικνύει ότι η αποτελεσματικότητα σε 3D ιατρικά δεδομένα εξαρτάται από τον συνδυασμό κατάλληλων αναπαραστάσεων, ελεγχόμενης πολυπλοκότητας και αυστηρής μεθοδολογικής σχεδίασης, προσφέροντας μια τεκμηριωμένη βάση για περαιτέρω ανάπτυξη συστημάτων υποβοηθούμενης διάγνωσης νευροεκφυλιστικών νόσων.

Λέξεις Κλειδιά: Άνοια, Νόσος Alzheimer, Τρισδιάστατη Μαγνητική Τομογραφία (3D MRI), Βαθιά Μάθηση, 3D CNN, Μεταφορά Μάθησης, Προεκπαιδευμένο Μοντέλο, Συνένωση Πληροφοριών (Data Fusion), Ιεραρχική Ταξινόμηση, Macro – F1

Abstract

This thesis examines the automatic detection and assessment of dementia severity using three-dimensional magnetic resonance imaging (MRI) data of the brain, utilizing modern deep learning and information fusion techniques. A comprehensive computational framework was developed that includes preprocessing, volume homogenization, representation extraction from pretrained 3D neural networks, and comparative evaluation of multiple classification strategies.Three different 3D backbones (Med3D, ModelGenesis, MedicalNet) were studied in binary and multi-class diagnostic scenarios, while early, mid, late, and weighted fusion techniques were investigated, as well as a two-stage hierarchical architecture that approximates the logic of clinical diagnosis. Particular emphasis was placed on systematic evaluation with metrics suitable for imbalanced medical data, with Macro-F1 as the main indicator.The results showed that there is no universally optimal architecture for all diagnostic scenarios. Binary pathology detection and severity assessment benefit from different representations, while weighted late fusion provided the most stable behavior in the multi-class problem. Furthermore, the hierarchical approach contributed to reducing decision complexity and improving the discriminatory power between stages of dementia.The work demonstrates that effectiveness in 3D medical data depends on the combination of appropriate representations, controlled complexity, and rigorous methodological design, providing an evidence-based foundation for further development of assisted diagnosis systems for neurodegenerative diseases.

Keywords: Dementia, Alzheimer's Disease, Three-dimensional Magnetic Resonance Imaging (3D MRI), Deep Learning, 3D CNN, Transfer Learning, Pre-trained Model, Data Fusion, Hierarchical Classification, Macro – F1

Πίνακας Περιεχομένων

Κεφάλαιο 1. Εισαγωγή **1**

1.1 Δομή Προβλήματος & Κίνητρο 1

1.2 Σκοπός και Στόχοι Έρευνας 2

1.3 Επισκόπηση της Προτεινόμενης Προσέγγισης 2

1.4 Συνεισφορά της Διπλωματικής Εργασίας 3

Κεφάλαιο 2. Ανασκόπηση Βιβλιογραφίας **4**

2.1 Πειραματικός Σχεδιασμός και Διαχείριση Δεδομένων στην Ταξινόμηση MRI 4

2.1.1 Διασταυρούμενη Επικύρωση στην Ιατρική Απεικόνιση *4*

2.1.2 Διαρροή Πληροφορίας (Data Leakage) *4*

2.1.3 Διαχωρισμός σε Επίπεδο Εξεταζόμενου Ατόμου *5*

2.2 Δομικές Ιδιαιτερότητες και Κατανομή Δειγμάτων σε Σύνολα Δεδομένων MRI ... 5

2.3 Προεπεξεργασία Δεδομένων MRI για Μοντέλα Μηχανικής και Βαθιάς Μάθησης 5

2.3.1 Ομογενοποίηση και Τυποποίηση Εισόδων *6*

2.3.2 Αφαίρεση Μη Εγκεφαλικού Ιστού και Καθαρισμός Θορύβου *6*

2.3.3 Κανονικοποίηση Έντασης και Κλιμάκωση *7*

2.3.4 Μεταφορά Μάθησης και Συμβατότητα με Προεκπαιδευμένα Μοντέλα *7*

2.4 Υπολογιστικές Προσεγγίσεις για Ταξινόμηση MRI στην Άνοια 7

2.4.1 Παραδοσιακές Μέθοδοι Μηχανικής Μάθησης *7*

2.4.2 Βαθιά Μάθηση σε 2D Απεικονίσεις MRI *8*

2.4.3 Τρισδιάστατα Δίκτυα Βαθιάς Μάθησης (3D CNNs) *8*

2.4.4 Προεκπαιδευμένα 3D Μοντέλα και Transfer Learning *8*

2.5 Σύνθετες Στρατηγικές Ταξινόμησης 9

2.5.1 Ensemble Μέθοδοι στην Ταξινόμηση MRI *9*

2.5.2 Ιεραρχική Ταξινόμηση (Hierarchical Classification) *9*

2.6 Συνένωση Πληροφορίας (Data Fusion) στην Ανάλυση MRI 10

2.7 Μετρικές Αξιολόγησης σε Ανισόρροπα Ιατρικά Δεδομένα 11

2.8 Σύνοψη Κεφαλαίου 11

Κεφάλαιο 3. Θεωρητικό Υπόβαθρο **13**

3.1 Μαγνητική Τομογραφία Εγκεφάλου και Τρισδιάστατη Αναπαράσταση MRI Δεδομένων 13

3.1.1 T1- Weighted MRI και Δομική Απεικόνιση *13*

3.1.2 Τρισδιάστατη Αναπαράσταση Ιατρικών Εικόνων *13*

3.2 Προεπεξεργασία Τρισδιάστατων MRI Δεδομένων 14

3.2.1 Skull Stripping και Brain Masking *14*

3.2.2 Bias Field Correction *15*

3.2.3 Κανονικοποίηση Έντασης *16*

3.2.4 Χωρική Κανονικοποίηση *16*

3.2.5 3D Data Augmentation ... *16*
3.3 Διαχωρισμός Δεδομένων και Πειραματικό Πρωτόκολλο ... 17
3.3.1 Διαχωρισμός σε Επίπεδο Εξεταζόμενου ... *17*
3.3.2 Στρωματοποιημένη Δειγματοληψία ... *18*
3.3.3 Στρατηγική Διαχωρισμού Δεδομένων ... *18*
3.3.4 Αναπαραγωγιμότητα (Reproducibility) ... *19*
3.4 Μεταφορά Μάθησης και Προεκπαιδευμένα 3D Μοντέλα Εξαγωγής Χαρακτηριστικών ... 19
3.4.1 Μεταφορά Μάθησης (Transfer Learning) ... *19*
3.4.2 Προεκπαιδευμένα Τρισδιάστατα Μοντέλα (Pretrained Models) ... *20*
3.4.3 Εξαγωγή και Τυποποίηση Χαρακτηριστικών ... *22*
3.5 Θεμελιώδεις Ταξινομητές Μηχανικής Μάθησης ... 22
3.5.1 Προτυποποίηση Χαρακτηριστικών ... *23*
3.5.2 Γραμμικοί Ταξινομητές ... *23*
3.5.3 Μη Γραμμικός SVM ... *24*
3.5.4 Distance – Based Μέθοδοι ... *24*
3.5.5 Ensemble Μέθοδοι ... *25*
3.5.6 Πολυεπίπεδα Νευρωνικά Δίκτυα (MLP) ... *25*
3.5.7 Διαχείριση Ανισορροπίας Κλάσεων ... *26*
3.6 Ιεραρχική Ταξινόμηση ... 26
3.6.1 Διατύπωση Προβλήματος ... *26*
3.6.2 Σύγκριση με Επίπεδη (Flat) Προσέγγιση ... *27*
3.7 Συνένωση Πληροφοριών (Data Fusion) ... 27
3.7.1 Συνένωση σε Επίπεδο Χαρακτηριστικών (Feature – Level Fusion) ... *27*
3.7.2 Συνένωση σε Επίπεδο Απόφασης (Decision – Level Fusion) ... *27*
3.7.3 Stacking Fusion ... *28*
3.7.4 Θεωρητική Σημασία της Συνένωσης ... *28*
3.8 Μετρικές Αξιολόγησης ... 29
Κεφάλαιο 4. Προτεινόμενη Μεθοδολογία ... 32
4.1 Συνολική Αρχιτεκτονική της Προτεινόμενης Προσέγγισης ... 32
4.2 Προεπεξεργασία και Οργάνωση Δεδομένων MRI ... 32
4.2.1 Αρχική μορφή δεδομένων και δομή dataset ... *32*
4.2.2 Ενοποίηση βάθους όγκου ... *33*
4.2.3 Δημιουργία Διαφορετικών Διαγνωστικών Σεναρίων ... *34*
4.2.4 Μετατροπή σε 3D Volumes(.npy) ... *34*
4.2.5 Προεπεξεργασία 3D όγκου και κανονικοποίηση εντάσεων ... *35*
4.2.6 Στρωματοποιημένος Διαχωρισμός ανά Εξεταζόμενο ... *35*
4.2.7 Τρισδιάστατο Data Augmentation στο Training Set ... *36*
4.3 Εξαγωγή Χαρακτηριστικών με Προεκπαιδευμένα 3D Δίκτυα ... 36
4.3.1 Εξαγωγή Χαρακτηριστικών με Med3D (ResNet – 18) ... *37*
4.3.2 Εξαγωγή Χαρακτηριστικών με MedicalNet(ResNet – 50 3D) ... *37*
4.3.3 Εξαγωγή Χαρακτηριστικών με Model Genesis ... *37*
4.4 Κανονικοποίηση και Μείωση Διάστασης των Χαρακτηριστικών ... 38

4.5 Εκπαίδευση Κλασσικών Ταξινομητών 38
4.6 Συνδυασμός Πληροφοριών και Μοντέλων (Fusion Strategies) 39
4.6.1 Early Fusion 39
4.6.2 Mid- Level Fusion 40
4.6.3 Late Fusion 40
4.6.4 Stacking 40
4.7 Ιεραρχικός Ταξινομητής 41
Κεφάλαιο 5. Πειραματική Υλοποίηση και Αποτελέσματα 43
5.1 Πειραματικό Περιβάλλον 43
5.2 Πειραματικό Πρωτόκολλο 43
5.2.1 Διαχωρισμός Δεδομένων 43
5.2.2 Κανονικοποίηση και Μείωση Μεγέθους Διανυσμάτων 44
5.2.3 Εκπαίδευση Ταξινομητών 44
5.2.4 Σενάρια Αξιολόγησης 44
5.2.5 Μετρικές Αξιολόγησης 44
5.3 Αποτελέσματα Βασικών Ταξινομητών 44
5.3.1 Αποτελέσματα Δυαδικής Ταξινόμησης 45
5.3.2 Αποτελέσματα Ταξινόμησης Βαρύτητας Άνοιας 48
5.3.3 Αποτελέσματα Πολυταξικής Ταξινόμησης (3 Κατηγοριών) 49
5.4 Αποτελέσματα Τεχνικών Fusion 50
5.4.1 Late Fusion Level 50
5.5 Αποτελέσματα Ιεραρχικού Ταξινομητή 50
5.6 Συνολικά Καλύτερα Αποτελέσματα και Σύγκριση 50
5.6.1 Σενάριο Δυαδικής Ταξινόμησης 50
5.6.2 Σενάριο 3 κλάσεων 53
5.6.3 Σενάριο Εκτίμησης Βαθμού Άνοιας 55
Κεφάλαιο 6. Συζήτηση 57
6.1 Ερμηνεία των Πειραματικών Αποτελεσμάτων 57
6.2 Ανταλλαγές μεταξύ των Μετρικών 58
6.3 Σύγκριση με Βιβλιογραφία 58
6.4 Μεθοδολογικές Επιπτώσεις 59
6.5 Περιορισμοί της Προτεινόμενης Προσέγγισης 59
6.6 Συνολική Τοποθέτηση 59
Κεφάλαιο 7. Συμπεράσματα & Μελλοντική Έρευνα 61
7.1 Σύνοψη Συνεισφορών 61
7.2 Συμπεράσματα 61
7.3 Προτάσεις για Μελλοντική Έρευνα 62
Βιβλιογραφία 63

Κεφάλαιο 1. Εισαγωγή

Η παρούσα διπλωματική εργασία πραγματεύεται το ζήτημα της αυτοματοποιημένης ταξινόμησης τρισδιάστατων μαγνητικών τομογραφιών εγκεφάλου στο πλαίσιο της άνοιας, αξιοποιώντας προηγμένες μεθόδους βαθιάς μάθησης. Η μελέτη επικεντρώνεται γύρω από τη διερεύνηση της αποτελεσματικότητας διαφορετικών διαγνωστικών προσεγγίσεων και στρατηγικών ταξινόμησης, με έμφαση στη σωστή διαχείριση των δεδομένων και στην αξιόπιστη αξιολόγηση των μοντέλων.

1.1 Δομή Προβλήματος & Κίνητρο

Η άνοια είναι ένα σύνδρομο που χαρακτηρίζεται από προοδευτική έκπτωση των γνωστικών λειτουργιών, όπως η μνήμη, η σκέψη, η γλώσσα και η ικανότητα λήψης αποφάσεων, πέραν αυτής που αναμένεται στο πλαίσιο της φυσιολογικής γήρανσης. Συνδέεται με παθολογικές μεταβολές του εγκεφάλου, ενώ η σταδιακή και επίμονη επιδείνωση των νοητικών ικανοτήτων επηρεάζει σημαντικά την καθημερινή λειτουργικότητα και την ποιότητα ζωής των ασθενών(World Health Organization, 2012). Η εμφάνιση της άνοιας έχει αυξηθεί, αφενός επειδή καταγράφεται σταθερή άνοδος του προσδόκιμου ζωής και μείωση της θνησιμότητας σε νεότερες ηλικίες και αφετέρου εξαιτίας της αυξημένης έκθεσης του πληθυσμού σε τροποποιήσιμους παράγοντες κινδύνου(Livingston et al., 2020). Αξίζει να σημειωθεί ότι η κλιμάκωση της άνοιας δεν αντανακλά αποκλειστικά πραγματική αύξηση των περιστατικών, αλλά σχετίζεται και με τη βελτίωση των διαγνωστικών πρακτικών και την ακριβέστερη καταγραφή της νόσου. Σε κάθε περίπτωση, η συχνότητα εμφάνισής της την καθιστά ένα μείζον πρόβλημα δημόσιας υγείας με σημαντικές κοινωνικές και οικονομικές επιπτώσεις.

Ένας καθοριστικός παράγοντας για την αποτελεσματική αντιμετώπιση της άνοιας είναι η έγκαιρη και αξιόπιστη διάγνωσή της. Η διάγνωση αποτελεί βασική προϋπόθεση τόσο για τον ίδιο τον ασθενή όσο και για το σύστημα υγείας, καθώς επιτρέπει την πρώιμη έναρξη κατάλληλης φροντίδας και υποστήριξης. Ιδιαίτερα σημαντικό είναι το γεγονός ότι η άνοια δεν συνιστά αποκλειστικά ένα ιατρικό πρόβλημα, αλλά μια σύνθετη κατάσταση που επηρεάζει συνολικά την καθημερινή ζωή του ατόμου, καθώς και το άμεσο κοινωνικό και οικογενειακό του περιβάλλον. Παράλληλα, η επίσημη διάγνωση της νόσου είναι απαραίτητη για την αξιόπιστη καταγραφή των περιστατικών, τον σχεδιασμό υπηρεσιών υγείας και την ανάπτυξη στοχευμένων πολιτικών πρόληψης και φροντίδας σε επίπεδο δημόσιας υγείας. Η απουσία διάγνωσης οδηγεί συχνά σε υποεκτίμηση της πραγματικής έκτασης της άνοιας και σε ανεπαρκή διαχείρισή της σε κοινωνικό και θεσμικό επίπεδο.

Ωστόσο, η διαγνωστική διαδικασία παραμένει ιδιαίτερα απαιτητική, ιδίως στα αρχικά στάδια της νόσου, όπου τα κλινικά συμπτώματα μπορεί να είναι ήπια ή να συγχέονται με φυσιολογικές μεταβολές που σχετίζονται με τη γήρανση. Επιπλέον, η ετερογένεια των κλινικών εκδηλώσεων και η πολυπλοκότητα των υποκείμενων νευροεκφυλιστικών μηχανισμών δυσχεραίνουν περαιτέρω την αντικειμενική και αξιόπιστη αξιολόγηση της άνοιας, καθιστώντας αναγκαία την ανάπτυξη πιο ακριβών και ευαίσθητων διαγνωστικών προσεγγίσεων (Livingston et al., 2020).

Η μαγνητική τομογραφία εγκεφάλου (Magnetic Resonance Imaging – MRI) αποτελεί ένα από τα βασικότερα απεικονιστικά εργαλεία για τη μελέτη δομικών αλλοιώσεων που σχετίζονται με την άνοια, καθώς παρέχει λεπτομερή χωρική πληροφορία και αποτύπωση ανατομικών χαρακτηριστικών και μορφολογικών μεταβολών του εγκεφάλου(Silva et al., 2020).

Η αξιοποίηση απεικονιστικών δεδομένων εγκεφάλου για υπολογιστική ανάλυση είναι μία υποσχόμενη κατεύθυνση, ωστόσο η ταξινόμηση τρισδιάστατων μαγνητικών τομογραφιών εγκεφάλου στο πλαίσιο της άνοιας εξακολουθεί να παρουσιάζει δυσκολίες. Τα διαθέσιμα σύνολα δεδομένων είναι συχνά περιορισμένα και εμφανίζουν ανισορροπία μεταξύ των κλάσεων, γεγονός που επηρεάζει την απόδοση των μοντέλων(Bradshaw et al., 2023; Cui et al., 2019). Τα παραπάνω καταδεικνύουν την ανάγκη για προσεκτικά σχεδιασμένες προσεγγίσεις, οι οποίες αξιοποιούν σύγχρονες μεθόδους βαθιάς μάθησης και εξασφαλίζουν αξιόπιστη αξιολόγηση και καλή γενίκευση σε νέα δεδομένα.

1.2 Σκοπός και Στόχοι Έρευνας

Ο πρωταρχικός σκοπός της παρούσας διπλωματικής εργασίας είναι η ανάπτυξη και αξιολόγηση προηγμένων αρχιτεκτονικών βαθιών νευρωνικών δικτύων με σκοπό την αυτοματοποιημένη ταξινόμηση των τρισδιάστατων μαγνητικών τομογραφιών εγκεφάλου, με επιδιωκόμενο αποτέλεσμα την υποστήριξη της διάγνωσης της άνοιας και την εκτίμηση του βαθμού σοβαρότητάς της. Στο πλαίσιο αυτό, πραγματοποιείται συστηματική σύγκριση των διαφορετικών υπολογιστικών προσεγγίσεων με καθιερωμένες μετρικές αξιολόγησης και διερευνάται η δυνατότητά τους να λειτουργήσουν ως αξιόπιστα εργαλεία υποστήριξης της διαγνωστικής διαδικασίας.

Για την εκπλήρωση του σκοπού αυτού είναι σημαντικό να επιτευχθούν οι επιμέρους στόχοι:

- Η σωστή οργάνωση των δεδομένων MRI σε επίπεδο εξεταζόμενου ατόμου (subject-level).
- Η προεπεξεργασία των δεδομένων με στόχο τη διατήρηση αποκλειστικά εγκεφαλικής, και επομένως ουσιαστικής, πληροφορίας.
- Η κατάλληλη διάρθρωση του συνόλου δεδομένων για τη διασφάλιση αξιόπιστης εκπαίδευσης.
- Η ορθή εξαγωγή χαρακτηριστικών μέσω προεκπαιδευμένων τρισδιάστατων μοντέλων βαθιάς μάθησης.
- Η υλοποίηση και σύγκριση δυαδικών και πολυκατηγορικών ταξινομητών.
- Η διερεύνηση ιεραρχικών στρατηγικών ταξινόμησης.
- Η εφαρμογή τεχνικών συνδυασμού πληροφορίας (data fusion) με στόχο την ενσωμάτωση συμπληρωματικών πηγών χαρακτηριστικών και τη βελτίωση της διακριτικής ικανότητας των ταξινομητών.
- Η αξιολόγηση της απόδοσης των προτεινόμενων προσεγγίσεων με χρήση καθιερωμένων μετρικών.

1.3 Επισκόπηση της Προτεινόμενης Προσέγγισης

Η προσέγγιση που ακολουθείται στη συγκεκριμένη εργασία καλύπτει όλα τα στάδια από την επεξεργασία των δεδομένων έως την τελική αξιολόγηση των μοντέλων.

Σε πρώτο στάδιο, τα δεδομένα MRI υποβάλλονται σε προεπεξεργασία ώστε να χρησιμοποιηθούν ως είσοδοι στα υπολογιστικά μοντέλα. Σημείο–κλειδί στο συγκεκριμένο στάδιο είναι η διαχείριση των δεδομένων ανά εξεταζόμενο άτομο (subject-level), προκειμένου να αποφευχθεί η διαρροή της πληροφορίας μεταξύ των συνόλων εκπαίδευσης και αξιολόγησης.

Για την εξαγωγή χαρακτηριστικών από τις τρισδιάστατες εικόνες του συνόλου δεδομένων αξιοποιούνται προεκπαιδευμένα μοντέλα βαθιάς μάθησης, τα οποία έχουν εκπαιδευτεί σε σχετικά ιατρικά σύνολα δεδομένων και είναι σε θέση να αποτυπώνουν χωρικά και μορφολογικά πρότυπα στον τρισδιάστατο χώρο. Η αξιοποίηση της προ υπάρχουσας γνώσης των μοντέλων αυτών επιτρέπει τη μεταφορά της σε νέα απεικονιστικά δεδομένα (transfer learning).

Στη συνέχεια, υλοποιούνται διαγνωστικά σχήματα ταξινόμησης, τόσο δυαδικά όσο και πολυκατηγορικά, μέσω των οποίων εξετάζεται η ικανότητα των μοντέλων να διακρίνουν διαφορετικές κατηγορίες άνοιας.

Πέραν των βασικών σεναρίων ταξινόμησης, διερευνώνται και πιο σύνθετες στρατηγικές, όπως η ιεραρχική ταξινόμηση, η οποία επιτρέπει τη σταδιακή διάκριση των κατηγοριών άνοιας, καθώς και τεχνικές συνδυασμού πληροφορίας (data fusion), που αποσκοπούν στην αξιοποίηση συμπληρωματικών πηγών πληροφορίας και στη βελτίωση της συνολικής απόδοσης των μοντέλων.

Τέλος, η απόδοση των προτεινόμενων προσεγγίσεων αξιολογείται με τη χρήση καθιερωμένων μετρικών ταξινόμησης, επιτρέποντας τη συστηματική σύγκριση των διαφορετικών μοντέλων και στρατηγικών. Μέσω της διαδικασίας αυτής, εκτιμάται η αποτελεσματικότητα των μεθόδων βαθιάς μάθησης ως εργαλείων υποστήριξης της διαγνωστικής διαδικασίας της άνοιας.

1.4 Συνεισφορά της Διπλωματικής Εργασίας

Η παρούσα εργασία συμβάλλει στην ανάλυση και αξιολόγηση μεθόδων για την ταξινόμηση τρισδιάστατων μαγνητικών τομογραφιών εγκεφάλου, με έμφαση στη σωστή οργάνωση και αξιοποίηση των διαθέσιμων δεδομένων.

Οι βασικές συνεισφορές της εργασίας περιλαμβάνουν:

- Τη σχεδίαση και υλοποίηση ενιαίου πλαισίου επεξεργασίας και ταξινόμησης τρισδιάστατων δεδομένων MRI.
- Την ανάλυση και σύγκριση διαφορετικών διαγνωστικών σεναρίων όπως δυαδικών, πολυκατηγορικών και ιεραρχικών προσεγγίσεων.
- Την αξιοποίηση τεχνικών συνδυασμού πληροφορίας (data fusion) για την ενίσχυση της διακριτικής ικανότητας των μοντέλων και την αποδοτικότερη εκμετάλλευση συμπληρωματικών χαρακτηριστικών.
- Την τεκμηριωμένη αξιολόγηση των προτεινόμενων προσεγγίσεων με βάση καθιερωμένες πειραματικές μετρικές.

Συνολικά, η παρούσα εργασία εξετάζει τη συμβολή των μεθόδων βαθιάς μάθησης στη βελτίωση της αξιοπιστίας και της αντικειμενικότητας της διαγνωστικής διαδικασίας.

Κεφάλαιο 2. Ανασκόπηση Βιβλιογραφίας

Το παρόν κεφάλαιο αποτυπώνει τη σύγχρονη ερευνητική εικόνα σχετικά με την ταξινόμηση δεδομένων MRI εγκεφάλου για τη διάγνωση της άνοιας, αναδεικνύοντας τις κυρίαρχες τεχνικές βαθιάς μάθησης, τις στρατηγικές αξιολόγησης και τα ζητήματα που σχετίζονται με τη διαχείριση δεδομένων. Η ανάλυση αυτή λειτουργεί ως βάση για την κατανόηση της μεθοδολογίας που ακολουθείται στην παρούσα εργασία.

2.1 Πειραματικός Σχεδιασμός και Διαχείριση Δεδομένων στην Ταξινόμηση MRI

Η εγκυρότητα των αποτελεσμάτων στην ταξινόμηση μαγνητικών τομογραφιών εγκεφάλου εξαρτάται σε μεγάλο βαθμό από τον πειραματικό σχεδιασμό και τη σωστή διαχείριση των δεδομένων. Η βιβλιογραφία έχει αναδείξει επανειλημμένα ότι η ελλιπής ή λανθασμένη πειραματική πρακτική μπορεί να οδηγήσει σε υπερεκτίμηση της γενικευσιμότητας των προτεινόμενων μοντέλων (Bradshaw et al., 2023). Συνεπώς, καταδεικνύεται ότι η αξιολόγηση των μοντέλων δεν εξαρτάται αποκλειστικά από την αρχιτεκτονική που χρησιμοποιείται, αλλά και από τη μεθοδολογία που ακολουθείται στη διαδικασία εκπαίδευσης και επικύρωσης.

2.1.1 Διασταυρούμενη Επικύρωση στην Ιατρική Απεικόνιση

Η διασταυρούμενη επικύρωση (cross-validation) είναι μία από τις πλέον διαδεδομένες τεχνικές για την αξιολόγηση της ικανότητας γενίκευσης ενός μοντέλου σε νέα, άγνωστα δεδομένα, ιδίως σε περιβάλλοντα όπου τα διαθέσιμα δεδομένα είναι περιορισμένα. Στην περίπτωσης της ιατρικής απεικόνισης, η εφαρμογής της δεν είναι απλή διαδικασία και απαιτεί ιδιαίτερη μεθοδολογική προσοχή. Οι Bradshaw et al. (2023) επισημαίνουν ότι η λανθασμένη επιλογή σχήματος επικύρωσης ή η ελλιπής διασφάλιση της ανεξαρτησίας μεταξύ των υποσυνόλων (folds) μπορεί να οδηγήσει σε συστηματική υπερεκτίμηση της πραγματικής απόδοσης των μοντέλων.

Παράλληλα, οι Aslan & Özupak (2025) επισημαίνουν ότι όταν κάθε μελέτη εφαρμόζει διαφορετικό τρόπο διαχωρισμού των δεδομένων ή διαφορετικές διαδικασίες επικύρωσης, τα αποτελέσματα δεν είναι άμεσα συγκρίσιμα. Για τον λόγο αυτό, υπογραμμίζουν την ανάγκη υιοθέτησης σαφώς ορισμένων και συνεπών πειραματικών πρωτοκόλλων, ώστε η αποτίμηση της απόδοσης των μοντέλων να βασίζεται σε κοινά και αξιόπιστα κριτήρια.

2.1.2 Διαρροή Πληροφορίας (Data Leakage)

Η διαρροή πληροφορίας συνιστά μία από τις σημαντικότερες απειλές για την εγκυρότητα των αποτελεσμάτων. Το φαινόμενο αυτό προκύπτει όταν πληροφορία από το σύνολο αξιολόγησης επηρεάζει άμεσα ή έμμεσα τη διαδικασία εκπαίδευσης του μοντέλου, οδηγώντας σε μη ρεαλιστική εκτίμηση της απόδοσης και υπερεκτίμηση της ικανότητας γενίκευσης. Οι Rumala (2023) επισημαίνουν ότι σε σύνολα δεδομένων όπου περισσότερα από ένα απεικονιστικά δείγματα προέρχονται από τον ίδιο εξεταζόμενο, η μη ορθή εφαρμογή του διαχωρισμού συνόλου εκπαίδευσης (train)/ συνόλου ελέγχου (test) μπορεί να επιτρέψει στο μοντέλο να «αναγνωρίζει» χαρακτηριστικά που σχετίζονται με το ίδιο άτομο, αντί να μαθαίνει γενικεύσιμα παθολογικά πρότυπα. Το αποτέλεσμα είναι η τεχνητή αύξηση της ακρίβειας, χωρίς πραγματική δυνατότητα εφαρμογής του μοντέλου σε νέα, ανεξάρτητα δεδομένα. Συνεπώς, η αυστηρή διασφάλιση της ανεξαρτησίας μεταξύ των συνόλων εκπαίδευσης και αξιολόγησης αποτελεί βασική

προϋπόθεση για την αξιόπιστη αποτίμηση της απόδοσης μοντέλων στην ιατρική απεικόνιση.

2.1.3 Διαχωρισμός σε Επίπεδο Εξεταζόμενου Ατόμου

Ιδιαίτερη σημασία έχει ο διαχωρισμός των δεδομένων σε επίπεδο εξεταζόμενου. Η βιβλιογραφία υπογραμμίζει ότι η αυστηρή εφαρμογή subject – level διαχωρισμού αποτελεί βασική προυπόθεση για αξιόπιστη εκτίμηση της γενικευσιμότητας των μοντέλων στην ιατρική απεικόνιση (Bradshaw et al., 2023; Rumala, 2023). Στην περίπτωση όπου πολλαπλές τομές ή επαναλαμβανόμενες εξετάσεις του ίδιου ατόμου κατανέμονται σε διαφορετικά σύνολα (π.χ. train και test), παραβιάζεται η ανεξαρτησία των δεδομένων και εισάγεται έμμεση συσχέτιση μεταξύ εκπαίδευσης και αξιολόγησης.

2.2 Δομικές Ιδιαιτερότητες και Κατανομή Δειγμάτων σε Σύνολα Δεδομένων MRI

Η απόδοση μοντέλων ταξινόμησης σε δεδομένα MRI δεν καθορίζεται μόνο από το συνολικό μέγεθος του συνόλου δεδομένων (dataset), αλλά και από τη δομή και την κατανομή των διαθέσιμων δειγμάτων. Οι Aslan & Özupak (2025) επισημαίνουν ότι η εσωτερική οργάνωση ενός συνόλου δεδομένων—δηλαδή η κατανομή των παρατηρήσεων ανά κλάση και ανά εξεταζόμενο—επηρεάζει άμεσα τη σταθερότητα των πειραμάτων και τη δυνατότητα γενίκευσης των μοντέλων.

Ένα συχνό πρόβλημα είναι η ανισορροπία μεταξύ διαγνωστικών κατηγοριών (class imbalance), όπου ορισμένες κλάσεις εμφανίζονται πολύ συχνότερα από άλλες. Οι Aslan & Özupak (2025) τονίζουν ότι σε τέτοιες συνθήκες τα μοντέλα τείνουν να ευνοούν την πλειοψηφική κλάση, γεγονός που μπορεί να οδηγήσει σε παραπλανητική εικόνα επίδοσης, ιδιαίτερα όταν δεν χρησιμοποιούνται κατάλληλες μετρικές και διαδικασίες αξιολόγησης.

Παράλληλα, συναντάται και δομική ανισορροπία ως προς τα δείγματα ανά εξεταζόμενο, όταν ορισμένα άτομα συνεισφέρουν σημαντικά περισσότερες τομές/αρχεία σε σχέση με άλλα. Η ιδιαιτερότητα αυτή μπορεί να μεταβάλει τη στατιστική κατανομή των δεδομένων και να προκαλέσει έμμεση μεροληψία κατά την εκπαίδευση, καθώς το μοντέλο «βλέπει» συχνότερα συγκεκριμένα μορφολογικά μοτίβα. Σε μικρά ή ετερογενή σύνολα δεδομένων, η επίδραση αυτής της ανισορροπίας γίνεται ακόμη πιο έντονη, ενισχύοντας την ανάγκη τεκμηρίωσης της κατανομής των δειγμάτων στο σύνολο δεδομένων (dataset).

Συνολικά, η βιβλιογραφία συγκλίνει στο ότι η ανάλυση της δομής του συνόλου δεδομένων (dataset), τόσο ως προς τις κλάσεις όσο και ως προς τη συνεισφορά ανά εξεταζόμενο, αποτελεί απαραίτητη προϋπόθεση για ορθή ερμηνεία των αποτελεσμάτων στην ταξινόμηση MRI για την άνοια.

2.3 Προεπεξεργασία Δεδομένων MRI για Μοντέλα Μηχανικής και Βαθιάς Μάθησης

Η προεπεξεργασία των απεικονιστικών δεδομένων MRI αποτελεί κρίσιμο στάδιο πριν από την εκπαίδευση υπολογιστικών μοντέλων, καθώς επηρεάζει άμεσα την ποιότητα των χαρακτηριστικών που θα εξαχθούν και τη σταθερότητα της εκπαίδευσης. Σε αντίθεση με ζητήματα πειραματικού σχεδιασμού ή διαχωρισμού δεδομένων, η

προεπεξεργασία αφορά τις ίδιες απεικονιστικές εισόδους και τον τρόπο με τον οποίο αυτές μετασχηματίζονται σε κατάλληλη μορφή για ανάλυση.

2.3.1 Ομογενοποίηση και Τυποποίηση Εισόδων

Τα δεδομένα MRI προέρχονται συχνά από διαφορετικά κέντρα λήψης, με διαφορετικές ρυθμίσεις σαρωτών και πρωτόκολλα απεικόνισης. Η ετερογένεια αυτή μπορεί να οδηγήσει σε διακυμάνσεις στην ένταση σήματος και στη γεωμετρική αναπαράσταση των όγκων.

Οι Ostellino κ.ά. (2022) παρουσιάζουν μία συνεπή ροή προεπεξεργασίας για MRI εγκεφάλου με στόχο τη δημιουργία συγκρίσιμων εισόδων για βαθιά μάθηση (deep learning), επισημαίνοντας ότι η ομογενοποίηση (normalization, resampling, spatial alignment) αποτελεί απαραίτητη προϋπόθεση για τη σταθερή εκπαίδευση μοντέλων. Οι συγγραφείς τονίζουν ότι ακόμη και μικρές αποκλίσεις στα πρωτόκολλα λήψης μπορούν να επηρεάσουν σημαντικά τα εξαγόμενα χαρακτηριστικά.

Στο ίδιο πλαίσιο, η επαναδειγματοληψία (resampling) σε κοινή ανάλυση συμβάλλει στη μείωση της διακύμανσης που δεν σχετίζεται με παθολογικά πρότυπα, αλλά με τεχνικές παραμέτρους της απεικόνισης.

2.3.2 Αφαίρεση Μη Εγκεφαλικού Ιστού και Καθαρισμός Θορύβου

Ένα βασικό στάδιο προεπεξεργασίας στα δεδομένα MRI είναι η απομάκρυνση μη εγκεφαλικού ιστού (skull stripping), ώστε η ανάλυση να περιορίζεται αποκλειστικά στις εγκεφαλικές δομές. Η παρουσία κρανιακών η εξωεγκεφαλικών περιοχών μπορεί να εισάγει μη σχετική πληροφορία και να επηρεάσει τη διαδικασία εκμάθησης, ιδίως όταν τα μοντέλα επιχειρούν να εντοπίσουν λεπτές μορφολογικές μεταβολές. Οι Ostellino κ.ά. (2022) τονίζουν ότι η δημιουργία συγκρίσιμων και ομογενοποιημένων εισόδων αποτελεί κρίσιμη προϋπόθεση για τη σταθερότητα των αποτελεσμάτων σε ετερογενή σύνολα δεδομένων MRI.

Πέρα από τη χωρική απομόνωση του εγκεφάλου, σημαντικό ρόλο διαδραματίζει και η αντιμετώπιση προβλημάτων ποιότητας, όπως artifacts κίνησης (motion artifacts), ασυνέπειες μεταξύ τομών ή διαφοροποιήσεις στα πρωτόκολλα λήψης. Οι Young κ.ά. προτείνουν μία μέθοδο πλήρως συνελικτικής ανακατασκευής από τομές σε όγκο (fully convolutional slice-to-volume reconstruction) για περιπτώσεις όπου η κίνηση αλλοιώνει τις λήψεις, δείχνοντας ότι η υπολογιστική αποκατάσταση μπορεί να βελτιώσει τη μορφολογική συνοχή και την αξιοπιστία των τρισδιάστατων όγκων πριν την περαιτέρω ανάλυση.

Η σημασία της ποιοτικής προεπεξεργασίας αναδεικνύεται και σε μελέτες που αξιοποιούν προεκπαιδευμένα τρισδιάστατα μοντέλα (Chen et al., 2019), όπου επισημαίνεται ότι η μεταφορά γνώσης (transfer learning) προϋποθέτει συνεπείς και επαρκώς κανονικοποιημένες εισόδους. Ακόμη και μικρές διαφοροποιήσεις στη χωρική ευθυγράμμιση ή στην ένταση των ογκοστοιχείων (voxel) μπορεί να επηρεάσουν την ικανότητα του μοντέλου να γενικεύει σε νέα δεδομένα.

Συνολικά, η βιβλιογραφία συγκλίνει στο ότι η προεπεξεργασία των ογκομετρικών (volumetric) δεδομένων δεν αποτελεί απλώς ένα τεχνικό προπαρασκευαστικό στάδιο, αλλά θεμελιώδη παράγοντα που επηρεάζει τη σταθερότητα, τη συγκρισιμότητα και τελικά την αξιοπιστία των αποτελεσμάτων σε μελέτες αυτόματης ταξινόμησης MRI.

2.3.3 Κανονικοποίηση Έντασης και Κλιμάκωση

Σε αντίθεση με φυσικές εικόνες RGB, τα MRI δεν έχουν απόλυτη κλίμακα έντασης. Η κανονικοποίηση έντασης (intensity normalization) είναι συνεπώς αναγκαία, ώστε το μοντέλο να μην επηρεάζεται από αυθαίρετες διακυμάνσεις σήματος μεταξύ εξετάσεων.

Οι Ostellino κ.ά. (2022) επισημαίνουν ότι η απουσία συνεπούς κανονικοποίησης μπορεί να οδηγήσει σε αστάθεια κατά την εκπαίδευση και σε μειωμένη γενικευσιμότητα, ιδιαίτερα όταν τα δεδομένα προέρχονται από πολλαπλές πηγές.

2.3.4 Μεταφορά Μάθησης και Συμβατότητα με Προεκπαιδευμένα Μοντέλα

Όταν χρησιμοποιούνται προεκπαιδευμένα τρισδιάστατα μοντέλα, όπως το Med3D, η προεπεξεργασία πρέπει να είναι συμβατή με τις συνθήκες υπό τις οποίες εκπαιδεύτηκε αρχικά το μοντέλο. Οι Chen κ.ά. (2019) τονίζουν ότι η επιτυχία της μεταφοράς μάθησης (transfer learning) σε 3D ιατρικά δεδομένα εξαρτάται σε μεγάλο βαθμό από τη μορφή των εισόδων, την κανονικοποίηση της έντασης και τη χωρική διάσταση των όγκων. Εάν τα νέα δεδομένα διαφέρουν σημαντικά ως προς την ανάλυση, την κλιμάκωση ή τη δομή τους σε σχέση με εκείνα που χρησιμοποιήθηκαν στην αρχική εκπαίδευση, η μεταφορά γνώσης ενδέχεται να μην είναι αποτελεσματική και η απόδοση του μοντέλου να υποβαθμιστεί.

2.4 Υπολογιστικές Προσεγγίσεις για Ταξινόμηση MRI στην Άνοια

Η εξέλιξη των υπολογιστικών μεθόδων για την αυτόματη ανάλυση δεδομένων MRI έχει ακολουθήσει μια σταδιακή μετάβαση από παραδοσιακές τεχνικές μηχανικής μάθησης σε βαθιά νευρωνικά δίκτυα και, πιο πρόσφατα, σε προεκπαιδευμένα τρισδιάστατα μοντέλα. Η επιλογή της υπολογιστικής προσέγγισης επηρεάζει σημαντικά τόσο την ακρίβεια όσο και τη δυνατότητα γενίκευσης των μοντέλων.

2.4.1 Παραδοσιακές Μέθοδοι Μηχανικής Μάθησης

Οι πρώιμες μελέτες ταξινόμησης MRI για τη διάγνωση της άνοιας βασίστηκαν σε χειροκίνητη ή ημιαυτόματη εξαγωγή χαρακτηριστικών, όπως μορφολογικοί δείκτες, όγκοι εγκεφαλικών περιοχών ή στατιστικά έντασης, και στη συνέχεια στην εφαρμογή αλγορίθμων μηχανικής μάθησης, όπως Support Vector Machines (SVM), Random Forests και k-Nearest Neighbors.

Οι Shen, Wu & Suk (2017) επισημαίνουν ότι τα μοντέλα αυτά εξαρτώνται σε μεγάλο βαθμό από την ποιότητα και τη διακριτική ικανότητα των επιλεγμένων χαρακτηριστικών, γεγονός που περιορίζει την ευελιξία τους σε ετερογενή δεδομένα. Παράλληλα, συγκριτικές μελέτες όπως των Aslan & Özupak (2025) αναδεικνύουν ότι η απόδοση των παραδοσιακών ταξινομητών επηρεάζεται σημαντικά από την επιλογή χαρακτηριστικών και από το πειραματικό πρωτόκολλο που ακολουθείται.

Παρότι οι μέθοδοι αυτές προσφέρουν ερμηνευσιμότητα και χαμηλότερο υπολογιστικό κόστος, συχνά αδυνατούν να συλλάβουν πολύπλοκα χωρικά πρότυπα που σχετίζονται με νευροεκφυλιστικές μεταβολές.

2.4.2 Βαθιά Μάθηση σε 2D Απεικονίσεις MRI

Με την ευρεία διάδοση των Convolutional Neural Networks (CNN), αρκετές μελέτες υιοθέτησαν 2D προσεγγίσεις, όπου μεμονωμένες τομές (slices) MRI χρησιμοποιούνται ως είσοδοι σε δίκτυα εικόνας.

Στη βιβλιογραφία τονίζεται ότι η 2D προσέγγιση επιτρέπει την αξιοποίηση καθιερωμένων αρχιτεκτονικών και προεκπαιδευμένων μοντέλων από τον χώρο της υπολογιστικής όρασης, μειώνοντας τις απαιτήσεις σε δεδομένα (Shen et al., 2017). Ωστόσο, επισημαίνεται ότι η ανάλυση σε επίπεδο τομής ενδέχεται να αγνοεί τη συνολική χωρική συνοχή του εγκεφάλου, καθώς η πληροφορία μεταξύ διαδοχικών τομών δεν μοντελοποιείται άμεσα.

Στη βιβλιογραφία υπογραμμίζεται ότι, παρότι οι 2D CNN παρουσιάζουν ικανοποιητικά αποτελέσματα, ενδέχεται να μην αποτυπώνουν πλήρως τις τρισδιάστατες μορφολογικές μεταβολές που χαρακτηρίζουν την άνοια.

2.4.3 Τρισδιάστατα Δίκτυα Βαθιάς Μάθησης (3D CNNs)

Η μετάβαση σε 3D CNN επέτρεψε την άμεση επεξεργασία ολόκληρων ογκομετρικών (volumetric) MRI δεδομένων, διατηρώντας τη χωρική πληροφορία και στις τρεις διαστάσεις.

Οι Chen et al. (2019), στο πλαίσιο του Med3D, υποστηρίζουν ότι τα 3D δίκτυα είναι περισσότερο κατάλληλα για ιατρικές απεικονίσεις, καθώς μαθαίνουν χωρικά πρότυπα σε επίπεδο όγκου και όχι μεμονωμένης τομής. Παρόμοια, οι Isensee et al. (2021) επισημαίνουν ότι οι 3D αρχιτεκτονικές παρουσιάζουν βελτιωμένη απόδοση σε καθήκοντα ιατρικής ανάλυσης, ιδίως όταν η παθολογία εκτείνεται σε ευρύτερες εγκεφαλικές περιοχές.

Ωστόσο, οι συγγραφείς αναγνωρίζουν ότι τα 3D μοντέλα συνοδεύονται από αυξημένες υπολογιστικές απαιτήσεις και μεγαλύτερη ανάγκη για δεδομένα, γεγονός που καθιστά τη σωστή διαχείριση του συνόλου δεδομένων (dataset) ιδιαίτερα κρίσιμη.

2.4.4 Προεκπαιδευμένα 3D Μοντέλα και Transfer Learning

Η εκπαίδευση τρισδιάστατων νευρωνικών δικτύων από μηδενική αρχικοποίηση (training from scratch) απαιτεί μεγάλο όγκο δεδομένων και σημαντικούς υπολογιστικούς πόρους, προϋποθέσεις που σπάνια ικανοποιούνται στην έρευνα της άνοιας. Για τον λόγο αυτό, η βιβλιογραφία έχει στραφεί στη χρήση προεκπαιδευμένων 3D μοντέλων και τεχνικών μεταφοράς μάθησης (transfer learning), με στόχο την αξιοποίηση γνώσης που έχει ήδη αποκτηθεί από μεγάλα ιατρικά σύνολα δεδομένων.

Οι Chen et al. (2019) προτείνουν την προεκπαίδευση 3D CNN σε εκτεταμένα ιατρικά σύνολα δεδομένων (datasets) διαφορετικών οργάνων, υποστηρίζοντας ότι τα μοντέλα αυτά μαθαίνουν γενικεύσιμες χωρικές αναπαραστάσεις οι οποίες μπορούν να προσαρμοστούν αποτελεσματικά σε νέα καθήκοντα. Σύμφωνα με τους συγγραφείς, η αρχική αυτή εκπαίδευση λειτουργεί ως ισχυρό σημείο εκκίνησης, μειώνοντας την ανάγκη για μεγάλο αριθμό επισημασμένων δειγμάτων στο τελικό πρόβλημα ταξινόμησης.

Παράλληλα, προσεγγίσεις αυτοεπιβλεπόμενης προεκπαίδευσης, όπως το ModelGenesis (Zhou et al.), δείχνουν ότι ακόμη και χωρίς πλήρη επισημείωση, τα 3D δίκτυα μπορούν να μάθουν σταθερές δομικές αναπαραστάσεις του ανθρώπινου σώματος.

Οι αναπαραστάσεις αυτές μεταφέρονται στη συνέχεια σε ειδικότερα κλινικά καθήκοντα, βελτιώνοντας τη σύγκλιση και τη σταθερότητα της εκπαίδευσης.

Συνολικά, η χρήση προεκπαιδευμένων 3D μοντέλων σε συνδυασμό με μεταφορά μάθησης (transfer learning) αποτελεί στρατηγική επιλογή σε περιβάλλοντα περιορισμένων δεδομένων, καθώς επιτρέπει την αξιοποίηση προϋπάρχουσας χωρικής

γνώσης και συμβάλλει στη βελτίωση της απόδοσης χωρίς την ανάγκη εκτεταμένης εκπαίδευσης από την αρχή.

2.5 Σύνθετες Στρατηγικές Ταξινόμησης

Η αυξανόμενη πολυπλοκότητα των προβλημάτων ταξινόμησης στην ιατρική απεικόνιση έχει οδηγήσει τη βιβλιογραφία πέρα από τις μεμονωμένες αρχιτεκτονικές, προς πιο σύνθετες στρατηγικές συνδυασμού και ιεραρχικής οργάνωσης των μοντέλων. Οι προσεγγίσεις αυτές στοχεύουν στη βελτίωση της σταθερότητας, της διακριτικής ικανότητας και της γενικευσιμότητας των συστημάτων ταξινόμησης.

2.5.1 Ensemble Μέθοδοι στην Ταξινόμηση MRI

Οι ensemble τεχνικές βασίζονται στη συνδυαστική αξιοποίηση πολλαπλών μοντέλων, με στόχο τη μείωση της διακύμανσης και τη βελτίωση της συνολικής απόδοσης. Στη βιβλιογραφία της ιατρικής απεικόνισης έχουν χρησιμοποιηθεί στρατηγικές όπως majority voting, weighted averaging, bagging και boosting.

Οι Aslan & Özupak (2025), σε συγκριτική μελέτη αλγορίθμων για πρόβλεψη της νόσου Alzheimer, επισημαίνουν ότι η συνδυαστική αξιοποίηση διαφορετικών ταξινομητών μπορεί να οδηγήσει σε πιο σταθερά αποτελέσματα σε σχέση με μεμονωμένα μοντέλα, ιδίως όταν το σύνολο δεδομένων (dataset) παρουσιάζει ανισορροπία κλάσεων. Οι συγγραφείς τονίζουν ότι η διαφοροποίηση μεταξύ των επιμέρους μοντέλων αποτελεί βασική προϋπόθεση για την αποτελεσματικότητα ενός ensemble σχήματος.

Παράλληλα, σε βαθιά νευρωνικά δίκτυα έχουν προταθεί προσεγγίσεις συνδυασμού διαφορετικών αναπαραστάσεων ή αρχιτεκτονικών. Οι Chen et al. (2019) δείχνουν ότι διαφορετικά επίπεδα χαρακτηριστικών σε 3D CNN μπορούν να αποτυπώνουν συμπληρωματικές χωρικές πληροφορίες, ενώ οι (Zhou et al., 2021) επισημαίνουν ότι η αξιοποίηση διαφορετικών προεκπαιδευμένων αναπαραστάσεων μπορεί να ενισχύσει τη σταθερότητα και τη σύγκλιση σε επακόλουθες εργασίες. Τα ευρήματα αυτά υποστηρίζουν ότι ο συνδυασμός συμπληρωματικών μοντέλων ή χαρακτηριστικών μπορεί να βελτιώσει τη γενικευσιμότητα, ιδιαίτερα σε περιβάλλοντα περιορισμένων και ετερογενών δεδομένων.

2.5.2 Ιεραρχική Ταξινόμηση (Hierarchical Classification)

Σε αντίθεση με τις επίπεδες (flat) πολυκατηγορικές προσεγγίσεις, η ιεραρχική ταξινόμηση οργανώνει το πρόβλημα σε διαδοχικά στάδια, ξεκινώντας από μια γενική διάκριση και προχωρώντας σε πιο εξειδικευμένη κατηγοριοποίηση των περιπτώσεων. Στο πλαίσιο της άνοιας, αυτό μπορεί να μεταφραστεί σε αρχική διάκριση μεταξύ υγιών και παθολογικών περιπτώσεων και στη συνέχεια σε λεπτομερέστερη κατηγοριοποίηση του βαθμού ή του τύπου της νόσου.

Η βιβλιογραφία επισημαίνει ότι η ιεραρχική οργάνωση μπορεί να μειώσει τη σύγχυση μεταξύ παρόμοιων κλάσεων, καθώς κάθε στάδιο επικεντρώνεται σε υποσύνολο του προβλήματος. Σε ιατρικά σενάρια, η στρατηγική αυτή θεωρείται συμβατή με τη διαγνωστική λογική, όπου η διαδικασία συχνά ακολουθεί διαδοχικά επίπεδα αξιολόγησης.

Οι Shen, Wu & Suk (2017) αναφέρουν ότι η σταδιακή διάκριση μεταξύ κατηγοριών μπορεί να βελτιώσει τη μάθηση λεπτών μορφολογικών διαφορών, ενώ συγκριτικές μελέτες επισημαίνουν ότι η κατάλληλη αποσύνθεση ενός σύνθετου προβλήματος

ταξινόμησης μπορεί να οδηγήσει σε καλύτερη ισορροπία μεταξύ ευαισθησίας και ειδικότητας.

Συνολικά, τόσο οι ensemble όσο και οι ιεραρχικές προσεγγίσεις αντανακλούν τη γενικότερη τάση της βιβλιογραφίας προς πιο σύνθετες και δομημένες στρατηγικές μάθησης, οι οποίες επιχειρούν να υπερβούν τους περιορισμούς μεμονωμένων μοντέλων σε περιβάλλοντα περιορισμένων και ετερογενών δεδομένων.

2.6 Συνένωση Πληροφορίας (Data Fusion) στην Ανάλυση MRI

Η αυξανόμενη πολυπλοκότητα των δεδομένων ιατρικής απεικόνισης έχει οδηγήσει τη βιβλιογραφία στην υιοθέτηση τεχνικών συνδυασμού πληροφορίας (data fusion), με στόχο την αξιοποίηση συμπληρωματικών αναπαραστάσεων και τη βελτίωση της διακριτικής ικανότητας των μοντέλων. Σε αντίθεση με τις ensemble στρατηγικές, όπου ο συνδυασμός πραγματοποιείται στο επίπεδο των τελικών προβλέψεων, η συνένωση πληροφοριών (data fusion) εστιάζει στην ενοποίηση διαφορετικών πηγών πληροφορίας ή αναπαραστάσεων πριν ή κατά τη διαδικασία μάθησης, επιδιώκοντας πιο ολοκληρωμένη μοντελοποίηση του προβλήματος.

Στην έρευνα της άνοιας, έχουν προταθεί προσεγγίσεις που συνδυάζουν δομικά MRI με άλλες μορφές δεδομένων, όπως λειτουργικές απεικονίσεις, κλινικούς δείκτες ή δημογραφικά χαρακτηριστικά (Shen, Wu & Suk, 2017). Οι συγγραφείς επισημαίνουν ότι η ενσωμάτωση πολλαπλών τύπων πληροφορίας μπορεί να οδηγήσει σε πιο ολοκληρωμένη αναπαράσταση της παθολογίας και συνεπώς σε βελτιωμένη ταξινόμηση.

Η βιβλιογραφία διακρίνει συνήθως τρία βασικά επίπεδα συνδυασμού:

- **Feature-level fusion**, όπου τα χαρακτηριστικά από διαφορετικές πηγές ενοποιούνται πριν την ταξινόμηση.
- **Decision-level fusion**, όπου οι προβλέψεις διαφορετικών μοντέλων συνδυάζονται στο τελικό στάδιο.
- **Representation-level fusion**, ιδιαίτερα σε βαθιά δίκτυα, όπου συνδυάζονται εσωτερικές αναπαραστάσεις από διαφορετικές αρχιτεκτονικές ή επίπεδα του ίδιου δικτύου.

Οι (Zhou et al., 2021)επισημαίνουν ότι διαφορετικές αναπαραστάσεις μπορούν να κωδικοποιούν συμπληρωματικά δομικά πρότυπα, γεγονός που καθιστά ελκυστική τη συνδυαστική αξιοποίησή τους στο ίδιο σύστημα ταξινόμησης. Αντίστοιχα, οι Chen et al. (2019) αναφέρουν ότι τα 3D δίκτυα παράγουν πολυεπίπεδες χωρικές αναπαραστάσεις, οι οποίες μπορούν να συνδυαστούν για ενίσχυση της διακριτικής ικανότητας.

Ιδιαίτερα σε περιβάλλοντα με περιορισμένο αριθμό δειγμάτων ή με ετερογενή χαρακτηριστικά, ο συνδυασμός πολλαπλών αναπαραστάσεων έχει προταθεί ως τρόπος ενίσχυσης της σταθερότητας και της ανθεκτικότητας των προβλέψεων, μειώνοντας την εξάρτηση από μία μόνο πηγή πληροφορίας.

Συνεπώς, η συνένωση πληροφοριών (data fusion) δεν περιορίζεται σε τεχνική βελτιστοποίησης, αλλά συνιστά στρατηγική αξιοποίησης συμπληρωματικής γνώσης, με στόχο τη δημιουργία πιο ολοκληρωμένων και ανθεκτικών συστημάτων ταξινόμησης MRI στην έρευνα της άνοιας.

2.7 Μετρικές Αξιολόγησης σε Ανισόρροπα Ιατρικά Δεδομένα

Η αξιολόγηση μοντέλων ταξινόμησης στην ιατρική απεικόνιση αποτελεί κρίσιμο στάδιο, καθώς η επιλογή των κατάλληλων μετρικών επηρεάζει ουσιαστικά την ερμηνεία της απόδοσης. Η βιβλιογραφία επισημαίνει ότι η απλή αναφορά της ακρίβειας (accuracy) δεν επαρκεί σε περιβάλλοντα όπου παρατηρείται ανισορροπία μεταξύ των κλάσεων, όπως συμβαίνει συχνά στα σύνολα δεδομένων (datasets) άνοιας.

Οι Aslan & Özupak (2025) υπογραμμίζουν ότι σε προβλήματα όπου μία κατηγορία υπερτερεί αριθμητικά, η ακρίβεια (accuracy) μπορεί να οδηγήσει σε παραπλανητικά συμπεράσματα, καθώς ένα μοντέλο που προβλέπει κυρίως την πλειοψηφική κλάση μπορεί να εμφανίζει υψηλή τιμή χωρίς ουσιαστική διαγνωστική αξία. Για τον λόγο αυτό, προτείνεται η χρήση μετρικών που λαμβάνουν υπόψη τόσο την ευαισθησία όσο και την ειδικότητα.

Στη βιβλιογραφία χρησιμοποιούνται ευρέως οι δείκτες:

- **Precision**, που αποτυπώνει την αναλογία των σωστά θετικών προβλέψεων,
- **Recall (Sensitivity)**, που εκφράζει την ικανότητα ανίχνευσης των πραγματικά θετικών περιπτώσεων,
- **F1-score**, που συνδυάζει precision και recall σε έναν ενιαίο δείκτη.

Ιδιαίτερη έμφαση δίνεται στο macro-averaged F1-score, το οποίο υπολογίζει τη μέση τιμή του F1 σε όλες τις κλάσεις χωρίς να εξαρτάται από το μέγεθός τους. Η προσέγγιση αυτή θεωρείται κατάλληλη σε ανισόρροπα δεδομένα, καθώς αντιμετωπίζει όλες τις κατηγορίες ισότιμα. Αντίθετα, οι σταθμισμένες (weighted) εκδοχές μπορεί να επηρεάζονται δυσανάλογα από την πλειοψηφική κλάση.

Οι Bradshaw et al. (2023) επισημαίνουν ότι η πλήρης αναφορά πολλαπλών μετρικών είναι απαραίτητη για την αξιόπιστη αποτίμηση της ικανότητας γενίκευσης ενός μοντέλου στην ιατρική απεικόνιση. Οι συγγραφείς τονίζουν ότι η αξιολόγηση πρέπει να αντικατοπτρίζει τη διαγνωστική σημασία του προβλήματος και όχι μόνο τη συνολική αριθμητική επίδοση.

Επιπλέον, σε δυαδικά προβλήματα ταξινόμησης χρησιμοποιείται συχνά η καμπύλη ROC και ο δείκτης AUC (Area Under the Curve), ο οποίος αποτυπώνει τη συμπεριφορά του μοντέλου σε διαφορετικά κατώφλια απόφασης. Η βιβλιογραφία υποστηρίζει ότι ο δείκτης AUC παρέχει πιο ολοκληρωμένη εικόνα της διακριτικής ικανότητας, ιδίως όταν το κόστος ψευδώς θετικών και ψευδώς αρνητικών προβλέψεων διαφέρει.

Συνολικά, η επιλογή μετρικών αξιολόγησης στην ταξινόμηση MRI για τη διάγνωση της άνοιας δεν αποτελεί απλή τεχνική απόφαση, αλλά συνδέεται άμεσα με την κλινική σημασία των αποτελεσμάτων. Η χρήση δεικτών όπως το macro F1-score και ο AUC αντανακλά τη γενικότερη τάση της βιβλιογραφίας προς πιο ισορροπημένη και ουσιαστική αποτίμηση της απόδοσης των μοντέλων.

2.8 Σύνοψη Κεφαλαίου

Από την ανασκόπηση της σχετικής βιβλιογραφίας προκύπτουν ορισμένα σταθερά και επαναλαμβανόμενα συμπεράσματα. Πρώτον, η μεθοδολογικά αυστηρή διαχείριση του συνόλου δεδομένων και ο συνεπής πειραματικός σχεδιασμός αναδεικνύονται ως καθοριστικοί παράγοντες για την αξιοπιστία και τη συγκρισιμότητα των αποτελεσμάτων.

Δεύτερον, η αξιοποίηση τρισδιάστατων αρχιτεκτονικών και προεκπαιδευμένων μοντέλων με τεχνικές μεταφοράς μάθησης προτείνεται ως ιδιαίτερα αποτελεσματική στρατηγική σε περιβάλλοντα περιορισμένων και ετερογενών δεδομένων MRI.

Τρίτον, ζητήματα όπως η δομική ανισορροπία των συνόλων δεδομένων (datasets), η ανισορροπία κλάσεων, καθώς και οι στρατηγικές συνδυασμού πληροφορίας και ιεραρχικής οργάνωσης της ταξινόμησης αναγνωρίζονται ως κρίσιμα πεδία βελτιστοποίησης για την ενίσχυση της σταθερότητας και της διακριτικής ικανότητας των μοντέλων.

Οι παραπάνω διαπιστώσεις δεν αποτελούν απλώς θεωρητικές παρατηρήσεις, αλλά λειτουργούν ως βασικοί άξονες σχεδιασμού της μεθοδολογίας και των πειραματικών επιλογών της παρούσας εργασίας, όπως αναλύεται στα επόμενα κεφάλαια.

Κεφάλαιο 3. Θεωρητικό Υπόβαθρο

3.1 Μαγνητική Τομογραφία Εγκεφάλου και Τρισδιάστατη Αναπαράσταση MRI Δεδομένων

Η Μαγνητική Τομογραφία (Magnetic Resonance Imaging – MRI) αποτελεί μη επεμβατική απεικονιστική τεχνική που βασίζεται στις μαγνητικές ιδιότητες των πυρήνων υδρογόνου στους βιολογικούς ιστούς. Μέσω της εφαρμογής ισχυρού μαγνητικού πεδίου και ραδιοσυχνοτήτων, επιτυγχάνεται η παραγωγή εικόνων υψηλής χωρικής ανάλυσης χωρίς τη χρήση ιονίζουσας ακτινοβολίας.

Στη μελέτη νευροεκφυλιστικών διαταραχών, όπως η άνοια, η MRI χρησιμοποιείται ευρέως για την αποτύπωση μορφολογικών μεταβολών στον εγκέφαλο, όπως ατροφία φλοιού ή διεύρυνση κοιλιών(Livingston et al., 2020).

3.1.1 T1- Weighted MRI και Δομική Απεικόνιση

Τη βασική μορφή απεικόνισης που χρησιμοποιείται στη δομική ανάλυση του εγκεφάλου αποτελεί η T1-weighted MRI. Ο όρος T1 αναφέρεται στον χρόνο διαμήκους χαλάρωσης των πρωτονίων όταν αυτά βρίσκονται μέσα σε ισχυρό μαγνητικό πεδίο.
Σε μια T1-weighted ακολουθία, η αντίθεση της εικόνας ρυθμίζεται έτσι ώστε να εξαρτάται κυρίως από αυτόν τον χρόνο χαλάρωσης. Επειδή διαφορετικοί ιστοί παρουσιάζουν διαφορετικούς χρόνους T1, απεικονίζονται με διαφορετική φωτεινότητα. Το αποτέλεσμα είναι εικόνες με υψηλή μορφολογική ευκρίνεια και καθαρό διαχωρισμό ανατομικών δομών.
Για τον λόγο αυτό, οι T1-weighted εικόνες χρησιμοποιούνται εκτενώς στη μελέτη νευροεκφυλιστικών παθήσεων, καθώς επιτρέπουν την ανάλυση μορφολογικών μεταβολών, την εκτίμηση εγκεφαλικής ατροφίας και τη μέτρηση όγκων περιοχών όπως ο ιππόκαμπος και ο εγκεφαλικός φλοιός (Jack et al., 2010). Σχεδόν το σύνολο των μελετών που εστιάζουν στη δομική διερεύνηση της άνοιας βασίζεται σε T1-weighted MRI δεδομένα. Η υψηλή αντίθεση μεταξύ ιστών επιτρέπει την καθαρή αποτύπωση μορφολογικών διαφορών, γεγονός που τις καθιστά κατάλληλες για ανάλυση μέσω υπολογιστικών μοντέλων. Οι T1 MRI αποκτώνται συνήθως ως τρισδιάστατοι όγκοι (3D volumes), όπου ολόκληρος ο εγκέφαλος απεικονίζεται σε μορφή διαδοχικών τομών(Chen et al., 2019).

3.1.2 Τρισδιάστατη Αναπαράσταση Ιατρικών Εικόνων

Σε αντίθεση με τις φυσικές εικόνες 2D, τα δεδομένα MRI οργανώνονται ως τρισδιάστατοι όγκοι (volumes), οι οποίοι αποτελούνται από:

- Τρεις χωρικές διαστάσεις (x, y, z)
- Στοιχεία όγκου που ονομάζονται **voxels** (volume elements)

Κάθε voxel αντιστοιχεί σε μία μικρή τρισδιάστατη μονάδα ιστού και περιέχει τιμή έντασης που σχετίζεται με τις φυσικές ιδιότητες του ιστού.

Η ανάλυση ενός MRI volume δεν αφορά μεμονωμένες εικόνες, αλλά ολόκληρη τη χωρική δομή του εγκεφάλου. Για τον λόγο αυτό, τα δεδομένα μπορούν να θεωρηθούν ως τρισδιάστατοι αριθμητικοί πίνακες:

$$Z \times H \times W$$

όπου:

- Z = αριθμός τομών
- H = ύψος εικόνας
- W = πλάτος εικόνας

Η τρισδιάστατη αναπαράσταση διατηρεί τη χωρική συνοχή μεταξύ διαδοχικών τομών, στοιχείο ιδιαίτερα σημαντικό για τη μελέτη εκτεταμένων παθολογικών μεταβολών(Chen et al., 2019).

Ωστόσο, τα MRI δεδομένα που προκύπτουν από κλινικά πρωτόκολλα παρουσιάζουν μεταβλητότητα ως προς την ένταση σήματος, τον αριθμό τομών και τις χωρικές διαστάσεις. Η μεταβλητότητα αυτή καθιστά αναγκαία την εφαρμογή διαδικασιών ομογενοποίησης και κανονικοποίησης πριν από την αξιοποίησή τους σε υπολογιστικά μοντέλα μηχανικής μάθησης. Οι θεωρητικές αρχές των διαδικασιών αυτών παρουσιάζονται στην επόμενη ενότητα.

3.2 Προεπεξεργασία Τρισδιάστατων MRI Δεδομένων

Τα δεδομένα T1-weighted MRI που περιγράφηκαν στην προηγούμενη ενότητα αποτελούν τρισδιάστατους όγκους έντασης, οι οποίοι ενσωματώνουν μορφολογική πληροφορία για ολόκληρο τον εγκέφαλο. Παρότι η δομική απεικόνιση παρέχει υψηλή χωρική ανάλυση, τα ακατέργαστα δεδομένα παρουσιάζουν ιδιότητες που ενδέχεται να επηρεάσουν τη σταθερότητα και την αποδοτικότητα των υπολογιστικών μοντέλων.

Η προεπεξεργασία αποσκοπεί:

- στην απομόνωση του εγκεφαλικού ιστού,
- στη διόρθωση ανομοιογενειών έντασης,
- στη σταθεροποίηση της αριθμητικής κλίμακας,
- στην ενοποίηση της χωρικής αναπαράστασης.

Στις ακόλουθες υποενότητες παρουσιάζονται οι θεωρητικές αρχές των επιμέρους σταδίων.

3.2.1 Skull Stripping και Brain Masking

Η παρουσία μη εγκεφαλικού ιστού (κρανίο, δέρμα, υπόστρωμα) εισάγει μη σχετική πληροφορία. Στόχος του skull stripping είναι ο υπολογισμός μιας δυαδικής μάσκας:

$$M(x, y, z) \in \{0,1\}$$

ώστε:

$$M(x, y, z) = \begin{cases} 1, & \text{αν voxel ανήκει στον εγκέφαλο} \\ 0, & \text{διαφορετικά} \end{cases}$$

Η διαδικασία αυτή περιορίζει τους επόμενους υπολογισμούς αποκλειστικά στον εγκεφαλικό όγκο(Smith, 2002).

❖ Otsu Thresholding

Η αρχική εκτίμηση μάσκας βασίζεται στη μέθοδο Otsu, η οποία επιλέγει κατώφλι T που μεγιστοποιεί τη μεταξύ-κλάσεων διασπορά (Otsu, 1979):

$$\sigma_B^2(T) = \omega_1(T)\omega_2(T)[\mu_1(T) - \mu_2(T)]^2$$

όπου:

- ω_i= πιθανότητα κλάσης,
- μ_i= μέση ένταση κλάσης.

Το κατώφλι επιλέγεται ως:

$$T^* = \arg\max_T \sigma_B^2(T)$$

Η αρχική μάσκα ορίζεται ως:

$$M_0(x,y,z) = \mathbb{1}\{I(x,y,z) > T^*\}$$

❖ Μορφολογικές Πράξεις

Η αρχική δυαδική μάσκα μπορεί να περιέχει θόρυβο ή μικρές ασυνέχειες. Για τη βελτίωσή της εφαρμόζονται μορφολογικές πράξεις με δομικό στοιχείο B:

Binary Closing (γεμίζει κενά):

$$M' = (M_0 \oplus B) \ominus B$$

Binary Opening (αφαιρεί θόρυβο):

$$M'' = (M' \ominus B) \oplus B$$

Στη συνέχεια υπολογίζεται η μεγαλύτερη συνεκτική συνιστώσα:

$$M_{brain} = \text{LargestConnectedComponent}(M'')$$

Η τελική μάσκα χρησιμοποιείται για περιορισμό των υπολογισμών στον εγκεφαλικό ιστό.

3.2.2 Bias Field Correction

Οι MRI παρουσιάζουν ανομοιογένεια έντασης λόγω χαμηλής συχνότητας πεδίου. Το παρατηρούμενο σήμα μοντελοποιείται ως:

$$I(x) = J(x) \cdot B(x) + \epsilon(x)$$

όπου:

- $J(x)$= πραγματική ένταση,
- $B(x)$= χαμηλής συχνότητας πεδίο,
- $\epsilon(x)$= θόρυβος.

Το πεδίο προσεγγίζεται με Gaussian smoothing:

$$\hat{B}(x) = \mathcal{G}_\sigma * I(x)$$

και η διορθωμένη ένταση:

$$I_{corr}(x) = \frac{I(x)}{\hat{B}(x)}$$

Η διόρθωση αυτή μειώνει τεχνητές διακυμάνσεις έντασης εντός του ίδιου ιστού (Tustison et al., 2010).

3.2.3 Κανονικοποίηση Έντασης

Οι MRI δεν έχουν απόλυτη φυσική κλίμακα έντασης. Για αριθμητική σταθερότητα εφαρμόζεται z-score:

$$I_{norm}(x) = \frac{I(x) - \mu}{\sigma}$$

Η κανονικοποίηση γίνεται εντός μάσκας (masked standardization) και διασφαλίζει ότι οι τιμές έντασης του εγκεφαλικού ιστού έχουν μηδενικό μέσο και μοναδιαία διασπορά.

- Intensity Clipping

Για περιορισμό ακραίων τιμών εφαρμόζεται:

$$I_{clip}(x) = \min\left(\max\left(I_{norm}(x), a\right), b\right)$$

με τυπικό εύρος [a,b].
Η διαδικασία αυτή βελτιώνει τη σταθερότητα κατά την εκπαίδευση βαθιών δικτύων.

3.2.4 Χωρική Κανονικοποίηση

Οι τρισδιάστατοι όγκοι παρουσιάζουν διαφοροποίηση διαστάσεων. Για να είναι τα δεδομένα συμβατά με 3D CNN, όλοι οι όγκοι μετασχηματίζονται σε σταθερό σχήμα εισόδου :

$$Z_t \times H_t \times W_t$$

Η μετατροπή επιτυγχάνεται μέσω 3D resampling με γραμμική παρεμβολη:

$$I'(x') = \sum_i w_i \, I(x_i)$$

όπου τα w_i υπολογίζονται από την τριγραμμική παρεμβολή (trilinear interpolation), δηλαδή καθορίζονται από τις σχετικές αποστάσεις στον χώρο (Chen et al., 2019).
Η διαδικασία αυτή εξασφαλίζει:

- σταθερή χωρική ανάλυση,
- συμβατότητα με συνελικτικά φίλτρα σταθερού μεγέθους.

3.2.5 3D Data Augmentation

Η περιορισμένη διαθεσιμότητα ιατρικών δεδομένων καθιστά αναγκαία την εισαγωγή ελεγχόμενης μεταβλητότητας (Shorten & Khoshgoftaar, 2019).

- Γεωμετρικοί Μετασχηματισμοί:

Rotation(περιστροφή):

$$x' = R(\theta)x$$

Shift(μετατόπιση):

$$x' = x + \Delta$$

Zoom(κλιμάκωση):

$$x' = sx$$

Flip (αντιστροφή άξονα)

- Μετασχηματισμοί Έντασης:

Προσθήκη Gaussian noise:

$$I'(x) = I(x) + \mathcal{N}(0, \sigma^2)$$

Ρύθμιση Αντίθεσης (Contrast Adjustment):

$$I'(x) = \alpha I(x) + \beta$$

Εξομάλυνση Gaussian (Smoothing):

$$I'(x) = \mathcal{G}_\sigma * I(x)$$

Μετά - Κανονικοποίηση

Μετά τους μετασχηματισμούς εφαρμόζεται εκ νέου:

$$I_{final}(x) = \frac{I'(x) - \mu'}{\sigma'}$$

ώστε να διατηρηθεί αριθμητική σταθερότητα.

3.3 Διαχωρισμός Δεδομένων και Πειραματικό Πρωτόκολλο

Η σωστή πειραματική σχεδίαση αποτελεί κρίσιμο παράγοντα για την αξιοπιστία των αποτελεσμάτων σε προβλήματα ιατρικής ταξινόμησης. Στην παρούσα εργασία ο διαχωρισμός των δεδομένων πραγματοποιείται σε επίπεδο εξεταζόμενου (subject-level splitting), με διατήρηση των αναλογιών των κλάσεων (stratified sampling) και ελεγχόμενη αναπαραγωγιμότητα..

3.3.1 Διαχωρισμός σε Επίπεδο Εξεταζόμενου

Κάθε εξεταζόμενος s_i αναπαρίσταται ως ενιαίος τρισδιάστατος όγκος:

$$V_i \in \mathbb{R}^{Z \times H \times W}$$

όπου:

- Z= αριθμός τομών,
- H, W= χωρικές διαστάσεις.

Ο συνολικός πληθυσμός των δεδομένων ορίζεται ως:

$$\mathcal{D} = \{(V_i, y_i)\}_{i=1}^{N}$$

όπου y_i η κλάση του εξεταζόμενου.

Ο διαχωρισμός πραγματοποιείται ως:

$$\mathcal{D} = \mathcal{D}_{train} \cup \mathcal{D}_{val} \cup \mathcal{D}_{test}$$

με τον περιορισμό:

$$\mathcal{D}_{train} \cap \mathcal{D}_{val} \cap \mathcal{D}_{test} = \emptyset$$

σε επίπεδο subject.

Δηλαδή:

$$s_i \in \mathcal{D}_{train} \Rightarrow s_i \notin \mathcal{D}_{val}, s_i \notin \mathcal{D}_{test}$$

Αυτό αποτρέπει το φαινόμενο διαρροής πληροφορίας (data leakage), το οποίο θα προέκυπτε εάν διαφορετικοί όγκοι του ίδιου εγκεφάλου εμφανίζονταν σε διαφορετικά σύνολα. Αντίθετα, στον διαχωρισμό σε επίπεδο τομών (slice-level splitting), διαφορετικές τομές του ίδιου subject μπορεί να κατανεμηθούν σε διαφορετικά σύνολα, δημιουργώντας data leakage.

Σε ιατρικές απεικονιστικές μελέτες, ο διαχωρισμός σε επίπεδο εξεταζόμενου θεωρείται απαραίτητος ώστε να αποφεύγεται υπερεκτίμηση της απόδοσης των μοντέλων (Wen et al., 2020).

3.3.2 Στρωματοποιημένη Δειγματοληψία

Για τη διατήρηση της αναλογίας των κλάσεων, εφαρμόζεται στρωματοποιημένη δειγματοληψία.

Έστω ότι η κατανομή των κλάσεων στο πλήρες σύνολο είναι:

$$p_k = \frac{N_k}{N}$$

όπου:

- N_k= αριθμός subjects της κλάσης k,
- N= συνολικός αριθμός subjects.

Στον στρωματοποιημένο διαχωρισμό (stratified split) διατηρείται κατά προσέγγιση:

$$p_k^{train} \approx p_k^{val} \approx p_k^{test} \approx p_k$$

Έτσι αποφεύγεται η τεχνητή μεταβολή της κατανομής των κλάσεων, η οποία θα μπορούσε να οδηγήσει σε μεροληπτική εκτίμηση της απόδοσης.

3.3.3 Στρατηγική Διαχωρισμού Δεδομένων

Ο διαχωρισμός πραγματοποιείται σε δύο στάδια:

Διαχωρισμός Test: $\mathcal{D} \rightarrow \mathcal{D}_{train+val} + \mathcal{D}_{test}$

Διαχωρισμός Validation από το train+val: $\mathcal{D}_{train+val} \rightarrow \mathcal{D}_{train} + \mathcal{D}_{val}$

Η διάρθρωση αυτή επιτρέπει:

- Εκπαίδευση στο $\mathcal{D}_{train}$
- Ρύθμιση υπερπαραμέτρων στο $\mathcal{D}_{val}$
- Τελική αμερόληπτη αξιολόγηση στο $\mathcal{D}_{test}$

3.3.4 Αναπαραγωγιμότητα (Reproducibility)

Για την εξασφάλιση αναπαραγωγιμότητας, χρησιμοποιείται σταθερός τυχαίος σπόρος seed $= 42$.
Έτσι η διαδικασία δειγματοληψίας γίνεται ντετερμινιστική επιτρέποντας την επαναληψιμότητα των πειραμάτων.

3.4 Μεταφορά Μάθησης και Προεκπαιδευμένα 3D Μοντέλα Εξαγωγής Χαρακτηριστικών

Η εκπαίδευση βαθιών νευρωνικών δικύων από το μηδέν (training from scratch) σε 3D ιατρικά δεδομένα αποτελεί ιδιαίτερα απαιτητική διαδικασία, καθώς ο αριθμός των διαθέσιμων δειγμάτων είναι συνήθως περιορισμένος σε σχέση με τον μεγάλο αριθμό παραμέτρων του μοντέλου. Η ανισορροπία αυτή αυξάνει τον κίνδυνο υπερπροσαρμογής (overfitting).

Για τον λόγο αυτό, υιοθετείται η στρατηγική της Μεταφοράς Μάθησης (Transfer Learning), όπου ένα νευρωνικό δίκτυο έχει ήδη εκπαιδευτεί σε μεγάλο σύνολο 3D ιατρικών δεδομένων και επαναχρησιμοποιείται ως μηχανισμός εξαγωγής χαρακτηριστικών (feature extractor). Με αυτόν τον τρόπο, αντί να βελτιστοποιούνται εκατομμύρια παράμετροι από αρχικοποίηση, χρησιμοποιείται μια ήδη μαθημένη αναπαράσταση $f_\theta(x)$, όπου οι παράμετροι θ έχουν εκπαιδευτεί σε ευρύτερο ιατρικό ή μη πεδίο.

Η χρήση προεκπαιδευμένων 3D backbones επιτρέπει:

- αξιοποίηση γενικών χωρικών και μορφολογικών προτύπων,
- σταθερότερη βελτιστοποίηση,
- μείωση του κινδύνου υπερπροσαρμογής,
- βελτιωμένη γενικευσιμότητα σε άγνωστα subjects.

Επιπλέον, η μεταφορά μάθησης λειτουργεί ως έμμεση μορφή κανονικοποίησης, καθώς περιορίζει τον αριθμό των ελεύθερων παραμέτρων που προσαρμόζονται στα δεδομένα της συγκεκριμένης μελέτης (Pan & Yang, 2010).

Στο πλαίσιο της παρούσας εργασίας, η στρατηγική αυτή επιλέχθηκε λόγω του σχετικά μικρού μεγέθους του dataset και της ανάγκης εξαγωγής σταθερών και διακριτικών αναπαραστάσεων από τρισδιάστατα MRI δεδομένα.

3.4.1 Μεταφορά Μάθησης (Transfer Learning)

Ένα τρισδιάστατο συνελικτικό νευρωνικό δίκτυο μπορεί να θεωρηθεί ως μια παραμετρική συνάρτηση:

$$f_\theta : \mathcal{X} \subset \mathbb{R}^{Z \times H \times W} \rightarrow \mathbb{R}^d$$

όπου:

- $\mathcal{X}$ είναι ο χώρος των προεπεξεργασμένων MRI όγκων,
- $Z \times H \times W$ οι χωρικές διαστάσεις του όγκου,
- d η διάσταση του χώρου χαρακτηριστικών (feature space).

Η μεταφορά μάθησης συνίσταται στη χρήση ενός συνόλου παραμέτρων $\theta^{\backslash *}$, το οποίο έχει προεκπαιδευτεί σε διαφορετικό αλλά συναφές πρόβλημα (source domain), και στη μεταφορά του στο νέο πρόβλημα στόχο (target domain).

Στην παρούσα εργασία υιοθετείται η στρατηγική:

$$\boxed{z_i = f_{\theta^{\backslash *}}(X_i)}$$

όπου:

- X_i είναι ο τρισδιάστατος MRI όγκος του i-οστού subject,
- $z_i \in \mathbb{R}^d$ το εξαγόμενο διάνυσμα χαρακτηριστικών.

Σημαντικό στοιχείο είναι ότι οι παράμετροι $\theta^{\backslash *}$ παραμένουν σταθερές (fixed feature extraction) και δεν προσαρμόζονται εκ νέου στο dataset της εργασίας.

3.4.2 Προεκπαιδευμένα Τρισδιάστατα Μοντέλα (Pretrained Models)

Στο πλαίσιο της εργασίας αξιοποιήθηκαν τρισδιάστατες αρχιτεκτονικές ResNet, προεκπαιδευμένες σε μεγάλα ιατρικά σύνολα δεδομένων (datasets).

- <u>Med3D (ResNet-18 3D)</u>

Το Med3D αποτελεί 3D συνελικτικό δίκτυο βασισμένο στην αρχιτεκτονική ResNet-18, το οποίο έχει εκπαιδευτεί σε πολλαπλά ιατρικά σύνολα δεδομένων (datasets).

Η αρχιτεκτονική περιλαμβάνει:

- 3D συνελικτικά φίλτρα,
- υπολειμματικές (residual) συνδέσεις,
- διαδοχικά επίπεδα υποδειγματοληψίας (downsampling),
- παγκόσμια 3D μέση ομαδοποίηση (global average pooling).

Οι παρακαμπτήριες (residual) συνδέσεις (skip connections) επιτρέπουν την άμεση προσθήκη της εισόδου ενός επιπέδου στην έξοδό του.

Η αρχιτεκτονική αυτή διευκολύνει τη βελτιστοποίηση βαθιών δικτύων, καθώς επιτρέπει την απρόσκοπτη ροή των βαθμίδων κατά την οπισθοδιάδοση (backpropagation), μειώνοντας το φαινόμενο της εξαφάνισης βαθμίδων(Chen et al., 2019) .

- Το **Global Average Pooling (GAP)** είναι πράξη που:
  - λαμβάνει κάθε χάρτη χαρακτηριστικών (feature map)
  - υπολογίζει τον μέσο όρο όλων των voxel τιμών του

Αν ο τελευταίος χάρτης χαρακτηριστικών (feature map) έχει διαστάσεις $C \times D \times H \times W$ τότε το GAP υπολογίζει:

$$z_c = \frac{1}{DHW} \sum_{i=1}^{D} \sum_{j=1}^{H} \sum_{k=1}^{W} F_c\,(i,j,k)$$

και παράγει διάνυσμα $z \in \mathbb{R}^C$,δηλαδή υπολογίζει τον μέσο όρο κάθε χάρτη χαρακτηριστικών (feature map) και παράγει ένα συμπαγές διάνυσμα χαρακτηριστικών.
Η τελική αναπαράσταση προκύπτει ως:

$$\mathrm{z} = \mathrm{GAP}(F(\mathrm{X}))$$

όπου $F(\cdot)$είναι ο μη γραμμικός μετασχηματισμός των συνελικτικών επιπέδων και GAP είναι το Global Average Pooling.

- MedicalNet (ResNet-50 3D)

Το MedicalNet βασίζεται σε βαθύτερη 3D ResNet-50 αρχιτεκτονική και έχει προεκπαιδευτεί σε μεγάλο πλήθος ιατρικών όγκων (23 datasets) (Chen et al., 2019).
Αφαιρείται το τελικό πλήρως συνδεδεμένο (fully connected) επίπεδο ταξινόμησης και χρησιμοποιείται μόνο ο συνελικτικός κορμός (backbone) ως εξαγωγέας χαρακτηριστικών:

$$\mathrm{z} = \mathrm{AdaptiveAvgPool3D}(F(\mathrm{X}))$$

με αποτέλεσμα τη δημιουργία υψηλής διάστασης διανύσματος χαρακτηριστικών. Το Adaptive Average Pooling είναι γενίκευση του GAP. Η διαφορά τους είναι ότι ενώ το GAP παράγει πάντα έξοδο 1×1×1, το AdaptiveAvgPool μπορεί να προσαρμόσει την έξοδο σε συγκεκριμένη διάσταση και έτσι εξασφαλίζεται μονοδιάστατη αναπαράσταση ανεξάρτητα από τις διαστάσεις εισόδου.

- Model Genesis

Το Model Genesis βασίζεται σε στρατηγική αυτοεπιβλεπόμενης (self-supervised) προεκπαίδευσης. Αντί να εκπαιδεύεται με ετικέτες, το μοντέλο μαθαίνει να ανακατασκευάζει τεχνητά παραμορφωμένους ιατρικούς όγκους (Zhou et al., 2021).
Μαθηματικά, η διαδικασία εκπαίδευσης βασίζεται στην ελαχιστοποίηση σφάλματος ανακατασκευής:

$$\mathcal{L} = \| X - \hat{X} \|_2^2$$

όπου:

- Xο αρχικός όγκος,
- $\hat{X}$η ανακατασκευασμένη έξοδος του δικτύου.

Με αυτόν τον τρόπο, το δίκτυο μαθαίνει γενικές χωρικές αναπαραστάσεις ιατρικών δεδομένων, οι οποίες μπορούν να μεταφερθούν σε πρόβλημα ταξινόμησης.

3.4.3 Εξαγωγή και Τυποποίηση Χαρακτηριστικών

Η συνολική διαδικασία μπορεί να περιγραφεί ως σύνθεση δύο συναρτήσεων:

$$\hat{y}_i = g_\phi(f_{\theta^*}(\mathrm{X}_i))$$

όπου:

- f_{θ^*}είναι το παγωμένο pretrained 3D backbone,
- g_ϕο τελικός ταξινομητής που εκπαιδεύεται στο dataset της εργασίας.

Τα εξαγόμενα χαρακτηριστικά z_i τυποποιούνται περαιτέρω μέσω γραμμικού μετασχηματισμού (Τυποποίηση και Z- score normalization):

$$\mathrm{z}' = \frac{\mathrm{z} - \mu}{\sigma}$$

όπου μ (μέσος όρος χαρακτηριστικού – mean) και σ (τυπική απόκλιση – standard deviation) υπολογίζονται από το σύνολο εκπαίδευσης (train set).

Η προσέγγιση αυτή επιτρέπει:

- μείωση του αριθμού εκπαιδευόμενων παραμέτρων,
- σταθερότερη εκπαίδευση,
- αξιοποίηση γενικών χωρικών αναπαραστάσεων που έχουν ήδη μάθει τα προεκπαιδευμένα μοντέλα.

3.5 Θεμελιώδεις Ταξινομητές Μηχανικής Μάθησης

Μετά την εξαγωγή αναπαραστάσεων υψηλού επιπέδου μέσω προεκπαιδευμένων 3D συνελικτικών δικτύων (Κεφ. 3.4), κάθε εξεταζόμενος αναπαρίσταται ως διάνυσμα χαρακτηριστικών $\mathrm{x}_i \in \mathbb{R}^d$ όπου d είναι η διάσταση της εξαγόμενης αναπαράστασης (embedding).

Το πρόβλημα ταξινόμησης διατυπώνεται ως εύρεση συνάρτησης η οποία αποδίδει την κατάλληλη διαγνωστική κατηγορία:

$$f: \mathbb{R}^d \to \{1, \dots, K\}$$

όπου K ο αριθμός κλάσεων.

Το σύνολο των embeddings οργανώνεται σε μητρώο χαρακτηριστικών

$$X = [x_1, x_2, \dots, x_N]^T \in \mathbb{R}^{N \times d}$$

όπου N ο αριθμός των δειγμάτων και d η διάσταση της αναπαράστασης.

Η ταξινόμηση πλέον δεν πραγματοποιείται σε επίπεδο voxel, αλλά σε χώρο συμπαγών αναπαραστάσεων (feature space), γεγονός που μειώνει τη διάσταση του προβλήματος και επιτρέπει τη χρήση κλασικών και νευρωνικών ταξινομητών. Συνεπώς, έχουμε ταξινόμηση βάσει χαρακτηριστικών (feature-based classification), όπου το συνελικτικό δίκτυο λειτουργεί ως σταθερός μετασχηματιστής αναπαράστασης και η τελική απόφαση λαμβάνεται από ανεξάρτητο ταξινομητή.

3.5.1 Προτυποποίηση Χαρακτηριστικών

Οι εξαγόμενες αναπαραστάσεις ενδέχεται να έχουν διαφορετικές κλίμακες μεταξύ διαστάσεων. Για την αποφυγή κυριαρχίας χαρακτηριστικών μεγάλης διακύμανσης εφαρμόζεται κανονικοποίηση ανά χαρακτηριστικό μέσω z-score:

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

όπου:

- μ_jο μέσος όρος του χαρακτηριστικού j,
- σ_jη τυπική απόκλιση.

δηλαδή, μετασχηματίζει τα δεδομένα σε χώρο μηδενικού μέσου και μοναδιαίας διασποράς.

Σε ορισμένες περιπτώσεις εφαρμόζεται επιπλέον κανονικοποίηση L2:

$$\mathrm{x}'' = \frac{\mathrm{x}'}{\| \mathrm{x}' \|_2}$$

ώστε όλα τα δείγματα να βρίσκονται στην μοναδιαία υπερεπιφάνεια:

$$\| \mathbf{x}'' \|_2 = 1$$

Η L2 κανονικοποίηση ευνοεί γεωμετρικές μετρικές βασισμένες στη γωνιακή απόσταση (cosine similarity).

- Μείωση Διαστάσεων (PCA)

Σε περιπτώσεις πολύ υψηλής διάστασης, εφαρμόζεται Ανάλυση Κύριων Συνιστωσών (Principal Component Analysis – PCA).

Το PCA βασίζεται στη διάσπαση ιδιοτιμών της συνδιακύμανσης και επιλέγει τις πρώτες m ιδιοδιανυσματικές κατευθύνσεις που διατηρούν προκαθορισμένο ποσοστό

διακύμανσης ≥ 0.95

Έτσι επιτυγχάνεται συμπίεση πληροφορίας με ελεγχόμενη απώλεια.

3.5.2 Γραμμικοί Ταξινομητές

Το παρόν κεφάλαιο παρουσιάζει αποκλειστικά τους ταξινομητές που χρησιμοποιήθηκαν στην παρούσα εργασία, οι οποίοι λειτουργούν στον χώρο αναπαραστάσεων (embeddings) που παράγονται από προεκπαιδευμένα 3D νευρωνικά δίκτυα. Η επιλογή τους επιτρέπει τη συγκριτική αξιολόγηση γραμμικών, μη γραμμικών, ενισχυτικών και νευρωνικών προσεγγίσεων στον ίδιο αναπαραστατικό χώρο.

- Logistic Regression

Η Λογιστική Παλινδρόμηση μοντελοποιεί την πιθανότητα κλάσης ως:

$$P(y = 1 \mid x) = \sigma(w^T x + b)$$

όπου $\sigma(z) = \frac{1}{1+e^{-z}}$ (He et al., 2019).

Η εκπαίδευση πραγματοποιείται μέσω ελαχιστοποίησης της διασταυρούμενης εντροπίας με πιθανή L2 κανονικοποίηση:

$$L = -\sum y_i \log \hat{y}_i + \lambda \parallel w \parallel^2$$

- Linear Support Vector Classifier (Linear SVC)

Ο γραμμικός SVM επιδιώκει την εύρεση υπερεπιπέδου:

$$w^T x + b = 0$$

που μεγιστοποιεί το περιθώριο μεταξύ των κλάσεων. Στην soft-margin εκδοχή επιλύεται:

$$\min_{w,b} \frac{1}{2} \parallel w \parallel^2 + C\sum \xi_i$$

υπό τον περιορισμό:

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

όπου C ελέγχει τον συμβιβασμό μεταξύ περιθωρίου (margin) και σφαλμάτων (Pande & Banerjee, 2021).

Στην παρούσα εργασία χρησιμοποιείται γραμμικός πυρήνας.

3.5.3 Μη Γραμμικός SVM

Όταν τα δεδομένα δεν είναι γραμμικά διαχωρίσιμα, εφαρμόζεται SVM με πυρήνα RBF:

$$K(x_i, x_j) = \exp(-\gamma \parallel x_i - x_j \parallel^2)$$

ο οποίος επιτρέπει μη γραμμικό διαχωρισμό σε μετασχηματισμένο χώρο υψηλότερης διάστασης.

3.5.4 Distance – Based Μέθοδοι

- k-Nearest Neighbors (KNN)

Ο KNN ταξινομεί νέο δείγμα βάσει των k πλησιέστερων γειτόνων:

$$\hat{y}(x) = \text{mode}\{y_i : x_i \in \mathcal{N}_k(x)\}$$

Η απόσταση υπολογίζεται μέσω Ευκλείδειας μετρικής.

- Learning Vecton Quantization (LVQ)

Το LVQ βασίζεται σε πρωτότυπα διανύσματα w_c.
Για δείγμα x, επιλέγεται το πλησιέστερο πρωτότυπο και ενημερώνεται ως:

$$w_c^{new} = w_c^{old} + \eta(x - w_c)$$

αν η ταξινόμηση είναι σωστή, ή

$$w_c^{new} = w_c^{old} - \eta(x - w_c)$$

αν είναι λανθασμένη.

3.5.5 Ensemble Μέθοδοι

❖ AdaBoost με Decision Trees

Το AdaBoost κατασκευάζει διαδοχικά ασθενείς ταξινομητές $h_t(x)$και σχηματίζει τελικό μοντέλο $\boxed{F(x) = \sum_{t=1}^{T} \alpha_t \, h_t(x)}$.

Κάθε νέο μοντέλο εστιάζει στα σφάλματα των προηγούμενων μέσω αναπροσαρμογής βαρών.

❖ Bagging Linear SVM

Στο Bagging δημιουργούνται πολλαπλά δείγματα εκπαίδευσης με επανατοποθέτηση και εκπαιδεύεται ανεξάρτητος Linear SVM σε καθένα από αυτά. Η τελική πρόβλεψη προκύπτει μέσω πλειοψηφικής ψήφου:

$$\boxed{\hat{y}(x) = \text{mode}\{f_t(x)\}}$$

Η διαδικασία μειώνει τη διακύμανση του μοντέλου και αυξάνει τη σταθερότητα.

3.5.6 Πολυεπίπεδα Νευρωνικά Δίκτυα (MLP)

Το MLP υλοποιεί μη γραμμική χαρτογράφηση:

$$\boxed{\begin{aligned} h_1 &= \text{ReLU}(W_1 x + b_1) \\ h_l &= \text{ReLU}(W_l h_{l-1} + b_l) \\ \hat{y} &= \text{softmax}(W_L h_{L-1} + b_L) \end{aligned}}$$

Η συνάρτηση ReLU (Rectified Linear Unit) εισάγει μη γραμμικότητα στο δίκτυο, επιτρέποντας τη μάθηση σύνθετων ορίων απόφασης, ενώ ταυτόχρονα περιορίζει το φαινόμενο εξαφάνισης βαθμίδων σε σχέση με παλαιότερες ενεργοποιήσεις όπως η λογιστική (sigmoid).

Η συνάρτηση softmax μετατρέπει τις τελικές γραμμικές αποκρίσεις του δικτύου σε κατανομή πιθανοτήτων, εξασφαλίζοντας ότι:

$$\boxed{\sum_{c=1}^{C} \hat{y}_c = 1}$$

.

και επιτρέποντας την ερμηνεία της εξόδου ως πιθανότητα του να ανήκει σε κάθε διαγνωστική κλάση.

Η εκπαίδευση πραγματοποιείται μέσω διασταυρούμενης εντροπίας:

$$\boxed{L = -\sum_{c=1}^{C} y_c \log \hat{y}_c}$$

και βελτιστοποίησης τύπου Adam.

Για τη μείωση υπερπροσαρμογής εφαρμόζεται Dropout:

$$\boxed{h_i^{drop} = r_i h_i, r_i \sim Bernoulli(p)}$$

3.5.7 Διαχείριση Ανισορροπίας Κλάσεων

Σε περιπτώσεις ανισορροπίας εφαρμόζεται στάθμιση κλάσεων (class weighting) στη συνάρτηση απώλειας:

$$\boxed{L = -\sum w_c y_c \log \hat{y}_c}$$

ώστε να ενισχυθεί η συμβολή μειοψηφικών κλάσεων.

3.6 Ιεραρχική Ταξινόμηση

Σε προβλήματα πολυκατηγορικής ιατρικής ταξινόμησης, οι διαγνωστικές κατηγορίες συχνά οργανώνονται ιεραρχικά και όχι ως ανεξάρτητες, ισοδύναμες κλάσεις. Στην περίπτωση της άνοιας, οι υποκατηγορίες (π.χ. Very Mild, Mild, Moderate) αποτελούν εξειδίκευση μιας ευρύτερης κατηγορίας (Demented), η οποία διαχωρίζεται αρχικά από τη μη παθολογική κατάσταση (Non-Demented).

Η ιεραρχική ταξινόμηση αξιοποιεί αυτή τη δομική σχέση, αποσυνθέτοντας το αρχικό πρόβλημα σε διαδοχικά στάδια απόφασης, τα οποία μοντελοποιούν τη λογική της κλινικής διάγνωσης.

Μετά την εξαγωγή αναπαραστάσεων υψηλού επιπέδου (embeddings) από προεκπαιδευμένα τρισδιάστατα συνελικτικά δίκτυα (Κεφ. 3.4) και την εφαρμογή θεμελιωδών ταξινομητών στον χώρο χαρακτηριστικών (Κεφ. 3.5), το πρόβλημα της διάγνωσης μπορεί να διατυπωθεί ως πολυκατηγορική ταξινόμηση στον χώρο:

$$x \in \mathbb{R}^d$$

όπου d η διάσταση του διανύσματος χαρακτηριστικών.

Σε κλασική (flat) προσέγγιση, ορίζεται μία ενιαία συνάρτηση:

$$f: \mathbb{R}^d \to \{1,2,\dots,K\}$$

η οποία διαχωρίζει ταυτόχρονα όλες τις διαγνωστικές κατηγορίες.

Ωστόσο, σε πολλά ιατρικά προβλήματα οι κλάσεις δεν είναι ισοδύναμες, αλλά οργανώνονται σε φυσική ιεραρχία. Σε τέτοιες περιπτώσεις, η ιεραρχική ταξινόμηση (hierarchical classification) αποσυνθέτει το αρχικό πολυκατηγορικό πρόβλημα σε διαδοχικά υποπροβλήματα μικρότερης πολυπλοκότητας.

3.6.1 Διατύπωση Προβλήματος

Σε απλοποιημένη μορφή δύο σταδίων, το πρόβλημα αποσυντίθεται ως εξής:

1. Πρώτο στάδιο (γενική διάκριση):

$$f_1: \mathbb{R}^d \to \{C_{general}, C_{other}\}$$

2. Δεύτερο στάδιο (εξειδίκευση):

$$f_2: \mathbb{R}^d \to \{C_1, C_2, \dots, C_m\}$$

Η τελική πρόβλεψη ορίζεται ως:

$$\hat{y} = \begin{cases} C_{other}, & \text{αν } f_1(x) = C_{other} \\ f_2(x), & \text{αν } f_1(x) = C_{general} \end{cases}$$

Κάθε επιμέρους ταξινομητής δρα σε υποσύνολο του χώρου χαρακτηριστικών, επιλύοντας πρόβλημα χαμηλότερης πολυπλοκότητας σε σχέση με την ενιαία πολυκατηγορική διατύπωση.

3.6.2 Σύγκριση με Επίπεδη (Flat) Προσέγγιση

Στην επίπεδη ταξινόμηση, όλες οι κλάσεις αντιμετωπίζονται ως ισοδύναμες και ο διαχωρισμός πραγματοποιείται μέσω ενιαίας επιφάνειας απόφασης στον χώρο $\mathbb{R}^d$.

Αντίθετα, η ιεραρχική προσέγγιση:

- διασπά το πολυκατηγορικό πρόβλημα σε απλούστερα υποπροβλήματα,
- αξιοποιεί τη δομική σχέση μεταξύ των κατηγοριών,
- επιτρέπει στοχευμένη μάθηση σε κάθε επίπεδο,
- ευθυγραμμίζεται με τη λογική σταδιακής εξειδίκευσης που συχνά συναντάται σε κλινικά διαγνωστικά σχήματα.

Συνεπώς, η ιεραρχική ταξινόμηση θεμελιώνει μια δομημένη στρατηγική αποσύνθεσης της απόφασης, η οποία επιτρέπει την καλύτερη εκμετάλλευση της σχέσης μεταξύ των κλάσεων (Zhang et al., 2017)

3.7 Συνένωση Πληροφοριών (Data Fusion)

Η αξιοποίηση πολλαπλών προεκπαιδευμένων τρισδιάστατων μοντέλων (όπως Med3D, MedicalNet ή ModelGenesis) οδηγεί σε διαφορετικές αναπαραστάσεις (embeddings) για το ίδιο MRI δείγμα. Κάθε backbone έχει εκπαιδευτεί με διαφορετικό στόχο και σε διαφορετικά δεδομένα, με αποτέλεσμα να αποτυπώνει συμπληρωματικά μορφολογικά πρότυπα.

Η συνένωση πληροφοριών (data fusion) στοχεύει στη συνδυαστική αξιοποίηση αυτών των αναπαραστάσεων, ώστε να ενισχυθεί η διακριτική ικανότητα του συνολικού συστήματος ταξινόμησης.

Η διαδικασία fusion μπορεί να πραγματοποιηθεί σε δύο βασικά επίπεδα:

- σε επίπεδο χαρακτηριστικών (feature-level fusion),
- σε επίπεδο απόφασης (decision-level fusion).

3.7.1 Συνένωση σε Επίπεδο Χαρακτηριστικών (Feature – Level Fusion)

Στη feature-level (ή mid-level) fusion, τα embeddings από διαφορετικά μοντέλα συνενώνονται σε ενιαίο διάνυσμα μέσω απλής παράθεσης (concatenation):

$$z_i = [x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(M)}]$$

Το fused διάνυσμα z_i βρίσκεται σε χώρο υψηλότερης διάστασης και χρησιμοποιείται ως είσοδος σε έναν ενιαίο ταξινομητή.

Η προσέγγιση αυτή επιτρέπει στον τελικό ταξινομητή να μάθει κοινά πρότυπα που προκύπτουν από τη συνδυαστική πληροφορία των επιμέρους μοντέλων. Ωστόσο, η αύξηση της διάστασης ενδέχεται να απαιτεί προτυποποίηση και, σε ορισμένες περιπτώσεις, μείωση διαστασιμότητας ώστε να περιοριστεί ο κίνδυνος υπερπροσαρμογής.

3.7.2 Συνένωση σε Επίπεδο Απόφασης (Decision – Level Fusion)

Στη decision-level (ή late) fusion, κάθε backbone διαθέτει τον δικό του ταξινομητή και παράγει ανεξάρτητες προβλέψεις. Οι τελικές αποφάσεις συνδυάζονται μέσω κανόνων όπως:

- μέσος όρος πιθανοτήτων (soft voting),
- πλειοψηφική ψήφος (hard voting),
- σταθμισμένος συνδυασμός προβλέψεων.

Αν $p_i^{(m)}$ είναι το διάνυσμα πιθανοτήτων που παράγει το μοντέλο m, η τελική πιθανότητα μπορεί να υπολογιστεί ως:

$$p_i = \frac{1}{M} \sum_{m=1}^{M} p_i^{(m)}$$

και η τελική πρόβλεψη προκύπτει από τη μέγιστη πιθανότητα.

Η προσέγγιση αυτή επιτρέπει τη διατήρηση της ανεξαρτησίας των επιμέρους μοντέλων και μειώνει τον κίνδυνο υπερπροσαρμογής σε υψηλής διάστασης fused χώρους.

3.7.3 Stacking Fusion

Πέρα από σταθερούς κανόνες συνδυασμού, είναι δυνατόν να εκπαιδευτεί ένας μετα-ταξινομητής (meta-classifier) πάνω στις προβλέψεις των επιμέρους μοντέλων. Στην περίπτωση αυτή, τα διανύσματα πιθανοτήτων των base μοντέλων λειτουργούν ως νέα χαρακτηριστικά:

$$s_i = [p_i^{(1)}, p_i^{(2)}, \dots, p_i^{(M)}]$$

και εκπαιδεύεται συνάρτηση:

$$\hat{y}_i = g(s_i)$$

Η στρατηγική αυτή επιτρέπει στο σύστημα να μάθει τον βέλτιστο τρόπο συνδυασμού των επιμέρους προβλέψεων.

3.7.4 Θεωρητική Σημασία της Συνένωσης

Η συνένωση πληροφοριών βασίζεται στην υπόθεση ότι διαφορετικά μοντέλα συλλαμβάνουν διαφορετικές πτυχές της υποκείμενης δομής των δεδομένων. Όταν τα επιμέρους μοντέλα παρουσιάζουν συμπληρωματικά σφάλματα, ο συνδυασμός τους μπορεί να οδηγήσει σε βελτιωμένη σταθερότητα και γενικευσιμότητα.

Συνεπώς, το data fusion δεν αποτελεί απλώς τεχνική αύξησης διαστάσεων ή συνδυασμού ψήφων, αλλά στρατηγική αξιοποίησης ετερογενούς αναπαραστατικής πληροφορίας με στόχο την ενίσχυση της συνολικής απόδοσης του συστήματος ταξινόμησης.

3.8 Μετρικές Αξιολόγησης

Η αξιολόγηση ενός διαγνωστικού συστήματος ταξινόμησης απαιτεί μετρικές που αποτυπώνουν όχι μόνο τη συνολική ορθότητα, αλλά και τη συμπεριφορά του μοντέλου ως προς κάθε κατηγορία. Στα ιατρικά προβλήματα, όπου συχνά υπάρχει ανισορροπία κλάσεων (class imbalance), η χρήση κατάλληλων μετρικών καθίσταται κρίσιμη.

❖ Πίνακας Σύγχυσης (Confusion Matrix)

Ο πίνακας σύγχυσης απεικονίζει την κατανομή των σωστών και λανθασμένων προβλέψεων ενός μοντέλου ανά κατηγορία, δείχνοντας πόσα δείγματα κάθε πραγματικής κλάσης ταξινομήθηκαν σωστά ή συγχέθηκαν με άλλες κλάσεις.

Έστω πίνακας σύγχυσης για δυαδική ταξινόμηση:

- TP (True Positives): σωστά θετικά
- TN (True Negatives): σωστά αρνητικά
- FP (False Positives): ψευδώς θετικά
- FN (False Negatives): ψευδώς αρνητικά

❖ Μετρικές:

1) Ακρίβεια (accuracy)

Η συνολική ακρίβεια ορίζεται ως:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

και εκφράζει το ποσοστό σωστών προβλέψεων επί του συνόλου.

Ωστόσο, σε ανισόρροπα σύνολα δεδομένων (datasets), η ακρίβεια (accuracy) μπορεί να είναι παραπλανητική. Για παράδειγμα, αν η πλειοψηφική κλάση κυριαρχεί, ένα μοντέλο μπορεί να επιτύχει υψηλή ακρίβεια προβλέποντας κυρίως αυτή.

2) Θετική Προγνωστική Αξία (Precision)

Η Precision (θετική προγνωστική τιμή) ορίζεται ως:

$$Precision = \frac{TP}{TP + FP}$$

και εκφράζει το ποσοστό των θετικών προβλέψεων που είναι πράγματι σωστές.

Σε ιατρικά προβλήματα, υψηλή precision σημαίνει χαμηλό ποσοστό ψευδώς θετικών διαγνώσεων.

3) Ανάκληση (Recall)

Η ανάκληση (recall) ορίζεται ως:

$$Recall = \frac{TP}{TP + FN}$$

και εκφράζει το ποσοστό των πραγματικά θετικών δειγμάτων που ανιχνεύθηκαν σωστά.

Στην κλινική πράξη, η ανάκληση (recall) είναι ιδιαίτερα σημαντική, καθώς η αποτυχία ανίχνευσης παθολογικών περιπτώσεων (FN) μπορεί να έχει σοβαρές συνέπειες.

4) F1- Score

Η F1-score αποτελεί τη μέση τιμή Precision και Recall:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Η χρήση του αρμονικού μέσου τιμωρεί τις ακραίες τιμές, δηλαδή αν μία από τις δύο μετρικές είναι χαμηλή, το F1 μειώνεται σημαντικά.

Το F1-score είναι κατάλληλο σε περιπτώσεις ανισορροπίας κλάσεων, καθώς λαμβάνει υπόψη τόσο τα FP όσο και τα FN.

5) Macro-F1

Στην πολυκατηγορική ταξινόμηση, η Macro F1 υπολογίζεται ως ο μέσος όρος της F1 ανά κλάση:

$$Macro\text{-}F1 = \frac{1}{K}\sum_{c=1}^{K} F\,1_c$$

όπου:

- K ο αριθμός κλάσεων
- $F1_c$η F1 της κλάσης c

Κάθε κλάση συνεισφέρει ισότιμα, ανεξαρτήτως μεγέθους.

Στην παρούσα εργασία, το dataset παρουσιάζει ανισορροπία μεταξύ των διαγνωστικών κατηγοριών. Η χρήση της Macro- F1:

- αποτρέπει την κυριαρχία της πλειοψηφικής κλάσης,
- εξασφαλίζει ισότιμη αξιολόγηση όλων των σταδίων άνοιας,
- αντανακλά καλύτερα τη διαγνωστική ικανότητα του μοντέλου.

Για τον λόγο αυτό, η Macro F1 χρησιμοποιείται ως κύρια μετρική αξιολόγησης.

6) Balanced Accuracy

Η Balanced Accuracy ορίζεται ως:

$$Balanced\ Accuracy = \frac{Sensitivity + Specificity}{2}$$

ή γενικευμένα ως ο μέσος όρος της recall ανά κλάση.

Η μετρική αυτή είναι πιο κατάλληλη από την απλή ακρίβεια (accuracy) σε ανισόρροπα δεδομένα, καθώς εξισορροπεί τη συμβολή κάθε κατηγορίας.

7) ROC Curve και AUC

Η καμπύλη ROC (Receiver Operating Characteristic) απεικονίζει:

- στον άξονα x: False Positive Rate (FPR)

$$FPR = \frac{FP}{FP + TN}$$

- στον άξονα y: True Positive Rate (TPR = Recall)

Η επιφάνεια κάτω από την καμπύλη (AUC) ορίζεται ως:

$$AUC = \int_0^1 TPR(FPR)\, dFPR$$

Η AUC εκφράζει την πιθανότητα το μοντέλο να κατατάξει ένα τυχαίο θετικό δείγμα υψηλότερα από ένα αρνητικό.

8) Συνάρτηση Απώλειας (Cross-Entropy)

Κατά την εκπαίδευση των νευρωνικών δικτύων χρησιμοποιείται η διασταυρούμενη εντροπία:

$$L = -\sum_{c=1}^{C} y_c \log(\hat{y}_c)$$

η οποία ελαχιστοποιείται μέσω βελτιστοποιητών τύπου Adam ή AdamW.

- Η αξιολόγηση του συστήματος βασίζεται σε συνδυασμό μετρικών, με κύρια έμφαση στη Macro -F1, καθώς:
  - αντιμετωπίζει την ανισορροπία κλάσεων,
  - αξιολογεί ισότιμα όλες τις διαγνωστικές κατηγορίες,
  - αντανακλά ρεαλιστικά τη διαγνωστική απόδοση του μοντέλου.

Κεφάλαιο 4. Προτεινόμενη Μεθοδολογία

Στο παρόν κεφάλαιο παρουσιάζεται η προτεινόμενη μεθοδολογία για την ταξινόμηση τρισδιάστατων μαγνητικών τομογραφιών εγκεφάλου στο πλαίσιο της άνοιας. Η μεθοδολογία ακολουθεί μία συγκεκριμένη λογική, η οποία ξεκινάει από την προεπεξεργασία των δεδομένων έως τον τελικό συνδυασμό μοντέλων και την ιεραρχική ταξινόμηση. Στόχος μας είναι να διαμορφώσουμε ένα πλαίσιο, ικανό να αξιοποιήσει προεκπαιδευμένα δίκτυα βαθιάς μάθησης και κλασσικές τεχνικές μηχανικής μάθησης σε πολλαπλά διαγνωστικά σενάρια.

4.1 Συνολική Αρχιτεκτονική της Προτεινόμενης Προσέγγισης

Η προτεινόμενη αρχιτεκτονική οργανώνεται σε διαδοχικά στάδια επεξεργασίας. Αρχικά, πραγματοποιείται προεπεξεργασία των τρισδιάστατων όγκων MRI, με στόχο την ομογενοποίηση των εισόδων και την απομάκρυνση τεχνικών παραμορφώσεων. Στη συνέχεια εφαρμόζεται εξαγωγή χαρακτηριστικών μέσω προεκπαιδευμένων τρισδιάστατων συνελικτικών δικτύων (3D CNNs), τα οποία λειτουργούν ως μηχανισμοί αναπαράστασης υψηλού επιπέδου.

Τα παραγόμενα embeddings υποβάλλονται σε κανονικοποίηση και, όπου απαιτείται, σε μείωση διαστάσεων. Έπειτα εκπαιδεύονται κλασσικοί ταξινομητές και νευρωνικά δίκτυα πλήρων συνδεδεμένων επιπέδων (MLP), ενώ εξετάζονται και στρατηγικές συνδυασμού πληροφορίας. Τέλος, υλοποιείται ιεραρχική ταξινόμηση, η οποία εκμεταλλεύεται τη φυσική δομή του διαγνωστικού προβλήματος.

4.2 Προεπεξεργασία και Οργάνωση Δεδομένων MRI

Η προεπεξεργασία των δεδομένων στοχεύει στη διασφάλιση ομοιομορφίας και συγκρισιμότητας μεταξύ των δειγμάτων. Οι τρισδιάστατοι όγκοι υποβάλλονται σε διαδικασίες καθαρισμού θορύβου, βελτίωσης μάσκας εγκεφαλικού ιστού και διόρθωσης ανομοιομορφίας πεδίου. Παράλληλα εφαρμόζονται τεχνικές εξομάλυνσης και κανονικοποίησης εντάσεων, ώστε να περιοριστούν αποκλίσεις που οφείλονται στο απεικονιστικό σύστημα και όχι στη δομή του εγκεφάλου.

Η οργάνωση των δεδομένων πραγματοποιείται σε επίπεδο εξεταζόμενου ατόμου, αποτρέποντας τη διαρροή πληροφορίας μεταξύ συνόλων. Ο διαχωρισμός σε σύνολα εκπαίδευσης, επικύρωσης και ελέγχου σχεδιάζεται λαμβάνοντας υπόψη την ανισορροπία των διαγνωστικών κατηγοριών.

4.2.1 Αρχική μορφή δεδομένων και δομή dataset

Το αρχικό dataset διατίθεται σε μορφή 2D αξονικών τομών τύπου JPG. Κάθε εξεταζόμενος (subject) διαθέτει πολλαπλές τομές, οι οποίες αντιστοιχούν σε διαφορετικά επίπεδα κατά τον άξονα z του όγκου. Τα αρχεία είναι οργανωμένα σε φακέλους ανά διαγνωστική κατηγορία:

- Non Demented (άτομα χωρίς ενδείξεις άνοιας)
- Very Mild Dementia (πολύ ήπια γνωστική διαταραχή)

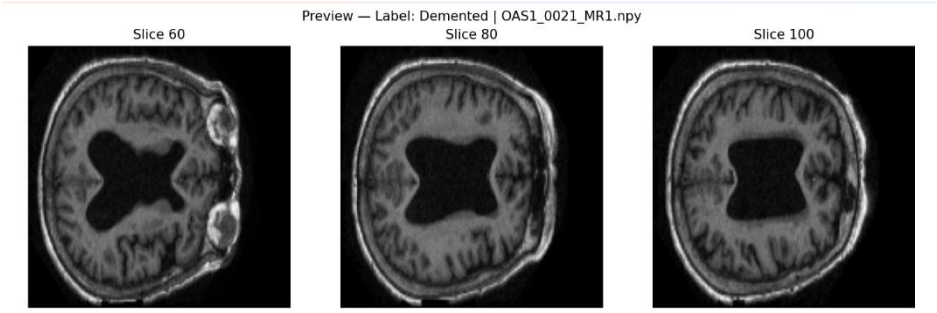
- Mild Dementia (ήπια άνοια με εμφανή γνωστική έκπτωση)
- Moderate Dementia (μέτριας βαρύτητας άνοια)

Η ονοματοδοσία των αρχείων ακολουθεί συγκεκριμένο πρότυπο της μορφής: SubjectID_MR1_mpr-1_sliceNumber.jpg

Η συγκεκριμένη δομή μάς επιτρέπει, μέσω κανονικών εκφράσεων (regex), να εξάγουμε με ακρίβεια το Subject_ID και το slice index από το όνομα κάθε αρχείου, ώστε να ανακατασκευάσουμε τον τρισδιάστατο όγκο ανά εξεταζόμενο (subject).

Πριν προχωρήσουμε σε οποιαδήποτε ενοποίηση ή μετασχηματισμό, υπολογίζουμε τον αριθμό των τομών (slices) ανά εξεταζόμενο (subject). Η ανάλυση αυτή μάς επιτρέπει να ελέγξουμε την πληρότητα των εξετάσεων, την ομοιογένεια του συνόλου δεδομένων (dataset) και πιθανές ελλείψεις ή ακραίες περιπτώσεις.

Για κάθε εξεταζόμενο (subject) δημιουργούμε μία εγγραφή. Παράλληλα εξάγουμε συνοπτικά στατιστικά ανά κλάση (αριθμό subjects, συνολικό αριθμό εικόνων, ελάχιστο/μέγιστο/διάμεσο αριθμό τομών).



Εικόνα 1.Ενδεικτικές εγκάρσιες τομές (axial slices) από τρισδιάστατο MRI όγκο εγκεφάλου, σε διαφορετικά επίπεδα (Slice 60, 80 και 100), οι οποίες απεικονίζουν τη χωρική δομή του εξεταζόμενου δείγματος.

4.2.2 Ενοποίηση βάθους όγκου

Για να εξασφαλίσουμε ομοιόμορφη τρισδιάστατη είσοδο προς τα μοντέλα 3D CNN, επειδή στο σύνολο δεδομένων (dataset) οι MRI έχουν διαφορετικά μεγέθη, επιλέγουμε τη διάμεσο (median) τιμή.

Εξασφαλίζοντας την επιλογή μιας ισορροπημένης τιμής αποφεύγουμε τη δημιουργία τεχνητών δεδομένων (interpolation), άρα δεν προσθέτουμε τεχνητή πληροφορία αλλά και ούτε αποκόπτουμε πραγματική πληροφορία.

Η διαδικασία που εφαρμόζουμε είναι η εξής:

1) Εάν ένας εξεταζόμενος (subject) διαθέτει περισσότερες τομές από τη τιμή της διαμέσου, κρατάμε τις κεντρικές (centered selection), ώστε να διατηρήσουμε το ανατομικά σημαντικό τμήμα του εγκεφάλου.
2) Εάν διαθέτει λιγότερες, εφαρμόζουμε ομοιόμορφη δειγματοληψία (uniform spread sampling) ώστε να αναπαραχθούν ακριβώς οι τομές που θέλουμε.

Με τον τρόπο αυτό επιτυγχάνουμε:

- Σταθερό αριθμό τομών ανά εξεταζόμενο (subject)
- Συγκρίσιμες 3D αναπαραστάσεις
- Αποφυγή εισαγωγής μεροληψίας (bias) λόγω μεταβλητού βάθους

4.2.3 Δημιουργία Διαφορετικών Διαγνωστικών Σεναρίων

Στη συνέχεια πραγματοποιούμε label remapping ώστε να υποστηρίξουμε πολλαπλά διαγνωστικά σενάρια, χωρίς να τροποποιούμε τα αρχικά δεδομένα.

Δημιουργούμε τρία βασικά σενάρια:

(α) 3-class σενάριο

- Non Demented
- Very Mild Dementia
- Mild + Moderate Dementia (συγχώνευση)

Η συγχώνευση Mild και Moderate πραγματοποιείται επειδή η κλάση Moderate διαθέτει εξαιρετικά μικρό αριθμό subjects, γεγονός που καθιστά την αυτόνομη εκπαίδευσή της στατιστικά ασταθή.

(β) Binary σενάριο

- Non Demented
- Demented (Very Mild + Mild + Moderate)

Το σενάριο αυτό χρησιμοποιείται κυρίως για το πρώτο στάδιο του ιεραρχικού ταξινομητή.

(γ) Dementia-only σενάριο

- Very Mild
- Mild
- Moderate

Αφαιρούμε πλήρως τους Non Demented subjects ώστε να μελετήσουμε αποκλειστικά την ενδο-κατηγορική διάκριση στα στάδια άνοιας.

4.2.4 Μετατροπή σε 3D Volumes(.npy)

Μετά την ενοποίηση του πλήθους των τομών σε σταθερό βάθος, προχωράμε στην ανακατασκευή ενός πλήρους τρισδιάστατου όγκου ανά εξεταζόμενο. Η διαδικασία αυτή είναι κρίσιμη, καθώς μετατρέπει ένα σύνολο ανεξάρτητων 2D εικόνων σε μία συνεκτική 3D αναπαράσταση, η οποία μπορεί να αξιοποιηθεί από δίκτυα τρισδιάστατης συνέλιξης (3D CNNs).

Για κάθε εξεταζόμενο (subject) φορτώνουμε τις επιλεγμένες grayscale τομές και τις ταξινομούμε βάσει του δείκτη θέσης τους κατά τον άξονα z. Η ταξινόμηση αυτή είναι απαραίτητη ώστε να διατηρηθεί η σωστή ανατομική συνέχεια του εγκεφάλου και να αποφευχθεί τυχόν αναστροφή ή ανακάτεμα τομών. Στη συνέχεια στοιβάζουμε τις εικόνες κατά τον άξονα βάθους και δημιουργούμε έναν τρισδιάστατο πίνακα μορφής (Z,H,W).

Παρότι το αρχικό βάθος είναι πλέον σταθερό, η χωρική ανάλυση κατά τους άξονες H και W ενδέχεται να παρουσιάζει μικρές διαφοροποιήσεις ή να μην είναι ιδανική για απευθείας χρήση σε προεκπαιδευμένα 3D δίκτυα. Για τον λόγο αυτό εφαρμόζουμε αναδειγματοληψία (resampling) ώστε κάθε όγκος να αποκτήσει τελικό σχήμα.

Η αναδειγματοληψία πραγματοποιείται με τριγραμμική παρεμβολή (trilinear interpolation), η οποία προσφέρει ομαλή μετάβαση τιμών χωρίς να εισάγει έντονες τεχνητές ακμές ή θόρυβο υψηλής συχνότητας. Η επιλογή του σχήματος αποτελεί συμβιβασμό μεταξύ χωρικής λεπτομέρειας και υπολογιστικού κόστους. Συγκεκριμένα, χρειάζεται το μέγεθος αυτού του σχήματος να είναι επαρκώς μεγάλο ώστε να διατηρεί

βασικά ανατομικά χαρακτηριστικά του εγκεφάλου και να είναι συμβατό με αρχιτεκτονικές όπως το MedicalNet και το Med3D, οι οποίες έχουν εκπαιδευτεί σε παρόμοια μεγέθη εισόδου.

Η διαδικασία αυτή δεν μεταβάλλει τις ετικέτες ούτε απορρίπτει δεδομένα. Αντιθέτως, επιτυγχάνει χωρική ενοποίηση του dataset, ώστε όλα τα subjects να εισέρχονται στο μοντέλο με ίδια δομή και διαστάσεις.

4.2.5 Προεπεξεργασία 3D όγκου και κανονικοποίηση εντάσεων

Μετά την ανακατασκευή και χωρική ενοποίηση των όγκων (volumes), εφαρμόζουμε επιπλέον προεπεξεργασία σε επίπεδο τρισδιάστατου όγκου. Η φάση αυτή στοχεύει στη βελτίωση της ποιότητας των δεδομένων, στη μείωση τεχνητών διαφορών μεταξύ εξετάσεων και στην ενίσχυση της στατιστικής σταθερότητας κατά την εκπαίδευση.

Αρχικά εφαρμόζουμε διαδικασία skull stripping, δηλαδή απομόνωσης του εγκεφαλικού ιστού από κρανιακές και εξωεγκεφαλικές δομές. Η αρχική εκτίμηση της μάσκας εγκεφάλου πραγματοποιείται μέσω Otsu thresholding επί του τρισδιάστατου όγκου. Η μέθοδος αυτή επιλέγεται διότι είναι μη παραμετρική και επιτρέπει αυτόματο διαχωρισμό μεταξύ περιοχών χαμηλής και υψηλής έντασης.

Στη συνέχεια βελτιώνουμε τη μάσκα με τρισδιάστατες μορφολογικές πράξεις. Εφαρμόζουμε binary closing για να καλύψουμε μικρά κενά, και binary opening για να αφαιρέσουμε θόρυβο. Από τα παραγόμενα διατηρούμε μόνο εκείνα των οποίων το μέγεθος υπερβαίνει το 15% του συνολικού όγκου, εξαλείφοντας έτσι μικρές απομονωμένες περιοχές που δεν αντιστοιχούν σε εγκεφαλικό ιστό. Έπειτα εφαρμόζουμε απλή προσέγγιση διόρθωσης ανομοιομορφίας πεδίου (bias-field correction). Εκτιμούμε τη χαμηλής συχνότητας μεταβολή έντασης. Η διαδικασία αυτή μειώνει σταδιακές μεταβολές φωτεινότητας που οφείλονται σε ιδιαιτερότητες του απεικονιστικού συστήματος και όχι στη δομή του εγκεφάλου.

Ακολουθεί ήπια εξομάλυνση (Gaussian smoothing), ώστε να περιοριστεί υψηλής συχνότητας θόρυβος χωρίς να χαθούν σημαντικές ανατομικές λεπτομέρειες.

Προτού πραγματοποιήσουμε κανονικοποίηση, περιορίζουμε τις τιμές έντασης, κάνοντας clipping, το οποίο αποτρέπει την επίδραση ακραίων τιμών (outliers) που θα μπορούσαν να αλλοιώσουν τον υπολογισμό της μέσης τιμής και της τυπικής απόκλισης.

Τέλος, εφαρμόζουμε z-score normalization εντός της μάσκας εγκεφάλου, δηλαδή μετασχηματίζουμε τις εντάσεις ώστε να έχουν μηδενική μέση τιμή και μοναδιαία τυπική απόκλιση, υπολογισμένες αποκλειστικά στο εγκεφαλικό τμήμα. Οι τιμές εκτός μάσκας μηδενίζονται. Με τον τρόπο αυτό εξασφαλίζουμε συγκρίσιμη κατανομή εντάσεων μεταξύ εξεταζόμενων (subjects), ενώ ταυτόχρονα αποτρέπουμε την εισαγωγή μη σχετικής πληροφορίας από το υπόβαθρο.

Επισημαίνουμε ότι σε κανένα στάδιο δεν τροποποιούμε τις ετικέτες ούτε απορρίπτουμε subjects λόγω έντασης ή μορφολογίας. Η προεπεξεργασία λειτουργεί αποκλειστικά ως μετασχηματισμός εισόδου, με στόχο τη βελτίωση της σταθερότητας και της γενικευσιμότητας των μοντέλων.

4.2.6 Στρωματοποιημένος Διαχωρισμός ανά Εξεταζόμενο

Μετά την ολοκλήρωση της ανακατασκευής και προεπεξεργασίας των τρισδιάστατων όγκων, προχωράμε στον διαχωρισμό του συνόλου δεδομένων σε υποσύνολα εκπαίδευσης (training), επικύρωσης (validation) και ελέγχου (test). Το στάδιο αυτό είναι

καθοριστικής σημασίας για την αξιόπιστη αξιολόγηση των μοντέλων και για την αποφυγή φαινομένων υπερεκπαίδευσης ή διαρροής πληροφορίας.

Η βασική μας επιλογή είναι να πραγματοποιήσουμε τον διαχωρισμό σε επίπεδο εξεταζόμενου (subject-level split) και όχι σε επίπεδο τομής (slice-level). Αυτό σημαίνει ότι όλες οι τομές και ο αντίστοιχος τρισδιάστατος όγκος ενός subject ανήκουν αποκλειστικά σε ένα από τα τρία σύνολα. Με τον τρόπο αυτό διασφαλίζουμε ότι το μοντέλο δεν βλέπει διαφορετικές τομές του ίδιου εγκεφάλου τόσο κατά την εκπαίδευση όσο και κατά την αξιολόγηση, αποφεύγοντας έτσι το φαινόμενο data leakage. Η επιλογή αυτή θεωρείται απαραίτητη σε ιατρικές εφαρμογές όπου η μονάδα ανάλυσης είναι ο ασθενής και όχι η μεμονωμένη εικόνα.

Συνολικά, ο subject-level διαχωρισμός αποτελεί βασικό πυλώνα της μεθοδολογίας μας, διασφαλίζοντας κλινικά έγκυρη αξιολόγηση και αποτρέποντας τεχνητή αύξηση της απόδοσης.

4.2.7 Τρισδιάστατο Data Augmentation στο Training Set

Στο πλαίσιο της ενίσχυσης της γενίκευσης των μοντέλων μας και της αντιμετώπισης της ανισορροπίας μεταξύ των κλάσεων, υλοποιήσαμε μηχανισμό offline data augmentation (αύξηση δεδομένων) σε επίπεδο τρισδιάστατου όγκου (3D volume). Η διαδικασία εφαρμόστηκε αυστηρά μετά τον subject-level διαχωρισμό των δεδομένων και αποκλειστικά στο σύνολο εκπαίδευσης (training set), ώστε να αποφευχθεί οποιαδήποτε μορφή διαρροής πληροφορίας (data leakage) προς τα σύνολα επικύρωσης (validation) και ελέγχου (test).

Η βασική λογική του μηχανισμού ήταν αρχικά ο εντοπισμός των εξεταζόμεων (subjects) που ανήκουν στο σύνολο εκπαίδευσης και η αντιγραφή των αντίστοιχων αρχικών προεπεξεργασμένων .npy όγκων σε ξεχωριστό φάκελο δεδομένων και στη συνέχεια η δημιουργία επιπλέον τεχνητών εκδόσεων ανά εξεταζόμενο (subject), έως ότου επιτευχθεί προκαθορισμένος στόχος πλήθους ανά κλάση (class balancing μέσω augmentation).

Οι μετασχηματισμοί που εφαρμόσαμε ήταν ήπιοι και ρεαλιστικοί, ώστε να διατηρείται η ανατομική εγκυρότητα του εγκεφαλικού όγκου.

Ωστόσο, μετά από πειραματική αξιολόγηση διαπιστώσαμε ότι η τελική απόδοση των μοντέλων δεν βελτιωνόταν ουσιαστικά με την προσθήκη τεχνητών (augmented) δεδομένων, ενώ αυξανόταν σημαντικά η πολυπλοκότητα της διαδικασίας και ο χρόνος εκπαίδευσης. Μετά από διερεύνηση της συμβολής του μηχανισμού, διαπιστώθηκε ότι δεν παρείχε ουσιαστική βελτίωση στη γενικευσιμότητα των μοντέλων, και συνεπώς δεν ενσωματώθηκε στο τελικό προτεινόμενο πλαίσιο.

Η ενότητα αυτή τεκμηριώνει τη μεθοδολογική μας διερεύνηση, ακόμη και σε περιπτώσεις όπου μια τεχνική δεν υιοθετήθηκε τελικά, στοιχείο κρίσιμο για την επιστημονική πληρότητα της εργασίας.

4.3 Εξαγωγή Χαρακτηριστικών με Προεκπαιδευμένα 3D Δίκτυα

Στο παρόν στάδιο της μεθοδολογίας δεν εκπαιδεύουμε εξαρχής βαθιά τρισδιάστατα νευρωνικά δίκτυα. Αντίθετα, αξιοποιούμε προεκπαιδευμένα 3D CNNs ως εξαγωγείς χαρακτηριστικών, με στόχο τη μετατροπή κάθε MRI όγκου σε μία αναπαράσταση (embedding), το οποίο στη συνέχεια τροφοδοτεί κλασικούς ταξινομητές μηχανικής μάθησης.

Η επιλογή αυτή βασίζεται σε δύο κύριες παρατηρήσεις. Πρώτον, τα διαθέσιμα ιατρικά δεδομένα είναι περιορισμένα για πλήρη εκπαίδευση από την αρχή μεγάλων 3D δικτύων χωρίς υπερπροσαρμογή. Δεύτερον, τα προεκπαιδευμένα μοντέλα έχουν ήδη μάθει γενικά ιατρικά χωρικά μοτίβα και μπορούν να λειτουργήσουν ως ισχυροί εξαγωγείς αναπαραστάσεων.

Η χρήση πολλαπλών συνελικτικών κορμών (backbones) επιτρέπει τη διερεύνηση συμπληρωματικών αναπαραστάσεων, καθώς διαφορετικά δίκτυα ενδέχεται να εστιάζουν σε διαφορετικά μορφολογικά χαρακτηριστικά.

Στην εργασία αξιοποιούμε τρία διαφορετικά 3D προεκπαιδευμένα μοντέλα:

- Med3D ResNet-18
- MedicalNet ResNet-50 (3D)
- Model Genesis

4.3.1 Εξαγωγή Χαρακτηριστικών με Med3D (ResNet – 18)

Για την πρώτη προσέγγιση χρησιμοποιούμε το προεκπαιδευμένο δίκτυο Med3D ResNet-18. Το δίκτυο έχει εκπαιδευτεί σε μεγάλο σύνολο ιατρικών δεδομένων και αποτελεί ελαφρύτερη αρχιτεκτονική σε σχέση με βαθύτερα μοντέλα. Στην υλοποίηση αφαιρούμε το τελικό πλήρως συνδεδεμένο επίπεδο ταξινόμησης (fully connected layer) και διατηρούμε μόνο τον συνελικτικό κορμό του δικτύου (convolutional backbone). Ακολουθεί υπολογισμός μέσης τιμής σε όλη τη χωρική διάσταση, ώστε να εξαχθεί διάνυσμα χαρακτηριστικών σταθερού μεγέθους συγκέντρωσης (global average pooling) για κάθε εξεταζόμενο.

4.3.2 Εξαγωγή Χαρακτηριστικών με MedicalNet(ResNet – 50 3D)

Στη δεύτερη προσέγγιση χρησιμοποιούμε το MedicalNet ResNet-50 (3D), το οποίο αποτελεί βαθύτερη αρχιτεκτονική και παράγει διανύσματα χαρακτηριστικών μεγαλύτερης διάστασης. Όπως και στην περίπτωση του Med3D, αφαιρούμε το τελικό επίπεδο ταξινόμησης και χρησιμοποιούμε το δίκτυο αποκλειστικά ως μηχανισμό εξαγωγής χαρακτηριστικών. Η μεγαλύτερη χωρητικότητα του ResNet-50 επιτρέπει την εξαγωγή πλουσιότερων αναπαραστάσεων, οι οποίες αξιοποιούνται στη συνέχεια από τους κλασικούς ταξινομητές.

4.3.3 Εξαγωγή Χαρακτηριστικών με Model Genesis

Στην τρίτη προσέγγιση αξιοποιούμε το προεκπαιδευμένο μοντέλο ModelGenesis, το οποίο έχει εκπαιδευτεί με αυτοεπιβλεπόμενη στρατηγική μάθησης (self-supervised) σε μεγάλο όγκο ιατρικών δεδομένων. Σε αντίθεση με τα Med3D και MedicalNet, τα οποία έχουν προεκπαιδευτεί με επιβλεπόμενη μάθηση, το ModelGenesis έχει μάθει αναπαραστάσεις μέσω προγνωστικών χωρικών μετασχηματισμών (proxy tasks), γεγονός που το καθιστά ιδιαίτερα κατάλληλο για μεταφορά γνώσης σε μικρά ιατρικά σύνολα δεδομένων (datasets).

Όπως και στις προηγούμενες περιπτώσεις, δεν πραγματοποιούμε ολική εκπαίδευση του δικτύου (end-to-end). Χρησιμοποιούμε το δίκτυο αποκλειστικά ως μηχανισμό εξαγωγής χαρακτηριστικών (feature extractor), διατηρώντας το προεκπαιδευμένο δίκτυο κορμού (backbone) και αφαιρώντας το τελικό επίπεδο ταξινόμησης (classification head)

4.4 Κανονικοποίηση και Μείωση Διάστασης των Χαρακτηριστικών

Η μετατροπή των εξαγόμενων αναπαραστάσεων (embeddings) σε τελικούς πίνακες εκπαίδευσης κρίθηκε απαραίτητη προκειμένου τα παραγόμενα χαρακτηριστικά να καταστούν άμεσα αξιοποιήσιμα από τους κλασικούς αλγορίθμους μηχανικής μάθησης. Τα προεκπαιδευμένα τρισδιάστατα δίκτυα (MedicalNet, Med3D και ModelGenesis) λειτουργούν ως μηχανισμοί εξαγωγής αναπαραστάσεων υψηλού επιπέδου, ωστόσο οι ταξινομητές όπως SVM, Logistic Regression και Random Forest απαιτούν δομημένα δισδιάστατα δεδομένα μορφής $(N \times D)$, όπου Nείναι ο αριθμός των δειγμάτων και D η διάσταση του διανύσματος χαρακτηριστικών.

Μετά τη δημιουργία των τελικών πινάκων εκπαίδευσης, εφαρμόστηκε διαδικασία κανονικοποίησης των χαρακτηριστικών με χρήση της μεθόδου StandardScaler. Η κανονικοποίηση πραγματοποιήθηκε αποκλειστικά με βάση τα δεδομένα του συνόλου εκπαίδευσης (train set), και στη συνέχεια οι ίδιοι παράμετροι μετασχηματισμού εφαρμόστηκαν στα σύνολα επικύρωσης και ελέγχου (validation και test), ώστε να αποφευχθεί η διαρροή πληροφορίας.

Η κανονικοποίηση ήταν απαραίτητη λόγω του μεγάλου μεγέθους των παραγόμενων αναπαραστάσεων, καθώς και της διαφορετικής κλίμακας τιμών που προκύπτει από τα προεκπαιδευμένα δίκτυα. Με τον τρόπο αυτό διασφαλίστηκε ότι κάθε διάσταση του διανύσματος χαρακτηριστικών συνεισφέρει ισόρροπα στη διαδικασία εκπαίδευσης των ταξινομητών.

Επιπλέον, σε ορισμένα σενάρια εφαρμόζεται μείωση διαστασιμότητας μέσω της Ανάλυσης Κύριων Συνιστωσών (Principal Component Analysis – PCA). Η εκπαίδευση του PCA πραγματοποιήθηκε επίσης αποκλειστικά στο σύνολο εκπαίδευσης και ο ίδιος μετασχηματισμός εφαρμόστηκε στα validation και test σύνολα. Η επιλογή του αριθμού των συνιστωσών έγινε με στόχο τη διατήρηση του μεγαλύτερου δυνατού ποσοστού διακύμανσης, μειώνοντας παράλληλα την πολυπλοκότητα του προβλήματος.

Η εφαρμογή της PCA εξυπηρέτησε δύο βασικούς σκοπούς:

- Μείωση του υπολογιστικού κόστους κατά την εκπαίδευση των ταξινομητών.
- Περιορισμό του κινδύνου υπερπροσαρμογής (overfitting), ιδίως σε σενάρια με σχετικά περιορισμένο αριθμό εξεταζομένων.

4.5 Εκπαίδευση Κλασσικών Ταξινομητών

Μετά την ολοκλήρωση της διαδικασίας εξαγωγής χαρακτηριστικών, κανονικοποίησης και μείωσης διαστάσεων, τα τελικά διανύσματα χαρακτηριστικών χρησιμοποιήθηκαν για την εκπαίδευση κλασικών αλγορίθμων μηχανικής μάθησης.

Σημαντικό στοιχείο της μεθοδολογίας αποτέλεσε η συνεπής χρήση όλων των διαθέσιμων συνόλων δεδομένων και όλων των διαγνωστικών σεναρίων σε κάθε πειραματική ρύθμιση.

Συγκεκριμένα, κάθε ταξινομητής εκπαιδεύτηκε και αξιολογήθηκε:

- Στο δυαδικό σενάριο (Demented vs Non-Demented)
- Στο σενάριο κατηγοριοποίησης βαθμού άνοιας
- Στο σενάριο τριών κατηγοριών
- Στο ιεραρχικό σενάριο ταξινόμησης

Αξιοποιήσαμε ευρύ φάσμα μοντέλων μηχανικής μάθησης, όπου περιλαμβάνονται γραμμικοί και μη γραμμικοί ταξινομητές, ensemble μέθοδοι καθώς και πολυεπίπεδα νευρωνικά δίκτυα.

Η ίδια πειραματική διαδικασία εφαρμόστηκε με συνεπή τρόπο σε όλα τα σύνολα χαρακτηριστικών που παρήχθησαν από τα διαφορετικά προεκπαιδευμένα δίκτυα, επιτρέποντας τη συστηματική σύγκριση τόσο μεταξύ ταξινομητών όσο και μεταξύ πηγών χαρακτηριστικών.

4.6 Συνδυασμός Πληροφοριών και Μοντέλων (Fusion Strategies)

Το σενάριο τριών κλάσεων αποτελεί αυξημένης δυσκολίας πρόβλημα, λόγω της αλληλοεπικάλυψης μεταξύ πρώιμων σταδίων και της ανισορροπίας των κλάσεων. Για τον λόγο αυτό υιοθετήθηκαν πολλαπλές τεχνικές fusion, με στόχο την αξιοποίηση της συμπληρωματικής πληροφορίας που προκύπτει από τα διαφορετικά προεκπαιδευμένα δίκτυα (Med3D, ModelGenesis, MedicalNet) και τις διαφορετικές ταξινομητικές αρχιτεκτονικές. Η βασική υπόθεση είναι ότι κάθε προεκπαιδευμένο μοντέλο εξάγει διαφορετικού τύπου αναπαραστάσεις και συνεπώς ο κατάλληλος συνδυασμός τους μπορεί να βελτιώσει τη σταθερότητα και τη γενικευσιμότητα της τελικής πρόβλεψης.

Στην παρούσα εργασία διερευνώνται τόσο early και mid fusion στρατηγικές σε επίπεδο χαρακτηριστικών, όσο και late fusion και stacking προσεγγίσεις σε επίπεδο προβλέψεων. Η επιλογή της κάθε στρατηγικής βασίζεται στη διαφορετική φιλοσοφία συνδυασμού.

Η early fusion βασίζεται στη συνένωση χαρακτηριστικών πριν την εκπαίδευση του ταξινομητή, ενώ η late fusion συνδυάζει τις προβλέψεις διαφορετικών μοντέλων σε επίπεδο απόφασης. Επιπλέον, η προσέγγιση stacking αξιοποιεί τις πιθανότητες πρόβλεψης πολλαπλών μοντέλων ως μετα-χαρακτηριστικά για έναν δευτερογενή ταξινομητή.

Ιδιαίτερα στο σενάριο των τριών κλάσεων όπως αναφέρθηκε, όπου η απόδοση των μεμονωμένων μοντέλων δεν ήταν ικανοποιητική, οι fusion τεχνικές χρησιμοποιήθηκαν ως μηχανισμοί ενίσχυσης της διακριτικής ικανότητας του συστήματος.

4.6.1 Early Fusion

4.6.1.1 2-way early fusion

Στην τεχνική 2-way early fusion πραγματοποιήθηκε πρώιμη συγχώνευση των χαρακτηριστικών που εξήχθησαν από τα προεκπαιδευμένα δίκτυα Med3D και ModelGenesis. Συγκεκριμένα, οι αναπαραστάσεις (embeddings) των δύο δικτύων ενοποιήθηκαν μέσω οριζόντιας συνένωσης (feature concatenation), δημιουργώντας ένα ενιαίο διάνυσμα αναπαράστασης για κάθε εξεταζόμενο άτομο. Η προσέγγιση αυτή επιτρέπει στο μοντέλο να αξιοποιήσει συμπληρωματική πληροφορία από δύο διαφορετικά προεκπαιδευμένα 3D backbones πριν το στάδιο ταξινόμησης.

Τα συγχωνευμένα χαρακτηριστικά κανονικοποιήθηκαν με StandardScaler, ο οποίος προσαρμόστηκε αποκλειστικά στα δεδομένα εκπαίδευσης ώστε να αποφευχθεί διαρροή πληροφορίας. Σε μία παραλλαγή εφαρμόστηκε επιπλέον PCA, περιορίζοντας τη διάσταση σε ασφαλές όριο με στόχο:

- τη μείωση θορύβου,
- τον περιορισμό υπερπροσαρμογής,
- τη βελτίωση της σταθερότητας των πυρηνικών μοντέλων.

4.6.1.2 3-way early fusion

Στην 3-way early fusion πραγματοποιήθηκε πρώιμη συγχώνευση των embeddings από τα τρία προεκπαιδευμένα δίκτυα Med3D, ModelGenesis και MedicalNet. Για κάθε εξεταζόμενο άτομο, τα αντίστοιχα διανύσματα χαρακτηριστικών ευθυγραμμίστηκαν και συνενώθηκαν οριζόντια, δημιουργώντας ένα ενιαίο υψηλής διάστασης διάνυσμα αναπαράστασης.

Η 3-way συγχώνευση στοχεύει στην ενίσχυση της αναπαράστασης μέσω συνδυασμού συμπληρωματικών χωρικών και μορφολογικών χαρακτηριστικών που μαθαίνουν διαφορετικά pretraining σχήματα. Ωστόσο, η αύξηση της διάστασης εισάγει μεγαλύτερο κίνδυνο υπερπροσαρμογής, γεγονός που καθιστά κρίσιμη την κατάλληλη κανονικοποίηση και επιλογή ταξινομητή στο επόμενο στάδιο.

4.6.2 Mid- Level Fusion

Στην τεχνική mid-level fusion πραγματοποιήθηκε συγχώνευση των αναπαραστάσεων (embeddings) των Med3D και ModelGenesis μετά την εξαγωγή χαρακτηριστικών αλλά πριν την τελική απόφαση, μέσω οριζόντιας συνένωσης των διανυσμάτων ανά split (train/val/test). Σε αντίθεση με το late fusion, ο συνδυασμός γίνεται σε επίπεδο αναπαράστασης και όχι σε επίπεδο πιθανοτήτων.

Τα συγχωνευμένα χαρακτηριστικά κανονικοποιήθηκαν με StandardScaler, ώστε να εξισορροπηθούν οι διαφορετικές κλίμακες των embeddings.

4.6.3 Late Fusion

Στην προσέγγιση late fusion ο συνδυασμός των μοντέλων πραγματοποιείται σε επίπεδο απόφασης και όχι σε επίπεδο χαρακτηριστικών. Συγκεκριμένα, κάθε προεκπαιδευμένο μοντέλο εκπαιδεύεται ανεξάρτητα και παράγει πιθανότητες κλάσεων (class probabilities), οι οποίες στη συνέχεια συνδυάζονται μέσω σταθμισμένου μέσου όρου.

Στην παρούσα εργασία χρησιμοποιήθηκαν τα Med3D και Model Genesis.

Το MedicalNet δεν συμπεριλήφθηκε στο late fusion, καθώς παρουσίασε χαμηλότερη απόδοση στο 3-class σενάριο και η ένταξή του μείωνε τη συνολική επίδοση του συνδυασμού.

Η late fusion παρουσιάζει πλεονέκτημα έναντι της early fusion όταν οι αναπαραστάσεις (embeddings) έχουν διαφορετική κατανομή ή όταν ένα backbone είναι σαφώς ισχυρότερο. Παράλληλα, αποφεύγεται η αύξηση της διάστασης του χώρου χαρακτηριστικών, περιορίζοντας τον κίνδυνο υπερπροσαρμογής.

4.6.4 Stacking

Στην τεχνική stacking εφαρμόστηκε ιεραρχικός συνδυασμός των δύο ετερογενών μοντέλων Med3d και Model Genesis.

Σε αντίθεση με το late soft voting, όπου οι πιθανότητες συνδυάζονται γραμμικά, στο stacking οι πιθανότητες κάθε μοντέλου χρησιμοποιούνται ως νέα χαρακτηριστικά (meta-features) για έναν δευτερογενή ταξινομητή.

Το stacking επιτρέπει στο meta-model να μάθει μη γραμμικούς συνδυασμούς μεταξύ των δύο base predictors, αξιοποιώντας περιπτώσεις όπου τα μοντέλα κάνουν διαφορετικά σφάλματα. Έτσι, η τελική απόφαση μαθαίνεται προσαρμοστικά.

Η προσέγγιση αυτή είναι πιο εκφραστική από το απλό late fusion και στοχεύει ειδικά στη βελτίωση της απόδοσης στο 3-class σενάριο, όπου οι διαχωριστικές επιφάνειες είναι πιο πολύπλοκες.

4.7 Ιεραρχικός Ταξινομητής

Η απευθείας 3-class ταξινόμηση της άνοιας (Non-Demented / Very Mild / Mild–Moderate) παρουσίασε περιορισμένη απόδοση, κυρίως λόγω της υψηλής αλληλοεπικάλυψης μεταξύ των πρώιμων σταδίων και της ανισορροπίας των κλάσεων. Για την αντιμετώπιση αυτών των δυσκολιών υιοθετήθηκε μια ιεραρχική προσέγγιση δύο σταδίων, η οποία διασπά το αρχικό πρόβλημα σε δύο διαδοχικά και απλούστερα υποπροβλήματα.

Η βασική φιλοσοφία της μεθόδου είναι ότι η ανίχνευση ύπαρξης άνοιας αποτελεί διαφορετικό και εννοιολογικά ευκολότερο πρόβλημα από την εκτίμηση της βαρύτητάς της. Συνεπώς, αντί να επιχειρείται μία ενιαία απόφαση, το σύστημα πρώτα αποφασίζει αν το άτομο είναι υγιές ή παρουσιάζει άνοια, και στη συνέχεια – μόνο εφόσον ανιχνευθεί άνοια – εκτιμά το στάδιο της νόσου.

Στο πρώτο στάδιο (Stage-1) υλοποιείται δυαδική ταξινόμηση μεταξύ Non-Demented και Demented. Το αποτέλεσμα του Stage-1 αποτελεί φίλτρο όπου εάν το δείγμα ταξινομηθεί ως Non-Demented, η διαδικασία τερματίζεται.

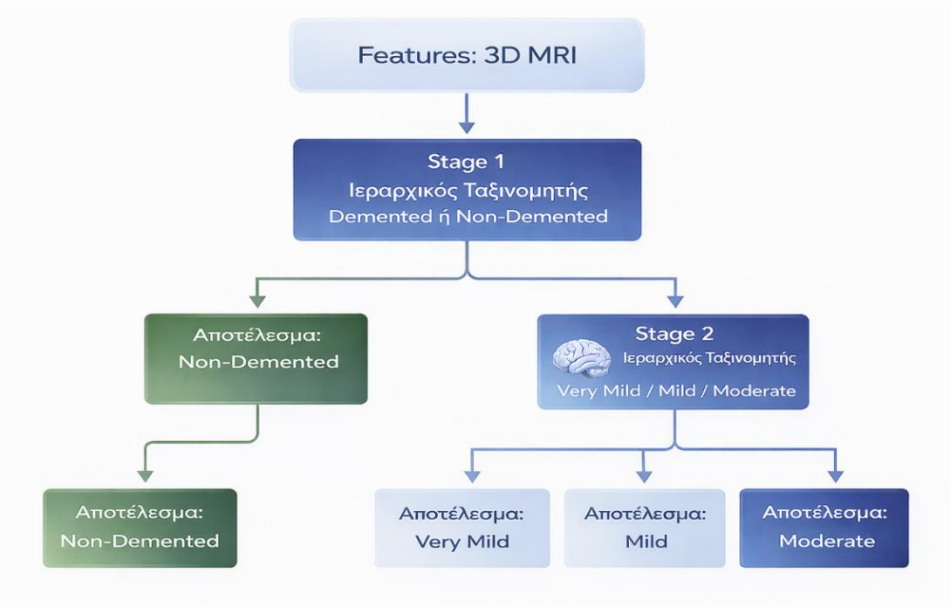
Στο δεύτερο στάδιο (Stage-2) γίνεται εκτίμηση βαρύτητας μόνο για τα δείγματα που χαρακτηρίστηκαν ως Demented. Η διαίρεση σε train/val/test πραγματοποιείται σε επίπεδο subject με στρωματοποιημένη δειγματοληψία, ώστε να αποφευχθεί διαρροή πληροφορίας μεταξύ ατόμων.

Κατά την ιεραρχική εξαγωγή συμπερασμάτων, κάθε δείγμα περνά πρώτα από το Stage-1. Εάν προβλεφθεί ως Non-Demented, η τελική κλάση είναι 0. Εάν προβλεφθεί ως Demented, ενεργοποιείται το Stage-2, το οποίο αποδίδει Very Mild ή Mild ή Moderate. Η πρόβλεψη του Stage-2 επαναχαρτογραφείται στον αρχικό 3-class χώρο με μετατόπιση των ετικετών.

Η ιεραρχική προσέγγιση βασίζεται στη μείωση της πολυπλοκότητας της απόφασης. Αντί για ένα ενιαίο 3-class, το σύστημα μαθαίνει δύο απλούστερα δυαδικά. Έτσι μειώνεται η σύγχυση μεταξύ γειτονικών σταδίων και βελτιώνεται η σταθερότητα της συνολικής απόδοσης. Επιπλέον, η αρχιτεκτονική είναι αρθρωτή, επιτρέποντας ανεξάρτητη βελτίωση κάθε σταδίου.

Ωστόσο, το σύστημα παρουσιάζει και περιορισμούς. Σφάλματα στο Stage-1 δεν μπορούν να διορθωθούν στο Stage-2, καθώς ένα λανθασμένο αρχικό φιλτράρισμα αποκλείει το δείγμα από περαιτέρω ανάλυση. Επιπλέον, η μεθοδολογία απαιτεί αυστηρή αντιστοίχιση subject-level δεδομένων μεταξύ των δύο σταδίων ώστε να αποφεύγεται ασυμφωνία ετικετών.

Συνολικά, ο ιεραρχικός ταξινομητής αποτελεί μια δομημένη προσέγγιση που επιχειρεί να εκμεταλλευτεί τη φυσική ιεραρχία του προβλήματος, μετατρέποντας ένα δύσκολο πολυκλασικό πρόβλημα σε ακολουθία ελεγχόμενων δυαδικών αποφάσεων.



Εικόνα 2.Αρχιτεκτονική του ιεραρχικού συστήματος ταξινόμησης δύο σταδίων για την εκτίμηση παρουσίας και βαθμού άνοιας.

Κεφάλαιο 5. Πειραματική Υλοποίηση και Αποτελέσματα

5.1 Πειραματικό Περιβάλλον

Στην παρούσα ενότητα περιγράφεται το υπολογιστικό και λογισμικό περιβάλλον εντός του οποίου υλοποιήθηκαν τα πειράματα της εργασίας. Η σαφής τεκμηρίωση του πειραματικού πλαισίου είναι κρίσιμη για τη διασφάλιση της αναπαραγωγιμότητας και της αξιοπιστίας των αποτελεσμάτων.
Η υλοποίηση πραγματοποιήθηκε σε περιβάλλον Windows, με χρήση της γλώσσας προγραμματισμού Python.
Για την επεξεργασία των δεδομένων και τη διαχείριση πινάκων χρησιμοποιήθηκαν οι βιβλιοθήκες NumPy και Pandas, ενώ για τη φόρτωση και αποθήκευση των τρισδιάστατων όγκων χρησιμοποιήθηκε μορφή αρχείων .npy, η οποία επιτρέπει αποδοτική αποθήκευση και γρήγορη ανάγνωση δεδομένων.
Η εξαγωγή χαρακτηριστικών από τα προεκπαιδευμένα τρισδιάστατα συνελικτικά δίκτυα (Med3D, MedicalNet και ModelGenesis) υλοποιήθηκε με χρήση της βιβλιοθήκης PyTorch.
Για την εκπαίδευση και αξιολόγηση των κλασικών αλγορίθμων μηχανικής μάθησης (SVM, Logistic Regression, Random Forest, Gradient Boosting, MLP) χρησιμοποιήθηκε η βιβλιοθήκη scikit-learn. Οι διαδικασίες κανονικοποίησης χαρακτηριστικών και μείωσης διαστασιμότητας (StandardScaler και Ανάλυση Κύριων Συνιστωσών – PCA) εφαρμόστηκαν επίσης μέσω scikit-learn, με προσαρμογή αποκλειστικά στο σύνολο εκπαίδευσης.
Τέλος, για την οπτικοποίηση των αποτελεσμάτων χρησιμοποιήθηκαν οι βιβλιοθήκες Matplotlib και Plotly, οι οποίες επέτρεψαν την παραγωγή διαγραμμάτων σύγχυσης, καμπυλών ROC και τρισδιάστατων αναπαραστάσεων των όγκων.

5.2 Πειραματικό Πρωτόκολλο

Η διαδικασία σχεδιάστηκε με στόχο τη δίκαιη σύγκριση μεταξύ μοντέλων και τη διασφάλιση της γενικευσιμότητας των αποτελεσμάτων.

5.2.1 Διαχωρισμός Δεδομένων

Ο διαχωρισμός του συνόλου δεδομένων πραγματοποιήθηκε σε επίπεδο εξεταζόμενου ώστε όλες οι τομές και ο αντίστοιχος τρισδιάστατος όγκος κάθε ατόμου να ανήκουν αποκλειστικά σε ένα υποσύνολο. Το σύνολο χωρίστηκε σε:

- Σύνολο εκπαίδευσης (training set)
- Σύνολο επικύρωσης (validation set)
- Σύνολο ελέγχου (test set)

Ο διαχωρισμός πραγματοποιήθηκε με στρωματοποιημένη δειγματοληψία ως προς την κλάση, ώστε να διατηρείται η αναλογία των κατηγοριών σε κάθε υποσύνολο. Η επιλογή subject – level split αποτρέπει φαινόμενα διαρροής πληροφορίας, τα οποία θα μπορούσαν να οδηγήσουν σε τεχνητά αυξημένες επιδόσεις.

5.2.2 Κανονικοποίηση και Μείωση Μεγέθους Διανυσμάτων

Τα διανύσματα χαρακτηριστικών που εξήχθησαν από τα προεκπαιδευμένα δίκτυα υποβλήθηκαν σε κανονικοποίηση με χρήση της μεθόδου τυποποίησης. Οι παράμετροι κανονικοποίησης υπολογίστηκαν αποκλειστικά στο σύνολο εκπαίδευσης και εφαρμόστηκαν αυτούσιοι στα σύνολα επικύρωσης και ελέγχου.

Σε επιλεγμένα σενάρια εφαρμόστηκε μείωση διάστασης μέσω Ανάλυσης Κύριων Συνιστωσών.

5.2.3 Εκπαίδευση Ταξινομητών

Για κάθε σύνολο χαρακτηριστικών (Med3D, MedicalNet, ModelGenesis, καθώς και τα σενάρια συγχώνευσης), εκπαιδεύτηκαν διαφορετικοί αλγόριθμοι μηχανικής μάθησης. Η διαδικασία περιλάμβανε ρύθμιση υπερπαραμέτρων μέσω αναζήτησης πλέγματος (grid search) στο σύνολο εκπαίδευσης, με αξιολόγηση στο σύνολο επικύρωσης.

Οι υπερπαράμετροι που εξετάστηκαν περιλάμβαναν,ενδεικτικά:

- Παράμετρο κανονικοποίησης C για τον SVM
- Πυρήνα και παραμέτρους πυρήνα (όπου εφαρμόζεται)
- Αριθμό δέντρων και βάθος για τα μοντέλα ensemble
- Ρυθμό μάθησης και αριθμό κρυφών μονάδων για το MLP

Η τελική επιλογή μοντέλου βασίστηκε στην επίδοση στο σύνολο επικύρωσης, ενώ η τελική αξιολόγηση πραγματοποιήθηκε αποκλειστικά στο σύνολο ελέγχου.

5.2.4 Σενάρια Αξιολόγησης

Η παραπάνω διαδικασία εφαρμόστηκε στα ακόλουθα διαγνωστικά σενάρια:

- Δυαδική ταξινόμηση (Non-Demented έναντι Demented)
- Ταξινόμηση τριών κατηγοριών
- Ταξινόμηση βαθμού άνοιας
- Ιεραρχική ταξινόμηση δύο σταδίων

Κάθε σενάριο αξιολογήθηκε ανεξάρτητα, ακολουθώντας την ίδια πειραματική διαδικασία.

5.2.5 Μετρικές Αξιολόγησης

Η αξιολόγηση των μοντέλων βασίστηκε σε μετρικές που λαμβάνουν υπόψη την ανισορροπία των κατηγοριών. Συγκεκριμένα χρησιμοποιήθηκαν:

- Accuracy
- Precision
- Recall
- F1-score (macro και weighted)
- Καμπύλη ROC και εμβαδόν κάτω από την καμπύλη (AUC), όπου εφαρμόζεται

5.3 Αποτελέσματα Βασικών Ταξινομητών

Στο παρόν κεφάλαιο παρουσιάζονται τα πειραματικά αποτελέσματα των προτεινόμενων μεθοδολογιών. Για την αξιολόγηση των μοντέλων χρησιμοποιήθηκαν οι μετρικές Accuracy, Balanced Accuracy, Precision, Recall και F1-score. Ιδιαίτερη έμφαση δόθηκε στη μετρική Macro F1-score, καθώς το πρόβλημα χαρακτηρίζεται από

ανισορροπία κλάσεων και πολυκατηγορική ταξινόμηση, όπου η ισότιμη αξιολόγηση όλων των διαγνωστικών κατηγοριών είναι κρίσιμη. Η Macro F1 επιλέχθηκε ως κύρια μετρική σύγκρισης, διότι συνδυάζει precision και recall ανά κλάση χωρίς να επηρεάζεται από το πλήθος των δειγμάτων κάθε κατηγορίας.

Για κάθε ταξινομητή παρατίθεται συγκεντρωτικός πίνακας με τις βέλτιστες επιδόσεις ανά σύνολο χαρακτηριστικών (STD/PCA) και διαγνωστικό σενάριο (binary, dementia severity, 3-class). Αναλυτική παρουσίαση όλων των μετρικών πραγματοποιείται μόνο για το συνολικά βέλτιστο μοντέλο ανά διαγνωστικό σενάριο.

5.3.1 Αποτελέσματα Δυαδικής Ταξινόμησης

- **AdaBoost με Decision Tree**

Πίνακας 1.Συγκεντρωτικά αποτελέσματα επιδόσεων (Macro-F1) για τα διαφορετικά σενάρια και σύνολα χαρακτηριστικών.

Feature Set	Diagnostic Scenario	Macro-F1 score	
Med3D_std	Binary	0.534	Depth = 1
Med3D_pca	Binary	0.607	Depth = 3
Medicalnet_std	Binary	0.566	Depth = 3
Medicalnet_pca	Binary	0.532	Depth = 3
Model Genesis_std	Binary	0.653	Depth = 3

- **Bagging Linear SVM**

Πίνακας 2.Αποτελέσματα της δυαδικής ταξινόμησης με τη μέθοδο Bagging Linear SVM.

Feature Set	Diagnostic Scenario	Macro – F1 score
Medicalnet_std	Binary	0.665
Medicalnet_pca	Binary	0.618
Med3D_std	Binary	0.600
Med3d_pca	Binary	0.590
Model Genesis_pca	Binary	0.721
Model Genesis_std	Binary	0.770

- **Linear SVC**

Πίνακας 3.Αποτελέσματα της δυαδικής ταξινόμησης με τον ταξινομητή Linear SVC.

Feature Set	Diagnostic Scenario	Macro -F1 score
Model Genesis_pca	Binary	0.7455
Model Genesis_std	Binary	0.697
Med3d_pca	Binary	0.5516
Med3D_std	Binary	0.6267
Medicalnet_pca	Binary	0.6655
Medicalnet_std	Binary	0.5816

- **Logistic Regression**

Πίνακας 4.Αποτελέσματα της δυαδικής ταξινόμησης με το μοντέλο Λογιστικής Παλινδρόμησης (Logistic Regression).

Feature Set	Diagnostic Scenario	Macro-F1 score
Model Genesis_pca	Binary	0.541
Model Genesis_std	Binary	0.589

- **LVQ**

Πίνακας 5.Αποτελέσματα της δυαδικής ταξινόμησης με τη μέθοδο LVQ..

Feature Set	Diagnostic Scenario	Macro-F1 score
Model Genesis_pca	Binary	0.592
Model Genesis_std	Binary	0.562
Med3D_pca	Binary	0.560
Med3D_std	Binary	0.560
Medicalnet_pca	Binary	0.592
Medicalnet_std	Binary	0.604

- **MLP**

Πίνακας 6.Αποτελέσματα της δυαδικής ταξινόμησης με το Νευρωνικό Δίκτυο MLP.

Feature Set	Diagnostic Scenario	Macro-F1 score
Model Genesis_pca	Binary	0.7608
Model Genesis_std	Binary	0.8245
Med3D_pca	Binary	0.6790
Med3D_std	Binary	0.7512
Medicalnet_pca	Binary	0.7201
Medicalnet_std	Binary	0.7348

- **SVM**

Πίνακας 7.Αποτελέσματα της δυαδικής ταξινόμησης με SVM για διαφορετικές συναρτήσεις πυρήνα (Linear, RBF, Cosine).

Feature Set	Diagnostic Scenario	Macro -F1 score		
		Linear	RBF	Cosine
Model Genesis_pca	Binary	0.6767	0.6669	0.6754
Model Genesis_std	Binary	0.6577	0.6829	0.7037
Med3D_pca	Binary	0.6845	0.6282	0.6941
Med3D_std	Binary	0.6783	0.6358	0.6801
Medicalnet_pca	Binary	0.5727	0.5874	0.5874
Medicalnet_std	Binary	0.6736	0.6199	0.6416

Στο δυαδικό σενάριο παρατηρείται σαφής υπεροχή των χαρακτηριστικών που εξήχθησαν από το ModelGenesis, ανεξαρτήτως ταξινομητή.

Η υψηλότερη επίδοση καταγράφηκε με:

- MLP (ModelGenesis_std) όπου macro-F1 = 0.8245
- Bagging Linear SVM (ModelGenesis_std) όπου macro-F1 = 0.770

Τα χαρακτηριστικά MedicalNet παρουσίασαν χαμηλότερες επιδόσεις στο συγκεκριμένο σενάριο.

Τα αποτελέσματα υποδηλώνουν ότι το ModelGenesis pretraining αποτυπώνει αποτελεσματικά τα μορφολογικά μοτίβα που διαφοροποιούν υγιή από παθολογικά υποκείμενα. Η σταθερή υπεροχή του τόσο σε γραμμικούς (SVM) όσο και σε μη γραμμικούς (MLP, ensemble) ταξινομητές υποδεικνύει υψηλή εγγενή διαχωρισιμότητα των αναπαραστάσεων (embeddings).

Τα Med3D embeddings εμφανίζουν σταθερή αλλά ελαφρώς χαμηλότερη απόδοση, ενώ τα MedicalNet δεν φαίνεται να προσφέρουν πρόσθετη πληροφορία στο απλό binary πρόβλημα.

Συμπερασματικά, στο πρόβλημα ανίχνευσης ύπαρξης άνοιας, τα χαρακτηριστικά ModelGenesis αποτελούν την καταλληλότερη αναπαράσταση.

5.3.2 Αποτελέσματα Ταξινόμησης Βαρύτητας Άνοιας

- **KNN**

Πίνακας 8.Αποτελέσματα ταξινόμησης της βαρύτητας της άνοιας για τα μοντέλο KNN.

Feature Set	Diagnostic Scenario	Macro-F1 score
Med3D_pca	Dementia	0.551

- **MLP**

Πίνακας 9.Αποτελέσματα ταξινόμησης της βαρύτητας της άνοιας για τα μοντέλο MLP.

Feature Set	Diagnostic Scenario	Macro-F1 score
Medicalnet_pca	Dementia	0.7424
Medicalnet_std	Dementia	0.6970
Med3D_pca	Dementia	0.5692
Med3D_std	Dementia	0.750

- **SVM**

Πίνακας 10.Αποτελέσματα ταξινόμησης της βαρύτητας της άνοιας για τα μοντέλο SVM.

Feature Set	Diagnostic Scenario	Macro -F1 score		
		Linear	RBF	Cosine
Model Genesis_std	Dementia	0.5617	05324	0.5388
Model Genesis_pca	Dementia	0.5263	0.5541	0.6231

Στο σενάριο εκτίμησης βαρύτητας η καλύτερη επίδοση καταγράφηκε με:

- SVM (ME3D_std) όπου macro-F1 = 0.750

Σε αντίθεση με το δυαδικό σενάριο, εδώ τα χαρακτηριστικά Med3D υπερέχουν σημαντικά. Η επίδοση 0.750 υποδηλώνει ότι τα Med3D embeddings αποτυπώνουν με μεγαλύτερη λεπτομέρεια τις σταδιακές μορφολογικές μεταβολές που σχετίζονται με την εξέλιξη της νόσου.

Η διαφοροποίηση αυτή ενισχύει τη θεωρητική υπόθεση ότι διαφορετικά pretraining σχήματα μαθαίνουν συμπληρωματικού τύπου αναπαραστάσεις:

- ModelGenesis → ισχυρό στη διάκριση υγιούς/παθολογικού
- Med3D → ισχυρό στη διάκριση βαθμού παθολογίας

Η παρατήρηση αυτή αποτέλεσε κρίσιμο στοιχείο στον σχεδιασμό των fusion στρατηγικών.

5.3.3 Αποτελέσματα Πολυταξικής Ταξινόμησης (3 Κατηγοριών)

- **Logistic Regression**

Πίνακας 11.Συγκεντρωτικά αποτελέσματα της πολυταξικής ταξινόμησης για το μοντέλο Logistic Regression.

Feature Set	Diagnostic Scenario	Macro-F1 score
Med3D	3-class	0.575

- **MLP**

Πίνακας 12.Συγκεντρωτικά αποτελέσματα της πολυταξικής ταξινόμησης για το μοντέλο MLP.

Feature Set	Diagnostic Scenario	Macro-F1 score
Med3D_pca	3-class	0.5692
Med3D_std	3-class	0.5626
Model Genesis_pca	3-class	0.5225
Model Genesis_std	3-class	0.286

- **Gradient Boosting**

Πίνακας 13.Συγκεντρωτικά αποτελέσματα της πολυταξικής ταξινόμησης για το μοντέλο Gradient Boosting.

Feature Set	Diagnostic Scenario	Macro-F1 score
Med3D_pca/std	3-class	0.6325

Στο πολυταξικό σενάριο παρατηρείται γενικευμένη μείωση της απόδοσης.

Η καλύτερη απόδοση καταγράφηκε για:

- Gradient Boosting (Med3D_pca/std) όπου macro – F1 = 0.6325

Η σημαντική πτώση της Macro-F1 (0.55–0.63) επιβεβαιώνει τη δυσκολία διάκρισης μεταξύ γειτονικών σταδίων άνοιας. Η αλληλοεπικάλυψη χαρακτηριστικών μεταξύ Very Mild και Mild–Moderate οδηγεί σε αυξημένη σύγχυση, ιδιαίτερα στις ενδιάμεσες κλάσεις.

Το εύρημα αυτό κατέδειξε ότι:

- Η απευθείας 3-class εκπαίδευση δεν επαρκεί.
- Απαιτούνται στρατηγικές συνδυασμού πληροφορίας ή ιεραρχική διάσπαση του προβλήματος.

5.4 Αποτελέσματα Τεχνικών Fusion

5.4.1 Late Fusion Level

Πίνακας 14.Αποτελέσματα επιδόσεων με τη χρήση τεχνικών Late Fusion (Soft και Weighted).

Feature Set	Diagnostic Scenario	Macro-F1 score	Weights
Med3D_std+ ModelGenesis_pca	3-class	0.6372	Soft (0.5/0.5)
Med3D_std+ ModelGenesis_pca	3-class	0.6740	Weighted(0.7/0.3)

Η σταθμισμένη late fusion (70/30 υπέρ Med3D) βελτιώνει τη μέση επίδοση σε 0.6740, υπερβαίνοντας τις μεμονωμένες προσεγγίσεις. Το αποτέλεσμα αυτό υποδηλώνει ότι τα δύο backbones παράγουν συμπληρωματικά σφάλματα, τα οποία μπορούν να εξομαλυνθούν μέσω κατάλληλης στάθμισης πιθανοτήτων.

5.5 Αποτελέσματα Ιεραρχικού Ταξινομητή

Πίνακας 15.Αποτελέσματα του Ιεραρχικού Ταξινομητή δύο σταδίων.

Feature Set	Diagnostic Scenario	Macro-F1 score
Stage-1: ModelGenesis (Binary) → Stage-2: Med3D (Dementia)	3-class	0.6469

Ο ιεραρχικός ταξινομητής επιτυγχάνει Macro-F1 = 0.6469 στο τελικό 3-class mapping, παρουσιάζοντας βελτιωμένη σταθερότητα σε σχέση με την απευθείας πολυκλασική εκπαίδευση. Παρά τη μείωση της πολυπλοκότητας μέσω διάσπασης σε δυαδικά υποπροβλήματα, τα σφάλματα του πρώτου σταδίου επηρεάζουν αλυσιδωτά το τελικό αποτέλεσμα.

5.6 Συνολικά Καλύτερα Αποτελέσματα και Σύγκριση

5.6.1 Σενάριο Δυαδικής Ταξινόμησης

Το βελτιστοποιημένο MLP πέτυχε Macro-F1 = 0.8245, Balanced Accuracy = 0.8319 και AUC = 0.8427, επιβεβαιώνοντας σταθερή και ισορροπημένη απόδοση στο δυαδικό σενάριο.

Από τον πίνακα ταξινόμησης προκύπτει ότι:

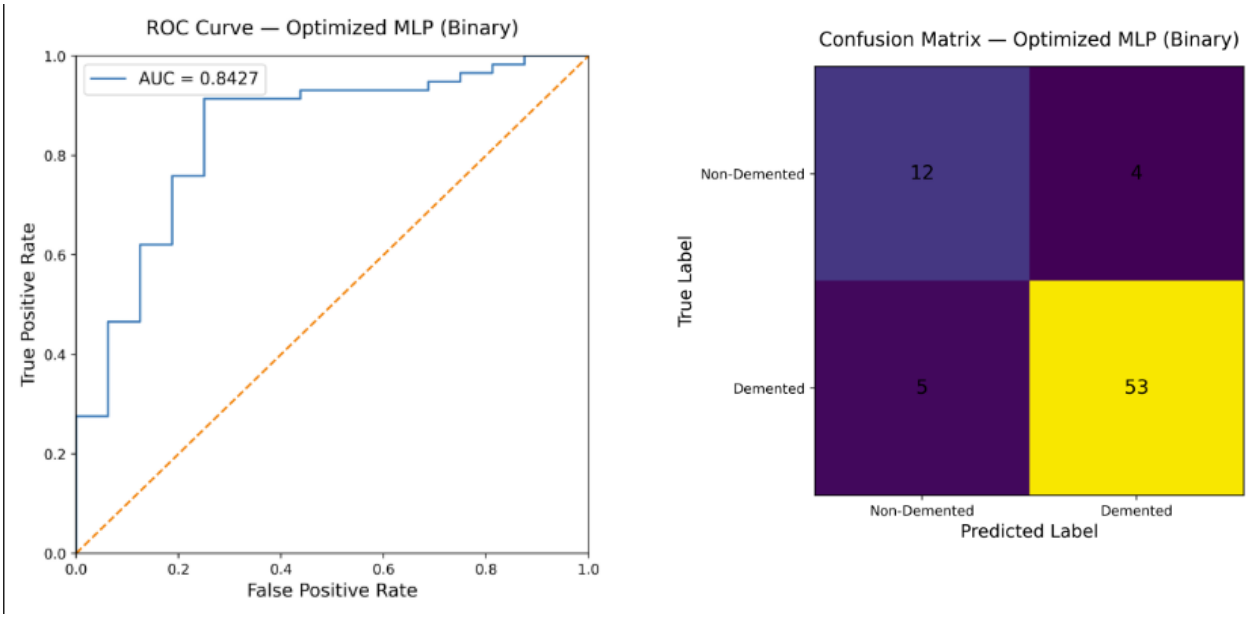
- Στην κλάση Non-Demented (16 δείγματα) η απόδοση είναι ικανοποιητική (F1 = 0.73), με 4 λανθασμένες ταξινομήσεις προς Demented.
- Στην κλάση Demented (58 δείγματα) η επίδοση είναι ιδιαίτερα υψηλή (F1 = 0.92), με πολύ καλή ανάκληση (0.91).

Η μικρή ανισορροπία του συνόλου (16 έναντι 58) δεν φαίνεται να επηρέασε έντονα το μοντέλο, καθώς η χρήση SMOTE και weighted sampling συνέβαλε σε πιο ισορροπημένη εκμάθηση.

Η καμπύλη ROC δείχνει καλή διαχωριστική ικανότητα, με AUC > 0.84, γεγονός που επιβεβαιώνει ότι το μοντέλο διαχωρίζει αποτελεσματικά τις δύο κατηγορίες σε επίπεδο πιθανοτήτων και όχι μόνο σκληρής πρόβλεψης.

Παρατηρείται ότι η απόδοση στο validation (Val F1 = 0.7055 στο epoch 300) είναι χαμηλότερη από την τελική στο test, γεγονός που υποδηλώνει ότι το test split πιθανόν είναι ελαφρώς ευνοϊκότερο ή ότι η διαδικασία early stopping οδήγησε σε σταθεροποιημένο αλλά όχι πλήρως βελτιστοποιημένο validation peak.

Συνολικά, το μοντέλο παρουσιάζει ισχυρή διαγνωστική ικανότητα στο δυαδικό σενάριο, με ιδιαίτερα καλή αναγνώριση της κατηγορίας Demented, η οποία αποτελεί και το κλινικά κρίσιμο σκέλος της ταξινόμησης.



Εικόνα 3. Αξιολόγηση της απόδοσης του μοντέλου MLP στο δυαδικό σενάριο: (α) Καμπύλη ROC και (β) Πίνακας σύγχυσης.

Πίνακας 16.Αναλυτικά μετρικά αξιολόγησης για το βελτιστοποιημένο μοντέλο MLP στις κλάσεις Non-Demented (0) και Demented (1).

	Precision	Recall	F1-score	Number of samples
0	0.7059	0.7500	0.7273	16
1	0.9298	0.9138	0.9217	58
accuracy			0.8784	74
macro avg	0.8179	0.8319	0.8245	74
weighted avg	0.8814	0.8784	0.8797	74

Η τιμή του macro-F1 υποδεικνύει ισορροπημένη συνολική απόδοση μεταξύ των δύο κλάσεων. Η Balanced Accuracy (0.8319) επιβεβαιώνει ότι η ταξινόμηση δεν επηρεάζεται έντονα από την ανισορροπία του δείγματος.

Για την κλάση Non-Demented (0) παρατηρείται F1-score = 0.7273, με recall = 0.75, γεγονός που δείχνει ικανοποιητική αλλά όχι άριστη αναγνώριση. Αντίθετα, η κλάση Demented (1) επιτυγχάνει F1-score 0.9217, με υψηλή precision (0.93) και recall (0.91), υποδηλώνοντας πολύ καλή ανίχνευση των περιστατικών άνοιας.

Η συνολική ακρίβεια του μοντέλου ανέρχεται σε 87.84%, δείχνοντας ισχυρή συνολική απόδοση στο δυαδικό διαγνωστικό σενάριο.

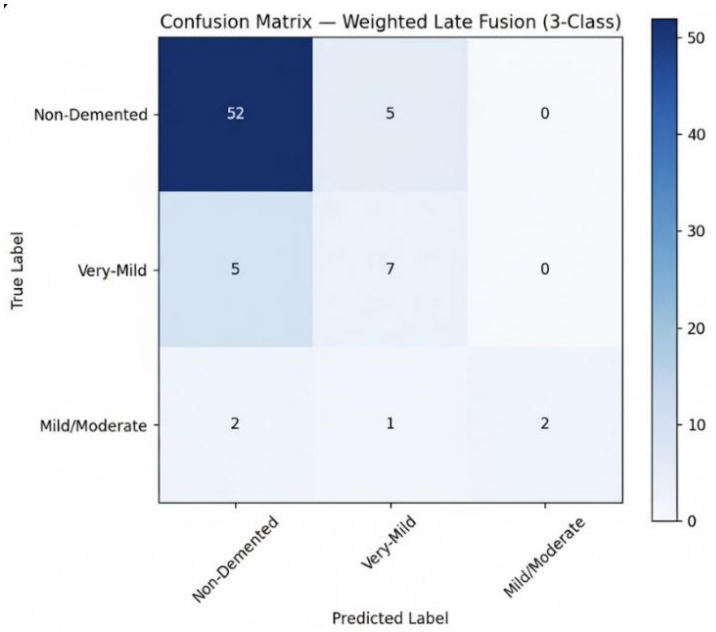
Η υπεροχή του συνδυασμού ModelGenesis με STD προεπεξεργασία ερμηνεύεται από τη φύση της αναπαράστασης που μαθαίνει το συγκεκριμένο backbone. Το ModelGenesis έχει εκπαιδευτεί μέσω self-supervised στρατηγικών σε ιατρικά δεδομένα, γεγονός που ενισχύει την ικανότητά του να αποτυπώνει δομικά και μορφολογικά πρότυπα σε επίπεδο τρισδιάστατου όγκου, χωρίς να εξαρτάται αποκλειστικά από επιφανειακές υφές. Η χρήση της τυπικής κανονικοποίησης (STD) διατηρεί τη συνολική πληροφορία του embedding χωρίς να μειώνει τη διάστασή του, επιτρέποντας στο MLP να αξιοποιήσει πλήρως τη χωρητικότητα του μοντέλου. Σε αντίθεση με την PCA, η οποία επιβάλλει γραμμικό περιορισμό της αναπαράστασης και ενδέχεται να απορρίπτει λεπτές διακριτικές μεταβολές, η STD διατηρεί τις μικροδιακυμάνσεις που σχετίζονται με πρώιμες μορφολογικές αλλοιώσεις. Ως αποτέλεσμα, ο συγκεκριμένος συνδυασμός φαίνεται να προσφέρει πιο πλούσια και διαχωρίσιμη αναπαράσταση στο δυαδικό πρόβλημα ανίχνευσης άνοιας.

5.6.2 Σενάριο 3 κλάσεων

Στο σενάριο ταξινόμησης τριών κλάσεων, η βέλτιστη απόδοση επιτεύχθηκε με τη μέθοδο Weighted Late Fusion (Med3D + ModelGenesis), η οποία παρουσίασε Macro-F1 = 0.6760. Η επίδοση αυτή υπερβαίνει τόσο την άμεση (direct) 3-class μοντέλο όσο και την ιεραρχική προσέγγιση, γεγονός που υποδεικνύει ότι ο συνδυασμός ετερογενών βαθιών αναπαραστάσεων συμβάλλει ουσιαστικά στη βελτίωση της διαχωριστικής ικανότητας στο πολυκλασικό πρόβλημα.

Πίνακας 17.Συγκριτική απόδοση των βασικών προσεγγίσεων (Direct 3-class, Fusion και Hierarchical) με βάση τη μετρική Macro-F1.

Feature Set	Diagnostic Scenario	Best Model	Macro-F1
Med3D_pca/std	3-class(Direct)	Gradient Boosting	0.6325
Med3D_std+ ModelGenesis_pca	3-class(Fusion)	Med3D + Model Genesis	0.6740
Stage-1: ModelGenesis (Binary) → Stage-2: Med3D (Dementia)	3-class(Hierarchical)	Stage 1 + Stage 2	0.6469



Εικόνα 4.Πίνακας σύγχυσης της μεθόδου Weighted Late Fusion στο σενάριο τριών κλάσεων.

Πίνακας 18.Αναλυτικές μετρικές αξιολόγησης για το βέλτιστο μοντέλο 3-class.

	Precision	Recall	F1-score	Number of samples
0	0.8814	0.9123	0.8966	57
1	0.5385	0.5833	0.5600	12
2	1.0000	0.4000	0.5714	5
accuracy			0.7568	74
macro- avg	0.8066	0.6319	0.6760	74
weighted-avg	0.8335	0.7568	0.7200	74

Η ανάλυση του πίνακα σύγχυσης δείχνει ότι η κλάση Non-Demented αναγνωρίζεται με ιδιαίτερα υψηλή αξιοπιστία, καθώς 52 από τα 57 δείγματα ταξινομήθηκαν σωστά, με F1-score 0.8966 και recall 0.9123. Οι λανθασμένες ταξινομήσεις περιορίζονται κυρίως προς την κλάση Very-Mild, χωρίς σύγχυση με τη σοβαρότερη κατηγορία Mild/Moderate, γεγονός που υποδηλώνει σαφή διαχωρισμό μεταξύ φυσιολογικών και προχωρημένων περιστατικών.

Αντίθετα, η κλάση Very-Mild εμφανίζει μέτρια απόδοση, με F1-score 0.5600 και recall 0.5833. Παρατηρείται σύγχυση κυρίως προς την κατηγορία Non-Demented, κάτι που είναι αναμενόμενο, καθώς τα πρώιμα στάδια γνωστικής έκπτωσης χαρακτηρίζονται από ήπιες δομικές αλλοιώσεις, οι οποίες ενδέχεται να επικαλύπτονται με τη φυσιολογική ανατομική μεταβλητότητα.

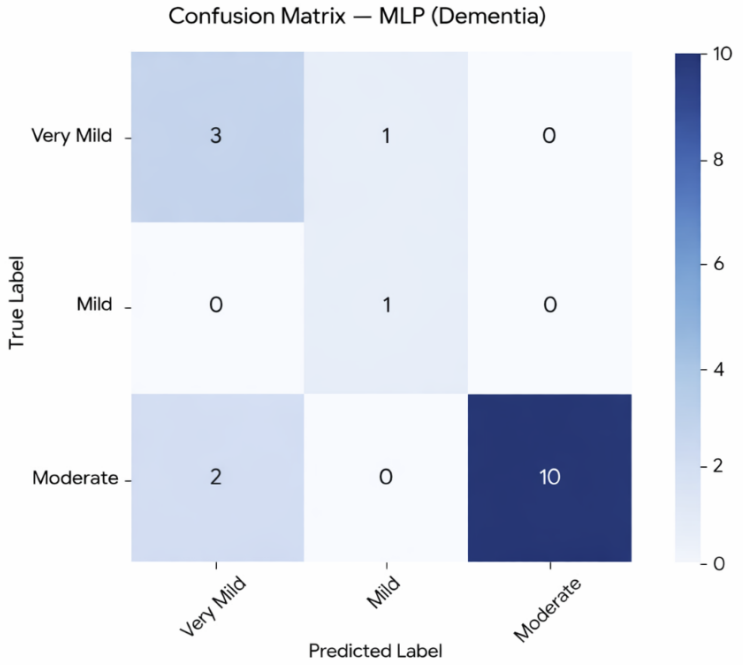
Η κλάση Mild/Moderate παρουσιάζει F1-score 0.5714 και recall 0.4000, με περιορισμένο αριθμό σωστών προβλέψεων. Η μειωμένη ανάκληση εξηγείται σε μεγάλο βαθμό από το πολύ μικρό πλήθος δειγμάτων στο test set, γεγονός που επηρεάζει τη στατιστική σταθερότητα της εκτίμησης και αυξάνει την ευαισθησία σε μεμονωμένες λανθασμένες προβλέψεις.

Συνολικά, η τιμή του Macro-F1 υποδηλώνει ικανοποιητική αλλά μη ομοιόμορφη απόδοση μεταξύ των τριών κατηγοριών. Το μοντέλο επιτυγχάνει σαφή διάκριση των Non-Demented, ενώ η κύρια δυσκολία εντοπίζεται στη διαβάθμιση των σταδίων άνοιας, ιδιαίτερα μεταξύ Very-Mild και Mild/Moderate. Το αποτέλεσμα αυτό είναι σύμφωνο με τη φύση του προβλήματος, καθώς πρόκειται για συνεχές παθολογικό φάσμα και όχι για απόλυτα διακριτές κατηγορίες.

Η βελτίωση που επιτυγχάνεται μέσω της weighted late fusion επιβεβαιώνει ότι ο συνδυασμός χαρακτηριστικών από διαφορετικά προεκπαιδευμένα 3D δίκτυα οδηγεί σε πιο ανθεκτικές και γενικεύσιμες αναπαραστάσεις σε σχέση με μεμονωμένα μοντέλα, ιδιαίτερα σε περιβάλλοντα με περιορισμένο και ανισομερές ιατρικό dataset.

5.6.3 Σενάριο Εκτίμησης Βαθμού Άνοιας

Στο σενάριο ταξινόμησης βαθμού άνοιας το βέλτιστο μοντέλο πέτυχε Macro-F1 = 0.7424, υποδηλώνοντας ικανοποιητική και σχετικά ισορροπημένη συνολική απόδοση μεταξύ των τριών κατηγοριών. Ωστόσο, η επίδραση της ανισορροπίας του συνόλου (12 Moderate έναντι 4 Very Mild και 1 Mild) είναι εμφανής, καθώς το μοντέλο εμφανίζει καλύτερη προσαρμογή στην πλειοψηφική κλάση.



Εικόνα 5.Πίνακας σύγχυσης του βέλτιστου μοντέλου για την εκτίμηση βαθμού άνοιας, αποτυπώνοντας τη διακριτική ικανότητα ανά στάδιο.

Πίνακας 19.Αναλυτικές μετρικές αξιολόγησης για το βέλτιστο μοντέλο 3-class.

	Precision	Recall	F1-score	Number of samples
0	0.6000	0.7500	0.6700	4
1	0.5000	1.0000	0.6700	1
2	1.0000	0.8300	0.9100	12
accuracy			0.8200	17
macro- avg	0.7000	0.8600	0.7500	17
weighted-avg	0.8824	0.8235	0.8390	17

Ο πίνακας σύγχυσης δείχνει ότι από τα συνολικά 17 δείγματα του test set (4 Very Mild, 1 Mild, 12 Moderate), το μοντέλο ταξινόμησε σωστά 14, επιτυγχάνοντας συνολική ακρίβεια 0.82. Ειδικότερα, στην κλάση Moderate παρατηρείται ιδιαίτερα υψηλή απόδοση, με 10 σωστές προβλέψεις σε 12 δείγματα, γεγονός που οδηγεί σε F1-score 0.91. Η συγκεκριμένη επίδοση υποδηλώνει ότι τα χαρακτηριστικά του Med3D αποτυπώνουν αποτελεσματικά τα εντονότερα μορφολογικά πρότυπα που αντιστοιχούν σε προχωρημένο στάδιο άνοιας.

Για την κλάση Very Mild, το μοντέλο ταξινόμησε σωστά 3 από τα 4 δείγματα (recall = 0.75), παρουσιάζοντας F1-score 0.67. Η κύρια πηγή σφάλματος αφορά σύγχυση με γειτονικό στάδιο βαρύτητας, κάτι αναμενόμενο δεδομένου ότι οι δομικές αλλοιώσεις στο πρώιμο στάδιο είναι λεπτές και συχνά επικαλύπτονται μορφολογικά με άλλα στάδια.

Στην κλάση Mild, αν και το μοναδικό δείγμα του test set ταξινομήθηκε σωστά (recall = 1.00), η τιμή precision διαμορφώνεται χαμηλότερα λόγω ψευδώς θετικών προβλέψεων από άλλες κλάσεις. Το γεγονός ότι η συγκεκριμένη κατηγορία εκπροσωπείται από πολύ μικρό αριθμό δειγμάτων περιορίζει τη στατιστική σταθερότητα της εκτίμησης.

Η διαφορά μεταξύ της τιμής Macro-F1 (0.75) και της Weighted-F1 (0.839) οφείλεται στην ανισορροπία του συνόλου δεδομένων. Η Macro-F1 υπολογίζει τον απλό μέσο όρο των F1-scores των τριών κλάσεων, δίνοντας ίσο βάρος σε κάθε κατηγορία ανεξαρτήτως μεγέθους. Αντίθετα, η Weighted-F1 σταθμίζει την απόδοση κάθε κλάσης με βάση τον αριθμό των δειγμάτων της. Στο συγκεκριμένο test set, η κλάση Moderate αποτελεί την πλειοψηφία (12 από τα 17 δείγματα) και παρουσιάζει πολύ υψηλό F1-score (0.91). Επομένως, η ισχυρή επίδοση στην πλειοψηφική κλάση αυξάνει σημαντικά τη σταθμισμένη μέση τιμή, οδηγώντας σε υψηλότερη Weighted-F1 σε σχέση με τη Macro-F1. Συνολικά, η επίδοση αυτή αναδεικνύει τη συμβολή τόσο του προεκπαιδευμένου Med3D όσο και της τυποποίησης (standardization – STD) των χαρακτηριστικών. Το Med3D, έχοντας εκπαιδευτεί σε μεγάλο όγκο ιατρικών τρισδιάστατων δεδομένων, έχει μάθει να ανιχνεύει χωρικά και μορφολογικά πρότυπα που σχετίζονται με δομικές μεταβολές του εγκεφάλου, γεγονός που το καθιστά ιδιαίτερα κατάλληλο για την αναγνώριση προχωρημένων σταδίων άνοιας. Παράλληλα, η εφαρμογή τυποποίησης εξομαλύνει την κλίμακα των χαρακτηριστικών και μειώνει τις διαφοροποιήσεις που οφείλονται σε διαφορετικές κατανομές έντασης ή εύρους τιμών, διευκολύνοντας τον ταξινομητή να εστιάσει στις ουσιαστικές διαφοροποιήσεις μεταξύ των σταδίων. Ο συνδυασμός αυτών των δύο παραγόντων οδηγεί σε πιο σταθερή και γενικεύσιμη απόδοση στο πρόβλημα της εκτίμησης βαθμού άνοιας.

Κεφάλαιο 6. Συζήτηση

6.1 Ερμηνεία των Πειραματικών Αποτελεσμάτων

Στο παρόν κεφάλαιο ερμηνεύουμε συστηματικά τα αποτελέσματα των πειραμάτων και αναλύουμε τη συμπεριφορά των προτεινόμενων μοντέλων υπό διαφορετικές στρατηγικές ταξινόμησης.

- Η αξιολόγηση έδειξε ότι οι διαφορετικές προεκπαιδευμένες αρχιτεκτονικές (Med3D, MedicalNet, ModelGenesis) παράγουν συμπληρωματικές αναπαραστάσεις των MRI δεδομένων, γεγονός που επιβεβαιώνει ότι κάθε backbone εστιάζει σε διαφορετικά μορφολογικά πρότυπα. Η απόδοση των μεμονωμένων ταξινομητών παρουσίασε διακυμάνσεις ανάλογα με το επίπεδο πολυπλοκότητας του προβλήματος (δυαδικό ή πολυκατηγορικό), γεγονός που αναδεικνύει τη δυσκολία διαχωρισμού των ενδιάμεσων σταδίων άνοιας.

- Η χρήση ιεραρχικής στρατηγικής οδήγησε σε πιο σταθερή διαγνωστική συμπεριφορά, καθώς ο αρχικός διαχωρισμός Non-Demented έναντι Demented μείωσε τη σύγχυση μεταξύ ετερογενών κλάσεων. Με τον τρόπο αυτό απομονώθηκε το κλινικά κρίσιμο πρώτο στάδιο απόφασης και περιορίστηκε η διάχυση σφαλμάτων προς τις επιμέρους υποκατηγορίες. Ωστόσο, ο ιεραρχικός ταξινομητής επηρεάστηκε από τη διάδοση σφαλμάτων μεταξύ των σταδίων.

- Παρατηρήθηκαν επίσης ανταλλαγές μεταξύ Precision και Recall σε ορισμένα μοντέλα. Η αύξηση του precision συνοδεύτηκε σε ορισμένες περιπτώσεις από ελαφρά μείωση του recall, γεγονός που υπογραμμίζει την ανάγκη ισορροπίας μεταξύ αποφυγής ψευδώς αρνητικών και περιορισμού ψευδώς θετικών διαγνώσεων. Η χρήση της Macro-F1 ως βασικής μετρικής κρίθηκε κατάλληλη λόγω της ανισορροπίας κλάσεων.

- Η στρατηγική συνένωσης (fusion) επέτρεψε την αξιοποίηση της συμπληρωματικότητας των embeddings, οδηγώντας σε συνολικά βελτιωμένη σταθερότητα απόδοσης σε σύγκριση με τα μεμονωμένα μοντέλα. Το αποτέλεσμα αυτό επιβεβαιώνει ότι η πολυ-αναπαραστασιακή προσέγγιση είναι καταλληλότερη για σύνθετα ιατρικά προβλήματα.

Μία πολύ σημαντική παρατήρηση είναι ότι η απόδοση δεν εξαρτάται μόνο από τον ταξινομητή, αλλά κυρίως από τη φύση των εξαγόμενων αναπαραστάσεων και τη στρατηγική εκμετάλλευσής τους. Πιο συγκεκριμένα όπως αναφέρθηκε και στο (Κεφ.5):

- Στη δυαδική διάκριση, το ModelGenesis σε συνδυασμό με MLP παρουσίασε τη μεγαλύτερη σταθερότητα και γενικευτική ικανότητα. Η self-supervised προεκπαίδευση φαίνεται να επιτρέπει την εκμάθηση αφηρημένων δομικών προτύπων, τα οποία διαχωρίζουν αποτελεσματικά φυσιολογικούς από παθολογικούς εγκεφάλους, ακόμη και σε περιορισμένο δείγμα.
- Αντίθετα, στην εκτίμηση βαθμού άνοιας, το Med3D απέδωσε καλύτερα. Η καθαρά ογκομετρική (volumetric) εκπαίδευση σε 3D ιατρικά δεδομένα ευνοεί την ανίχνευση λεπτών χωρικών διαφορών που χαρακτηρίζουν τα γειτονικά στάδια βαρύτητας. Η διάκριση μεταξύ Mild και Moderate δεν απαιτεί μόνο

ανίχνευση παθολογίας, αλλά εκτίμηση έντασης και κατανομής εκφυλιστικών μεταβολών, κάτι που φαίνεται να υποστηρίζεται επαρκώς από 3D προεκπαιδευμένα ιατρικά δίκτυα.

- Στην τριταξική ταξινόμηση, η δυσκολία αυξάνεται σημαντικά, καθώς το ενδιάμεσο στάδιο δεν διαθέτει σαφή μορφολογικά όρια. Η άμεση 3-class προσέγγιση ήταν πιο απαιτητική, ενώ ο συνδυασμός μοντέλων μέσω σταθμισμένου late fusion παρείχε πιο ισορροπημένη συμπεριφορά. Η υπεροχή μη ισοβαρούς στάθμισης επιβεβαιώνει ότι τα backbones δεν συνεισφέρουν ισοδύναμα, αλλά συμπληρωματικά.

6.2 Ανταλλαγές μεταξύ των Μετρικών

Στην ιατρική διάγνωση, οι μετρικές δεν ερμηνεύονται μεμονωμένα καθώς η βελτίωση μιας μετρικής δεν συνεπάγεται απαραίτητα συνολική υπεροχή. Η ακρίβεια (accuracy) μπορεί να είναι παραπλανητική σε μη πλήρως ισορροπημένα σύνολα, γι' αυτό η Macro-F1 αποτέλεσε βασικό δείκτη αξιολόγηση, καθώς αποδίδει ίσο βάρος σε όλες τις κατηγορίες και αποτρέπει την υπερεκτίμηση μοντέλων που αποδίδουν καλά μόνο στην πλειοψηφική κλάση. Η επιλογή αυτή ενισχύει τη διαγνωστική αξιοπιστία του συστήματος. Η Weighted-F1, αν και χρήσιμη, επηρεάζεται έντονα από την πλειοψηφική κατηγορία και μπορεί να δημιουργήσει εντύπωση βελτιωμένης συνολικής επίδοσης χωρίς αντίστοιχη βελτίωση στη διακριτική ικανότητα για όλες τις κλάσεις.

Η επιλογή μεταξύ precision και recall έχει ιδιαίτερη σημασία. Υψηλό recall μειώνει τον κίνδυνο να χαθεί ασθενής, ενώ υψηλό precision περιορίζει τις ψευδώς θετικές διαγνώσεις. Στο πλαίσιο της άνοιας, η ισορροπία αυτών των δύο είναι κρίσιμη, καθώς τόσο η καθυστέρηση διάγνωσης όσο και η λανθασμένη ταξινόμηση υγιών ατόμων έχουν σοβαρές επιπτώσεις.

6.3 Σύγκριση με Βιβλιογραφία

Τα αποτελέσματα κινούνται σε επίπεδα συγκρίσιμα με πρόσφατες μελέτες που βασίζονται σε 3D CNN αρχιτεκτονικές για ανίχνευση Alzheimer's από MRI .Ιδιαίτερα στη δυαδική διάκριση, τα αποτελέσματα είναι ανταγωνιστικά με μελέτες που εφαρμόζουν πλήρως end-to-end 3D μοντέλα, παρά το γεγονός ότι εδώ χρησιμοποιήθηκε προσέγγιση feature extraction και κλασικών ταξινομητών. Επιπλέον, όσο αφορά τη χρήση της μεθόδου «Μεταφοράς Μάθησης» τα αποτελέσματα ευθυγραμμίζονται με πρόσφατες μελέτες όπου η μεταφορά γνώσης βελτιώνει τη διακριτική ικανότητα σε μικρά ιατρικά σύνολα δεδομένων. Παράλληλα, η χρήση στρατηγικών fusion έχει αναφερθεί ως αποτελεσματική σε πολυπαραγοντικά διαγνωστικά σενάρια το οποίο επιβεβαιώνεται και στην

παρούσα εργασία όπου ο συνδυασμός ιεραρχικής ταξινόμησης και fusion μπορεί να προσφέρει πιο σταθερή απόδοση από μία επίπεδη πολυκατηγορική προσέγγιση. Οι ενσωματώσεις αυτές αποτελούν προσθήκες σε σχέση με προσεγγίσεις που χρησιμοποιούν μεμονωμένα backbones.

6.4 Μεθοδολογικές Επιπτώσεις

Τα ευρήματα υποδεικνύουν ότι η απλή ισοβαρής συγχώνευση πιθανοτήτων δεν είναι πάντοτε βέλτιστη. Η μη ισότιμη συνεισφορά των backbones καθιστά απαραίτητη τη ρύθμιση βαρών, ιδίως όταν τα embeddings έχουν διαφορετική πληροφοριακή πυκνότητα.

Η χρήση PCA οδήγησε σε μείωση διαστασιμότητας και γρηγορότερη εκπαίδευση, ωστόσο σε ορισμένες περιπτώσεις παρατηρήθηκε απώλεια διακριτικής πληροφορίας. Αντίθετα, η τυποποίηση (STD) διατήρησε την πλήρη πληροφορία των embeddings και ευνόησε μη γραμμικούς ταξινομητές, οι οποίοι μπορούν να εκμεταλλευτούν τη συνολική γεωμετρία του χαρακτηριστικού χώρου.

6.5 Περιορισμοί της Προτεινόμενης Προσέγγισης

Παρά τη συστηματική πειραματική αξιολόγηση, η προτεινόμενη προσέγγιση παρουσιάζει ορισμένους περιορισμούς που επηρεάζουν τη γενικευσιμότητα και την κλινική μεταφερσιμότητα των αποτελεσμάτων.

Αρχικά, το σύνολο δεδομένων προέρχεται από μία μόνο πηγή, γεγονός που περιορίζει την ικανότητα γενίκευσης του μοντέλου σε ετερογενείς πληθυσμούς και διαφορετικά πρωτόκολλα λήψης MRI. Η απουσία εξωτερικής επικύρωσης σε ανεξάρτητο dataset δεν επιτρέπει την πλήρη αξιολόγηση της ανθεκτικότητας του συστήματος σε δεδομένα εκτός κατανομής (out-of-distribution samples).

Επιπλέον, το μέγεθος του δείγματος παραμένει σχετικά περιορισμένο για βαθιά νευρωνικά δίκτυα τρισδιάστατης ανάλυσης. Η ανισορροπία μεταξύ των κλάσεων ενδέχεται να ενισχύει φαινόμενα μεροληψίας προς την πλειοψηφική κατηγορία, παρά τη χρήση τεχνικών εξισορρόπησης και σταθμισμένων μετρικών αξιολόγησης.

Η αξιολόγηση πραγματοποιήθηκε σε περιβάλλον offline πειραμάτων και όχι σε πραγματικές κλινικές συνθήκες, όπου παράγοντες όπως ο θόρυβος δεδομένων, οι διαφορές εξοπλισμού και η διακύμανση μεταξύ κέντρων ενδέχεται να επηρεάσουν την απόδοση.

Επιπρόσθετα, δεν διερευνήθηκε η ερμηνευσιμότητα των παραγόμενων αναπαραστάσεων (embeddings), στοιχείο ιδιαίτερα σημαντικό για εφαρμογές σε ιατρικό πλαίσιο. Παράλληλα, δεν πραγματοποιήθηκε fine-tuning των προεκπαιδευμένων 3D backbones στο συγκεκριμένο dataset, γεγονός που πιθανόν περιορίζει τη μέγιστη δυνατή απόδοση στο συγκεκριμένο πρόβλημα.

Οι παραπάνω περιορισμοί αναδεικνύουν την ανάγκη μελλοντικής αξιολόγησης σε πολυκεντρικά δεδομένα, με ενσωμάτωση τεχνικών ερμηνευσιμότητας και πιθανή προσαρμογή (fine-tuning) των αρχιτεκτονικών στο εκάστοτε κλινικό περιβάλλον.

6.6 Συνολική Τοποθέτηση

Συνολικά, τα αποτελέσματα της παρούσας μελέτης υποδεικνύουν ότι δεν υφίσταται μία καθολικά βέλτιστη αρχιτεκτονική για όλα τα διαγνωστικά σενάρια που σχετίζονται με την άνοια. Η απόδοση εξαρτάται ουσιαστικά από τη φύση του προβλήματος (δυαδική ανίχνευση έναντι εκτίμησης βαρύτητας) καθώς και από τη στρατηγική αξιοποίησης των παραγόμενων αναπαραστάσεων. Τα ευρήματα καταδεικνύουν ότι σε μικρά και ετερογενή ιατρικά σύνολα δεδομένων, η στρατηγική διαχείρισης των χαρακτηριστικών

και των αναπαραστάσεων είναι εξίσου κρίσιμη με την ίδια την επιλογή του backbone. Η μεθοδολογική επιλογή ιεραρχικής ταξινόμησης επιβεβαιώνει ότι η αποσύνθεση ενός σύνθετου προβλήματος σε διαδοχικά απλούστερα υποπροβλήματα μπορεί να βελτιώσει τη σταθερότητα και ερμηνευσιμότητα του συστήματος.

Με τον τρόπο αυτό, η εργασία τοποθετείται στο πλαίσιο των σύγχρονων προσεγγίσεων που δίνουν έμφαση όχι μόνο στην αρχιτεκτονική των νευρωνικών δικτύων, αλλά και στη στρατηγική ενοποίησης και αξιοποίησης της μεταφερόμενης γνώσης.

Κεφάλαιο 7. Συμπεράσματα & Μελλοντική Έρευνα

7.1 Σύνοψη Συνεισφορών

Η παρούσα εργασία ανέπτυξε ένα πλήρες υπολογιστικό πλαίσιο για την αυτόματη ανίχνευση και εκτίμηση βαθμού άνοιας από τρισδιάστατα δεδομένα μαγνητικής τομογραφίας εγκεφάλου. Το προτεινόμενο pipeline περιλάμβανε στάδια προεπεξεργασίας, ενοποίησης βάθους όγκου, εξαγωγής χαρακτηριστικών μέσω προεκπαιδευμένων 3D νευρωνικών δικτύων και συστηματικής σύγκρισης εναλλακτικών στρατηγικών ταξινόμησης.

Πραγματοποιήθηκε συγκριτική αξιολόγηση τριών διαφορετικών backbones (Med3D, ModelGenesis, MedicalNet) τόσο σε δυαδικό σενάριο ανίχνευσης παθολογίας όσο και σε πολυταξικό σενάριο εκτίμησης βαθμού άνοιας. Διερευνήθηκαν πολλαπλές στρατηγικές συνένωσης πληροφορίας (early, mid, late και weighted fusion), καθώς και ιεραρχική προσέγγιση δύο σταδίων, προσεγγίζοντας τη λογική της κλινικής διάγνωσης μέσω διαδοχικών αποφάσεων.

Παράλληλα, υλοποιήθηκαν βελτιστοποιημένες αρχιτεκτονικές MLP με τεχνικές κανονικοποίησης και regularization, αναδεικνύοντας τη σημασία της ορθής αξιοποίησης των παραγόμενων embeddings. Τα αποτελέσματα κατέδειξαν ότι η στρατηγική διαχείρισης και συνδυασμού των χαρακτηριστικών είναι εξίσου κρίσιμη με την ίδια την επιλογή του backbone, ιδιαίτερα σε μικρά και ανισόρροπα ιατρικά σύνολα δεδομένων.

Η βασική συνεισφορά της εργασίας έγκειται στη συστηματική διερεύνηση της συμπληρωματικότητας διαφορετικών προεκπαιδευμένων 3D αναπαραστάσεων και στην αξιολόγηση εναλλακτικών αρχιτεκτονικών στρατηγικών (fusion και hierarchical classification) για την ενίσχυση της διαγνωστικής απόδοσης.

7.2 Συμπεράσματα

Τα πειραματικά αποτελέσματα επιβεβαιώνουν ότι η αξιοποίηση προεκπαιδευμένων 3D μοντέλων σε δεδομένα MRI μπορεί να υποστηρίξει αποτελεσματικά τόσο τη δυαδική ανίχνευση παρουσίας άνοιας όσο και την εκτίμηση του βαθμού βαρύτητας της νόσου. Δεν αναδείχθηκε μία καθολικά βέλτιστη αρχιτεκτονική για όλα τα διαγνωστικά σενάρια. Το ModelGenesis εμφάνισε πλεονέκτημα στη δυαδική διάκριση, ενώ το Med3D απέδωσε καλύτερα στην εκτίμηση βαθμού άνοιας.
Στο πολυταξικό σενάριο, η σταθμισμένη στρατηγική late fusion παρείχε την πιο ισορροπημένη και σταθερή συμπεριφορά, επιβεβαιώνοντας ότι τα διαφορετικά backbones προσφέρουν συμπληρωματική πληροφορία. Η ανάλυση των μετρικών ανέδειξε τη σημασία της Macro-F1 ως κατάλληλου δείκτη αξιολόγησης σε συνθήκες ανισορροπίας κλάσεων, αποφεύγοντας την υπερεκτίμηση της απόδοσης σε πλειοψηφικές κατηγορίες.

Συνολικά, η εργασία καταδεικνύει ότι η προσεκτική επιλογή αναπαραστάσεων, η κατάλληλη στάθμιση πιθανοτήτων και η ελεγχόμενη πολυπλοκότητα οδηγούν σε πιο αξιόπιστα και γενικεύσιμα συστήματα υποβοηθούμενης διάγνωσης. Η απλή αύξηση της

πολυπλοκότητας ενός μοντέλου δεν εγγυάται απαραίτητα βελτίωση της απόδοσης, ιδιαίτερα σε περιορισμένα ιατρικά σύνολα δεδομένων.

7.3 Προτάσεις για Μελλοντική Έρευνα

Μελλοντική επέκταση της παρούσας προσέγγισης θα μπορούσε να περιλαμβάνει πολυτροπικό fusion, συνδυάζοντας δομική MRI με κλινικά, γνωστικά ή γενετικά δεδομένα, με στόχο τη βελτίωση της διαγνωστικής ευαισθησίας.

Η διερεύνηση εναλλακτικών αρχιτεκτονικών, όπως Vision Transformers ή υβριδικών CNN–Transformer μοντέλων, θα μπορούσε να προσφέρει διαφορετικούς μηχανισμούς χωρικής αναπαράστασης και να ενισχύσει την ικανότητα σύλληψης μακροσκοπικών δομικών συσχετίσεων.

Επιπλέον, η εξωτερική επικύρωση σε ανεξάρτητα και πολυκεντρικά σύνολα δεδομένων, καθώς και η εφαρμογή fine-tuning των προεκπαιδευμένων backbones σε μεγαλύτερα ιατρικά datasets, θα μπορούσαν να ενισχύσουν τη γενικευσιμότητα των αποτελεσμάτων.

Συμπερασματικά, η παρούσα εργασία αναδεικνύει ότι η επιτυχής εφαρμογή τεχνικών βαθιάς μάθησης σε 3D ιατρικά δεδομένα δεν εξαρτάται αποκλειστικά από την πολυπλοκότητα του μοντέλου, αλλά από τον συνδυασμό κατάλληλων αναπαραστάσεων, ορθής μεθοδολογικής σχεδίασης και προσεκτικής αξιολόγησης. Η προτεινόμενη προσέγγιση αποδεικνύει ότι ακόμη και σε περιορισμένα και ανισόρροπα σύνολα MRI δεδομένων, είναι εφικτή η ανάπτυξη αξιόπιστων συστημάτων υποβοηθούμενης διάγνωσης, τα οποία μπορούν να αποτελέσουν βάση για περαιτέρω ερευνητική και κλινική αξιοποίηση στον τομέα της νευροεκφυλιστικής νόσου.

Βιβλιογραφία

Bradshaw, T. J., Huemann, Z., Hu, J., & Rahmim, A. (2023). A Guide to Cross-Validation for Artificial Intelligence in Medical Imaging. In *Radiology: Artificial Intelligence* (Vol. 5, Number 4). https://doi.org/10.1148/ryai.220232

Chen, S., Ma, K., & Zheng, Y. (2019). *Med3D: Transfer Learning for 3D Medical Image Analysis*. http://arxiv.org/abs/1904.00625

Cui, Y., Jia, M., Lin, T.-Y., Song, Y., & Belongie, S. (2019). *Class-Balanced Loss Based on Effective Number of Samples*.

He, K., Huang, S., & Qian, X. (2019). Early detection and risk assessment for chronic disease with irregular longitudinal data analysis. *Journal of Biomedical Informatics*, *96*, 103231. https://doi.org/10.1016/j.jbi.2019.103231

Jack, C. R., Knopman, D. S., Jagust, W. J., Shaw, L. M., Aisen, P. S., Weiner, M. W., Petersen, R. C., & Trojanowski, J. Q. (2010). Hypothetical model of dynamic biomarkers of the Alzheimer's pathological cascade. *The Lancet Neurology*, *9*(1), 119–128. https://doi.org/10.1016/S1474-4422(09)70299-6

Livingston, G., Huntley, J., Sommerlad, A., Ames, D., Ballard, C., Banerjee, S., Brayne, C., Burns, A., Cohen-Mansfield, J., Cooper, C., Costafreda, S. G., Dias, A., Fox, N., Gitlin, L. N., Howard, R., Kales, H. C., Kivimäki, M., Larson, E. B., Ogunniyi, A., … Mukadam, N. (2020). Dementia prevention, intervention, and care: 2020 report of the Lancet Commission. In *The Lancet* (Vol. 396, Number 10248, pp. 413–446). Lancet Publishing Group. https://doi.org/10.1016/S0140-6736(20)30367-6

Otsu, N. (1979). A Threshold Selection Method from Gray-Level Histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, *9*(1), 62–66. https://doi.org/10.1109/TSMC.1979.4310076

Pan, S. J., & Yang, Q. (2010). A Survey on Transfer Learning. *IEEE Transactions on Knowledge and Data Engineering*, *22*(10), 1345–1359. https://doi.org/10.1109/TKDE.2009.191

Pande, S., & Banerjee, B. (2021). Adaptive hybrid attention network for hyperspectral image classification. *Pattern Recognition Letters*, *144*, 6–12. https://doi.org/10.1016/j.patrec.2021.01.015

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, *6*(1), 60. https://doi.org/10.1186/s40537-019-0197-0

Silva, G. S., Cortes, O. A. C., & Jacob, A. F. L. (2020). *Classification of Alzheimer's Disease by Magnetic Resonance Imaging with an Ensemble Approach*.

Smith, S. M. (2002). Fast robust automated brain extraction. *Human Brain Mapping*, *17*(3), 143–155. https://doi.org/10.1002/hbm.10062

Tustison, N. J., Avants, B. B., Cook, P. A., Yuanjie Zheng, Egan, A., Yushkevich, P. A., & Gee, J. C. (2010). N4ITK: Improved N3 Bias Correction. *IEEE Transactions on Medical Imaging*, *29*(6), 1310–1320. https://doi.org/10.1109/TMI.2010.2046908

World Health Organization. (2012). *Dementia: A public health priority*.

Zhang, L., Shah, S. K., & Kakadiaris, I. A. (2017). Hierarchical Multi-label Classification using Fully Associative Ensemble Learning. *Pattern Recognition*, *70*, 89–103. https://doi.org/10.1016/j.patcog.2017.05.007

Zhou, Z., Sodha, V., Pang, J., Gotway, M. B., & Liang, J. (2021). Models Genesis. *Medical Image Analysis*, *67*, 101840. https://doi.org/10.1016/j.media.2020.101840